

---

# **IMPLEMENTASI ENHANCED SUPER-RESOLUTION GENERATIVE ADVERSARIAL NETWORKS UNTUK SUPER-RESOLUTION DALAM IDENTIFIKASI PENYAKIT PADA TANAMAN KENTANG**

---

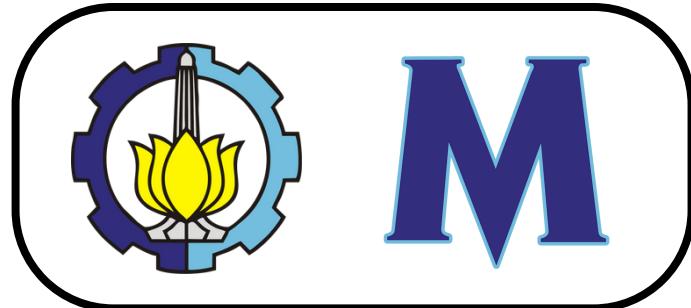
Oleh:  
Timmothy Farrel - 5002211118

Dosen Pembimbing:  
Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.

**DEPARTEMEN MATEMATIKA  
FAKULTAS SAINS DAN ANALITIKA DATA  
INSTITUT TEKNOLOGI SEPULUH NOPEMBER**



# POKOK BAHASAN



1

PENDAHULUAN

2

PERANCANGAN DAN  
IMPLEMENTASI

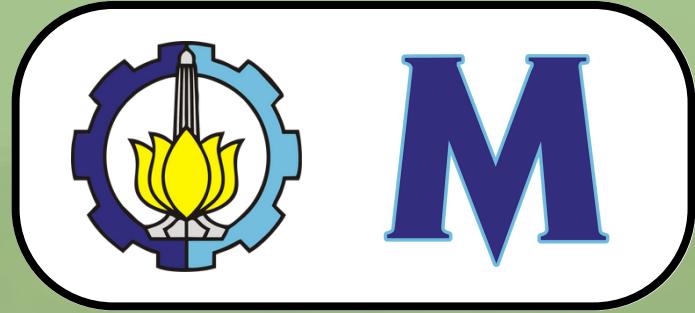
3

HASIL DAN  
PEMBAHASAN

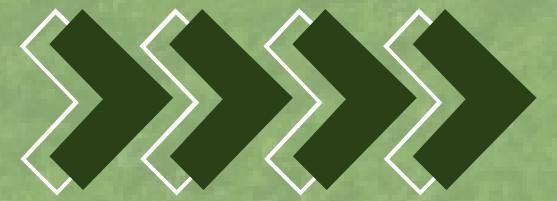
4

KESIMPULAN  
DAN SARAN

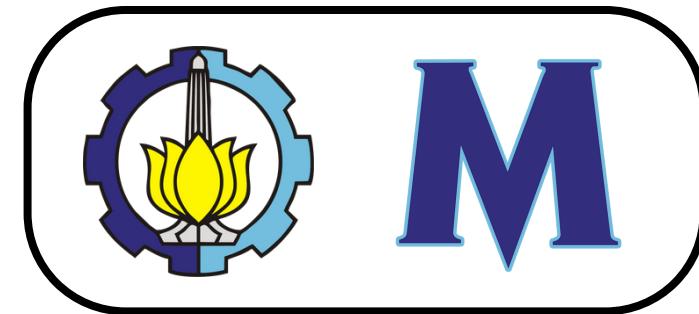




# PENDAHULUAN

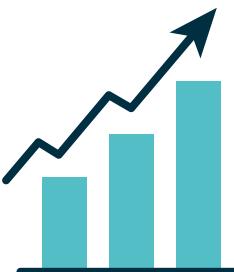


# LATAR BELAKANG

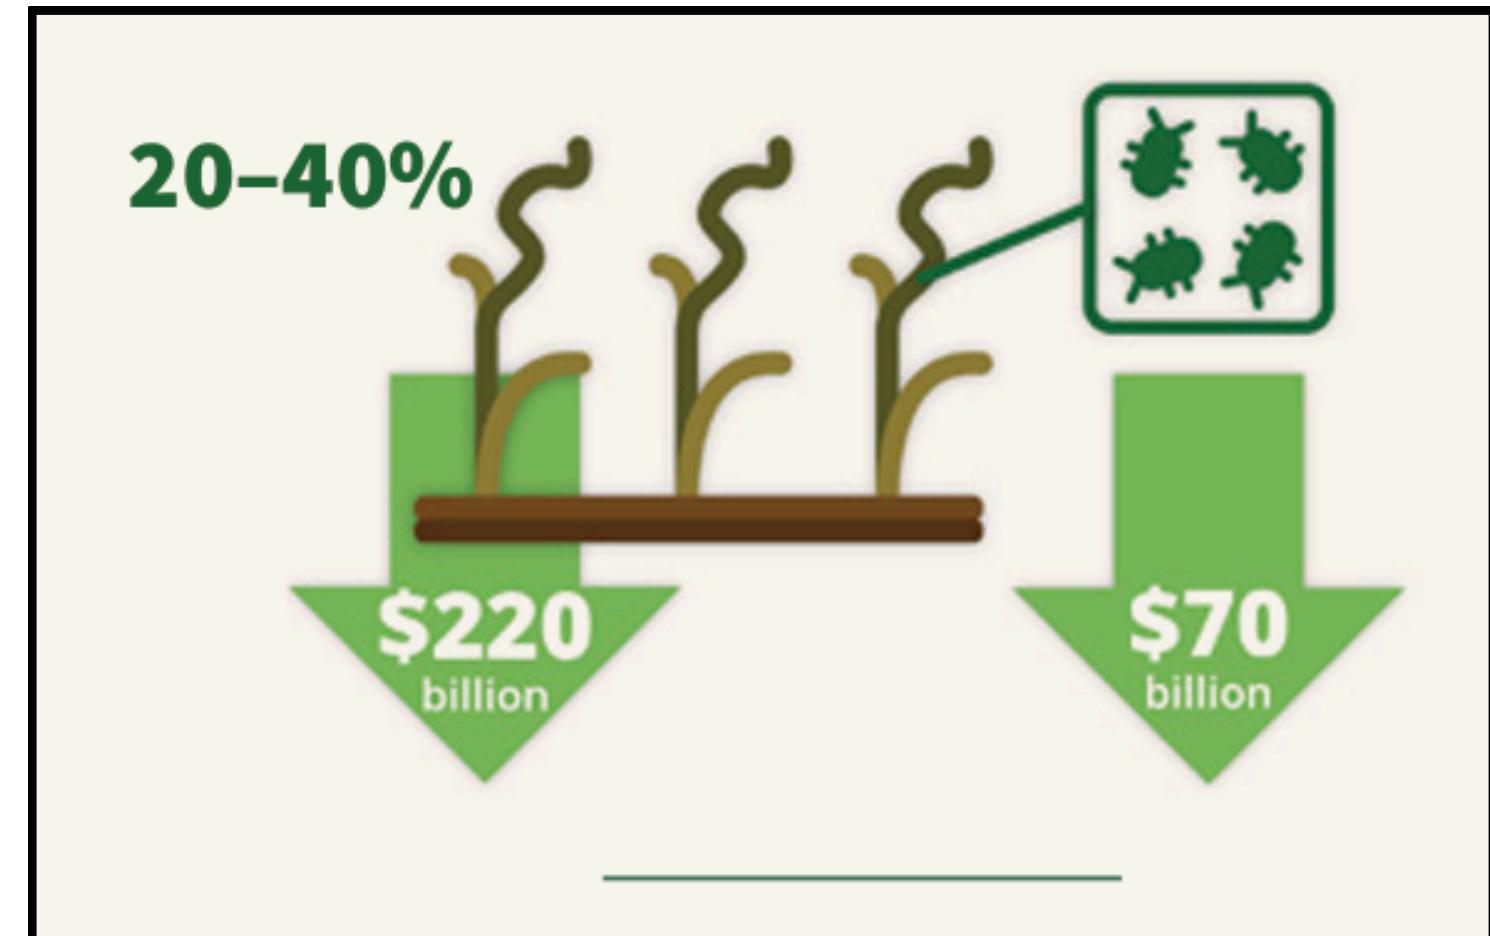
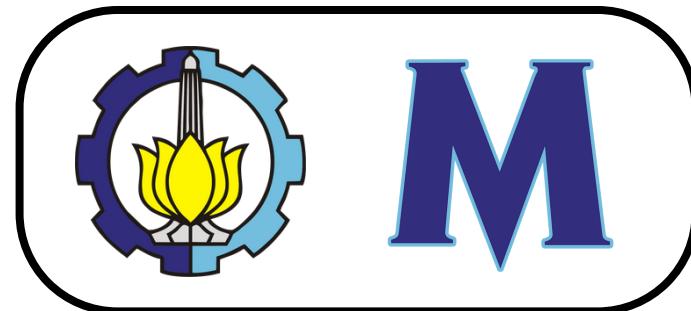


*Solanum tuberosum L.*

- Pada triwulan ketiga 2023, **13,57% PDB** berasal dari **Sektor Pertanian**
- **Kentang** adalah salah satu komoditas hortikultura strategis → Bahan baku industri makanan & produk berbasis pati.
- Permintaan kentang yang terus meningkat secara global menjadikannya mempunyai nilai ekonomi yang tinggi baik di pasar lokal maupun internasional (**Saini et al., 2023**)

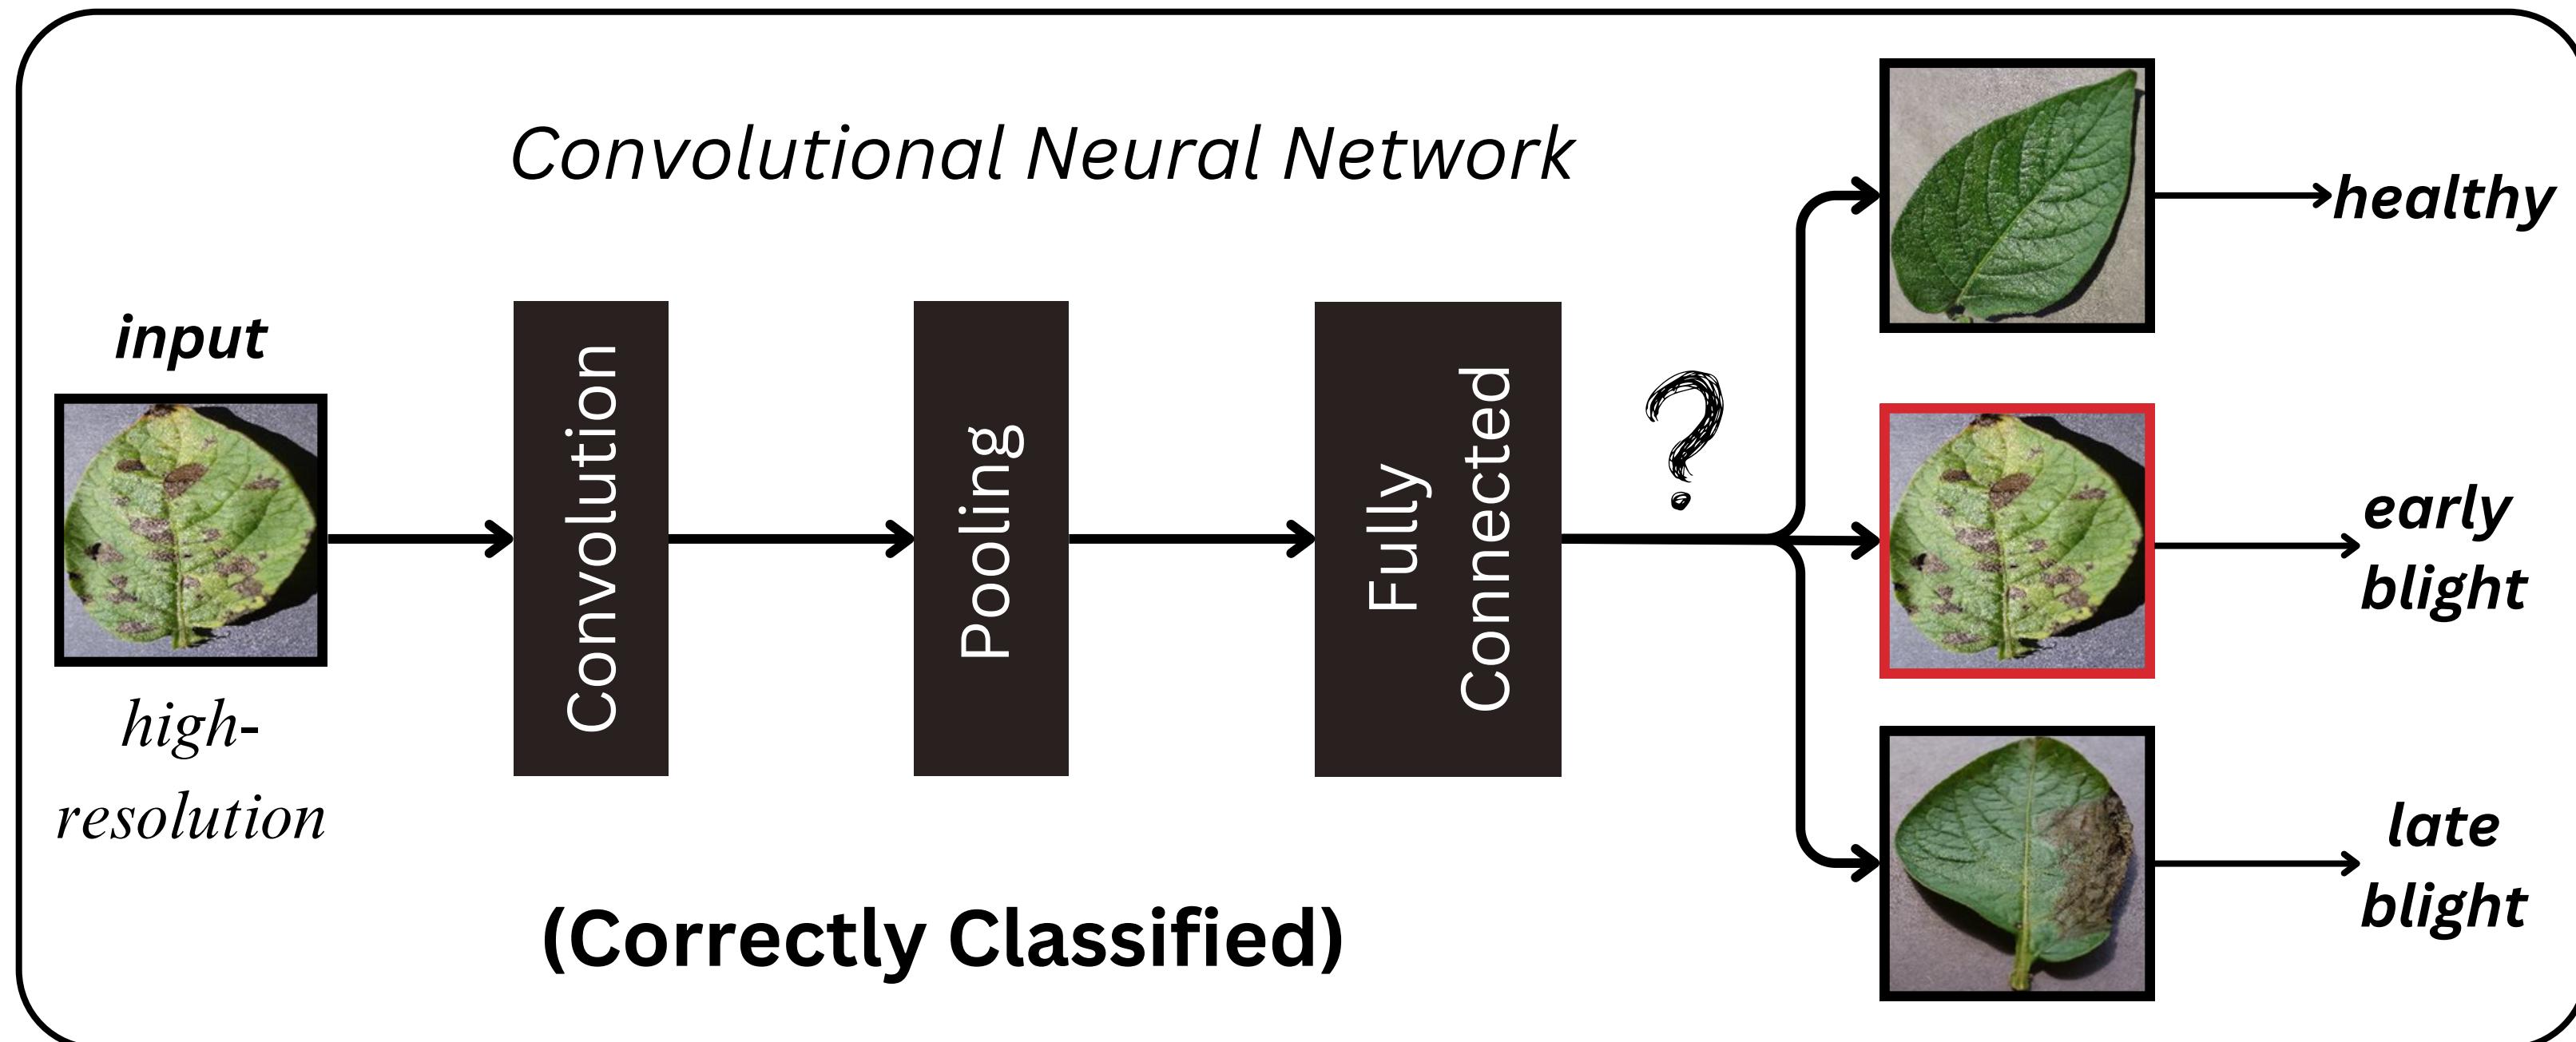
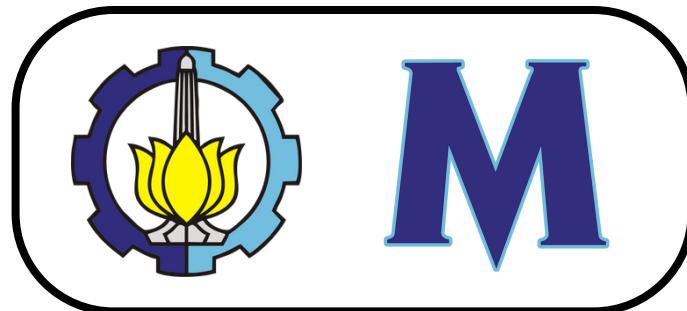


# LATAR BELAKANG

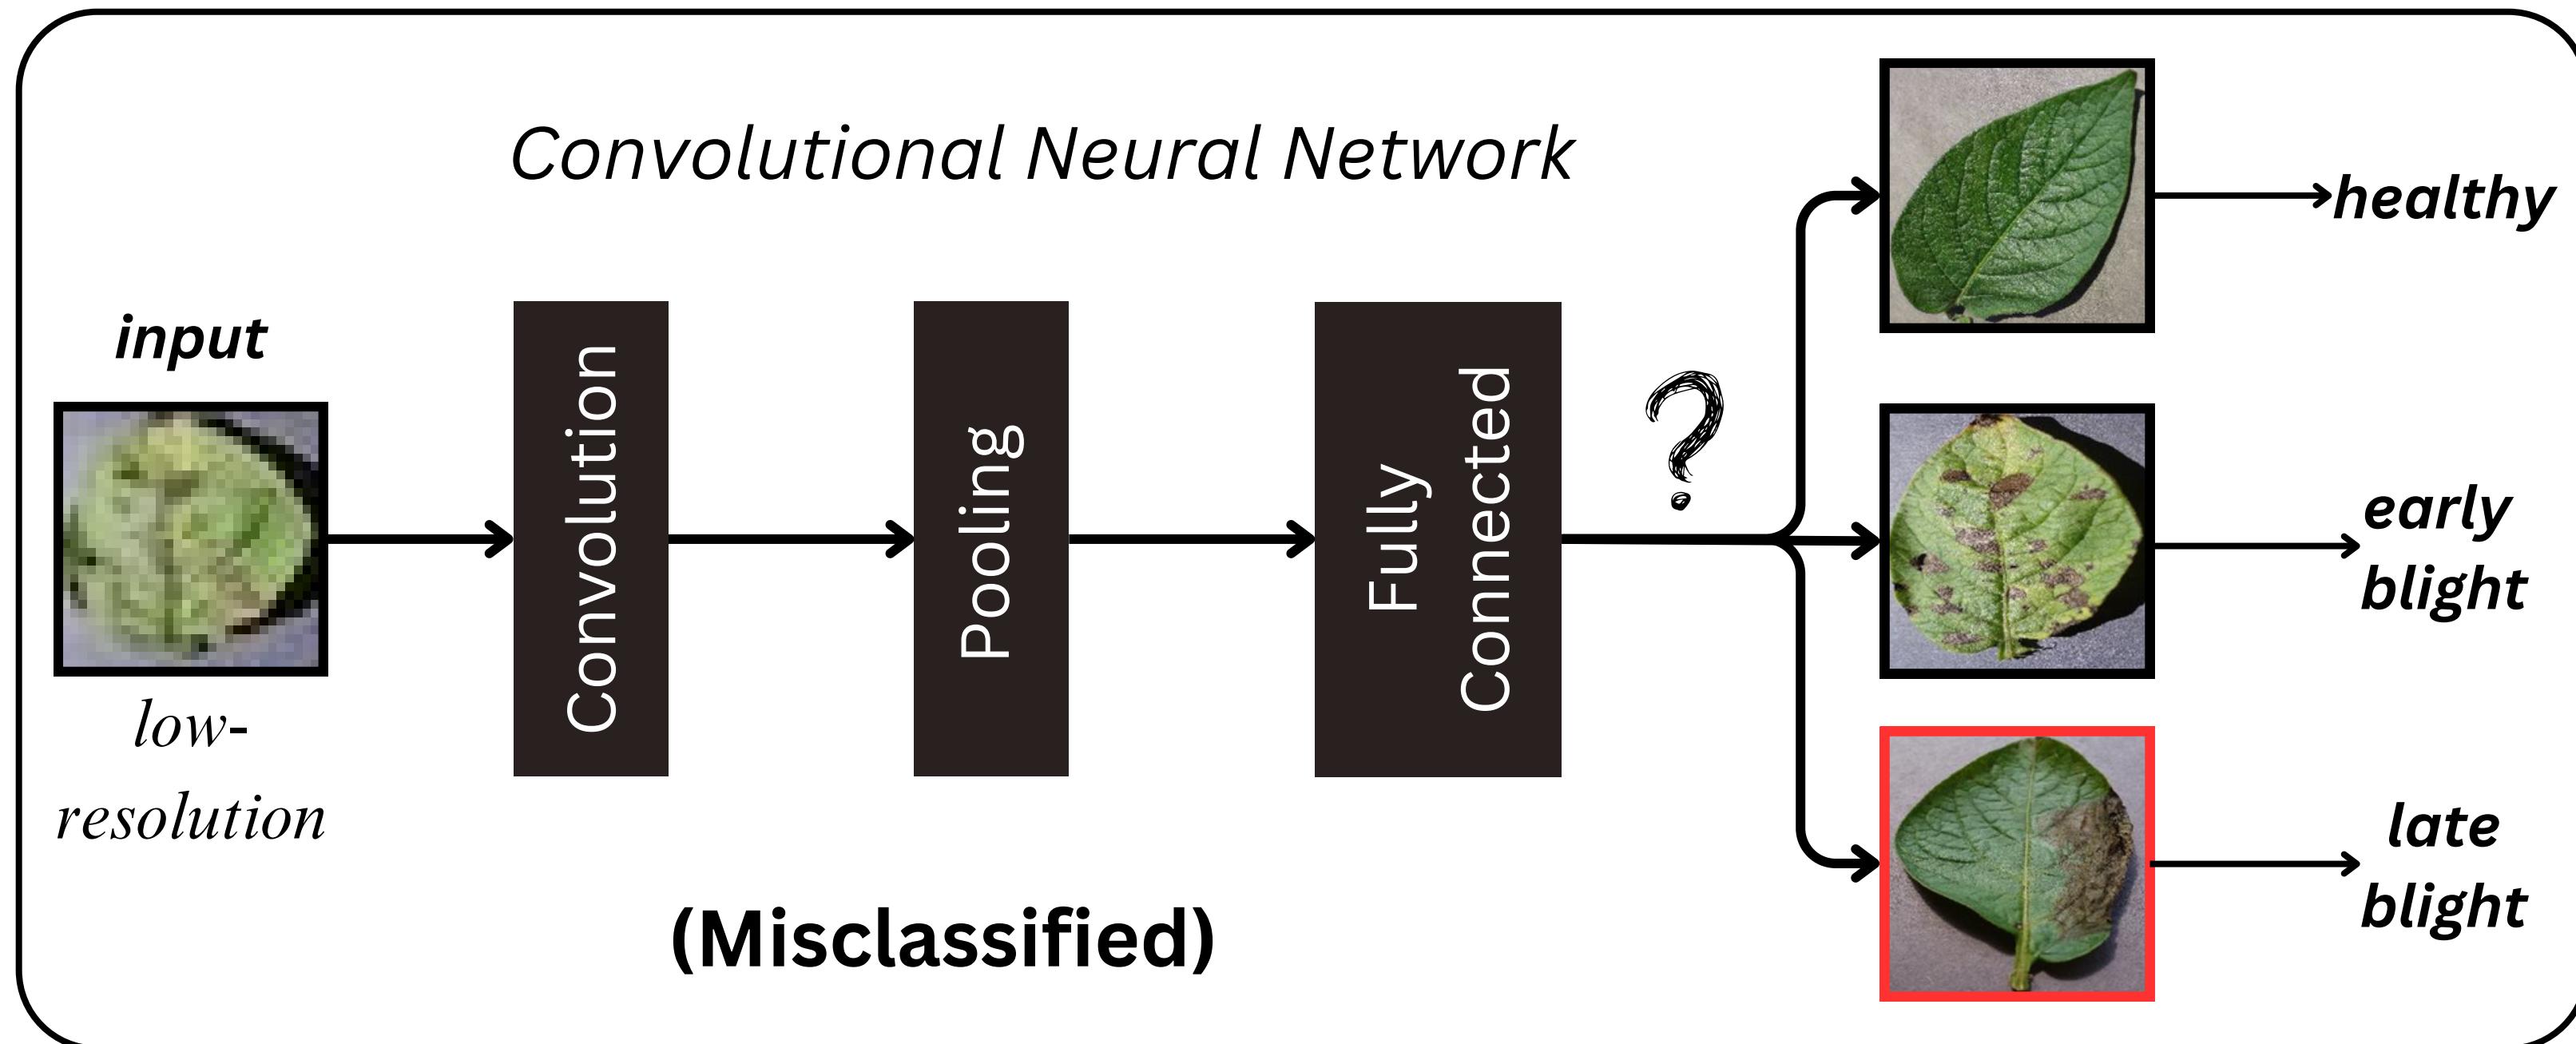
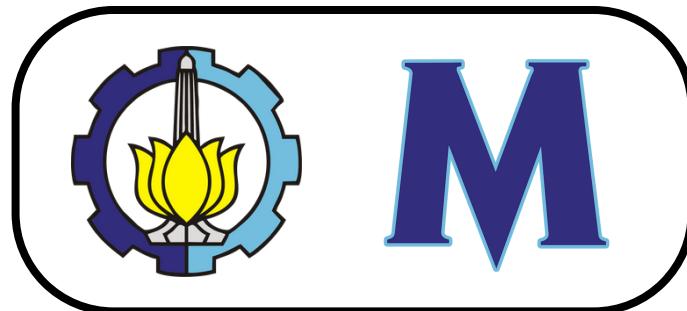


(Sumber: Food and Agriculture Organization of the United Nations (FAO), 2022)

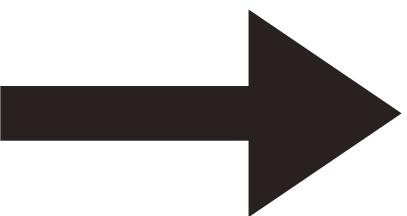
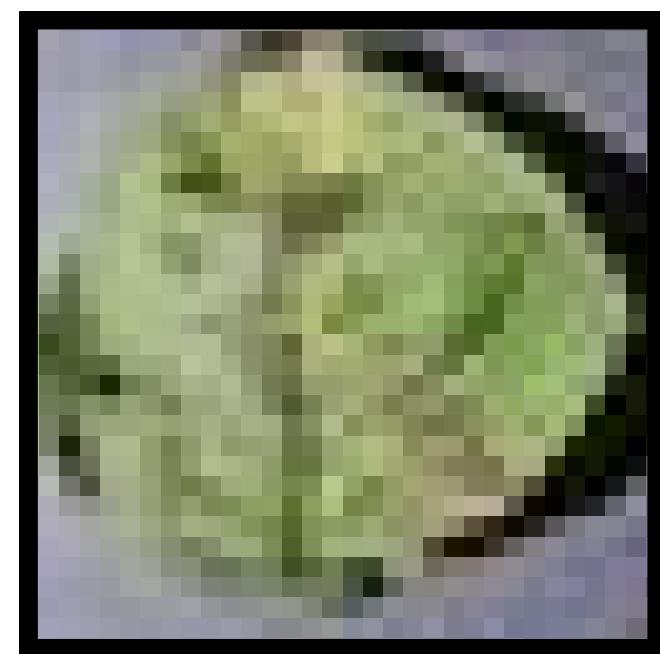
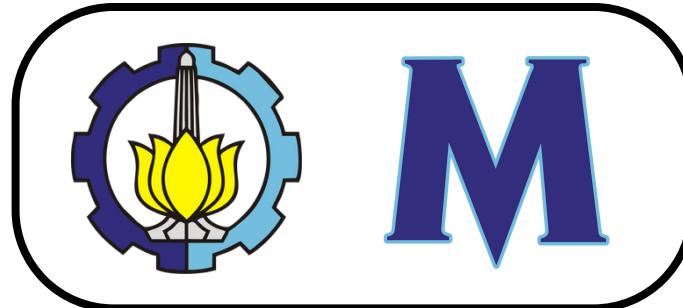
# LATAR BELAKANG



# LATAR BELAKANG



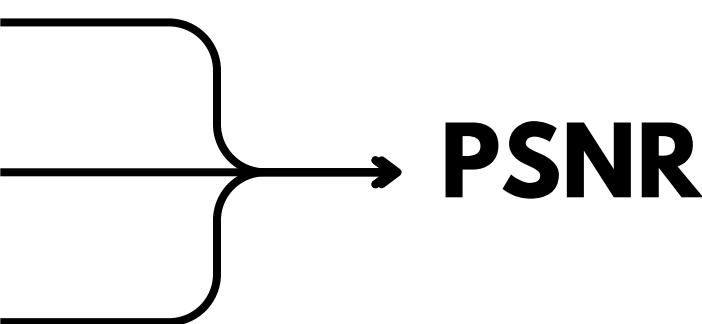
# LATAR BELAKANG



*Single Image  
Super-Resolution*



- SRCNN (Dong et al., 2014)
- DRCN (Kim, Lee & Lee, 2016)
- EDSR (Lim et al., 2017)



SRGAN (Ledig et al., 2017)



ESRGAN (Wang et al., 2018)



# PENELITIAN TERDAHULU

1

## ***ESRGAN: ENHANCED SUPER RESOLUTION GENERATIVE ADVERSARIAL NETWORKS***

Wang et al. (2018) mengevaluasi kembali komponen model SRGAN dan memperbaikinya untuk menghasilkan ESRGAN, suatu model yang lebih unggul dalam menghasilkan citra super resolution berkualitas tinggi.

2

## ***A LIGHTWEIGHT IMAGE SUPER-RESOLUTION NETWORK BASED ON ESRGAN FOR RAPID TOMATO LEAF DISEASE CLASSIFICATION***

Zha et al. (2022) mengembangkan model *lightweight super-resolution* untuk identifikasi penyakit pada daun tomat dengan mengoptimalkan ESRGAN.

3

## ***SUPER RESOLUTION-BASED LEAF DISEASE DETECTION IN POTATO PLANT USING BROAD DEEP RESIDUAL NETWORK (BDRN)***

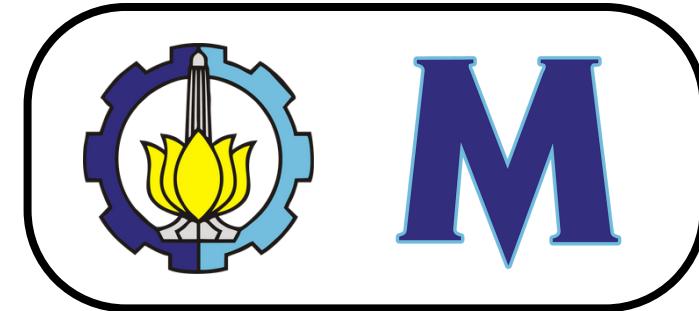
Yeswanth et al. (2023) mengembangkan model BDRN untuk meningkatkan resolusi citra daun kentang berpenyakit untuk mendukung deteksi penyakit yang lebih akurat.

4

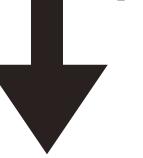
## ***AN INVESTIGATIVE STUDY ON THE USAGE OF VARIOUS GAN MODELS FOR PLANT LEAF DISEASE DETECTION***

Vallabhajosyula et al. (2024) melakukan studi investigatif terkait penggunaan berbagai model berbasis GAN untuk meningkatkan kualitas citra daun tanaman untuk mendukung proses deteksi penyakit tanaman yang lebih akurat.

# LATAR BELAKANG

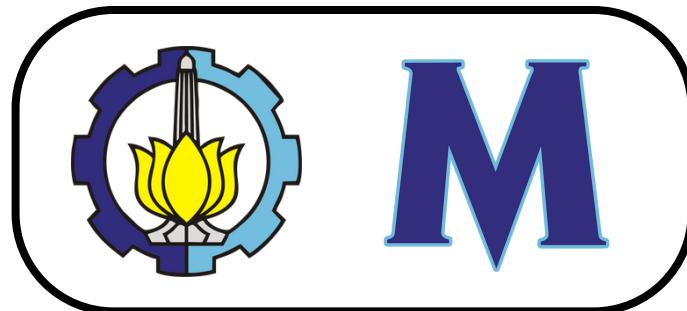


- Penerapan model ESRGAN untuk konteks spesifik penyakit pada daun kentang belum banyak dieksplorasi, terutama terkait dampaknya terhadap klasifikasi berbasis CNN
- Daun kentang memiliki karakteristik visual yang cenderung datar dan pola penyakit yang halus sehingga peningkatan kualitas visual secara perceptual menjadi penting untuk memastikan fitur penting tetap terjaga



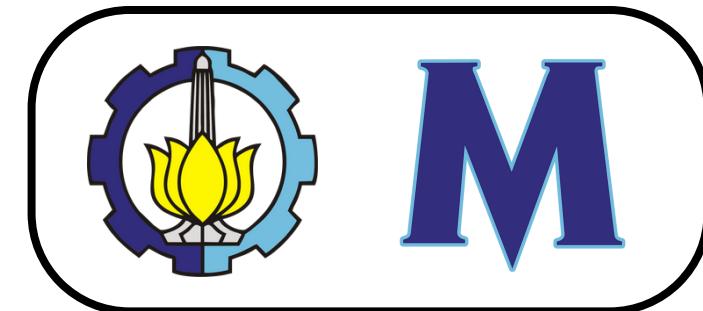
**Implementasi ESRGAN untuk *Super-Resolution* dalam Identifikasi  
Penyakit pada Daun Kentang**

# RUMUSAN MASALAH



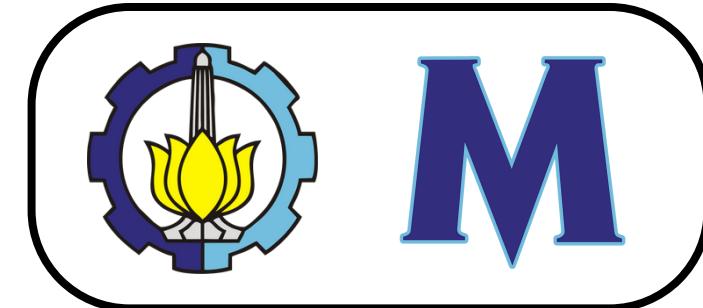
1. Bagaimana penerapan model *Enhanced Super-Resolution Generative Adversarial Networks* (ESRGAN) dalam meningkatkan resolusi citra daun kentang berpenyakit yang beresolusi rendah?
2. Bagaimana kinerja model *Enhanced Super-Resolution Generative Adversarial Networks* (ESRGAN) dalam meningkatkan resolusi citra daun kentang berpenyakit yang beresolusi rendah?
3. Bagaimana kualitas citra yang dihasilkan oleh model *Enhanced Super-Resolution Generative Adversarial Networks* (ESRGAN) dapat meningkatkan akurasi model klasifikasi berbasis *Convolutional Neural Network* (CNN) untuk mengidentifikasi penyakit pada daun kentang?

# BATASAN MASALAH



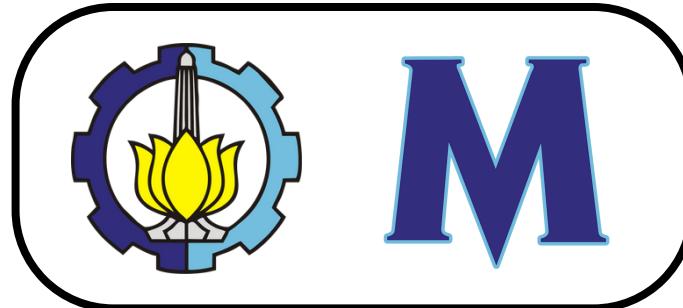
1. Data yang digunakan adalah data sekunder berupa citra daun kentang yang diperoleh dari platform penyedia dataset Kaggle.
2. Teknik *super-resolution* dilakukan pada citra tunggal (*single image super-resolution*).
3. Data masukan pada pelatihan *Enhanced Super-Resolution Generative Adversarial Networks* (ESRGAN) berupa citra daun kentang dalam format RGB dan beresolusi rendah.

# BATASAN MASALAH



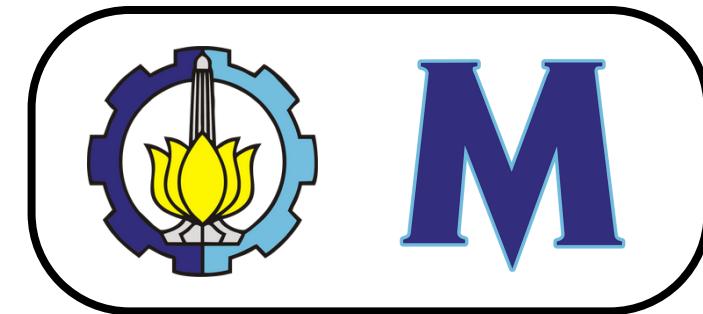
4. Data masukkan pada pelatihan model klasifikasi berbasis *Convolutional Neural Network (CNN)* berupa citra daun kentang dalam format RGB dan beresolusi tinggi.
5. *Dataset* citra daun kentang terdiri dari tiga kategori, yaitu daun sehat, daun dengan penyakit *early blight*, dan daun dengan penyakit *late blight*.

# TUJUAN PENELITIAN



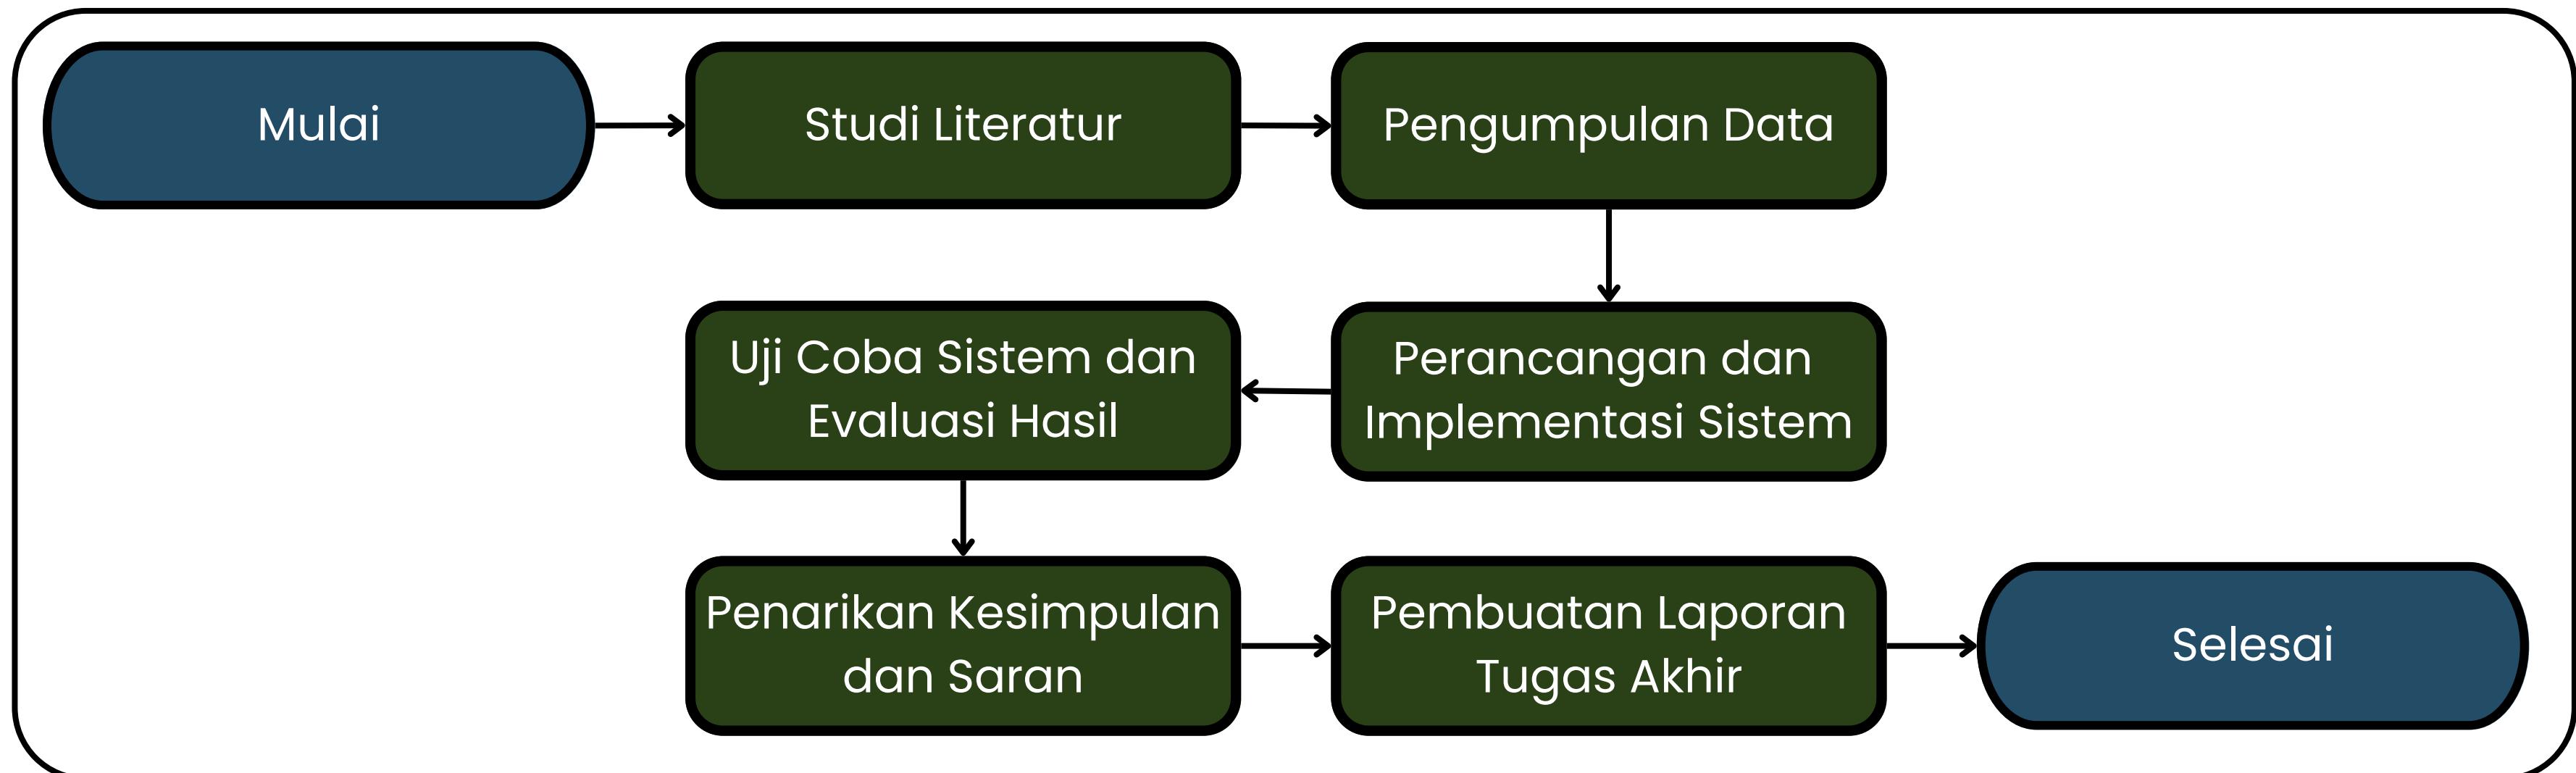
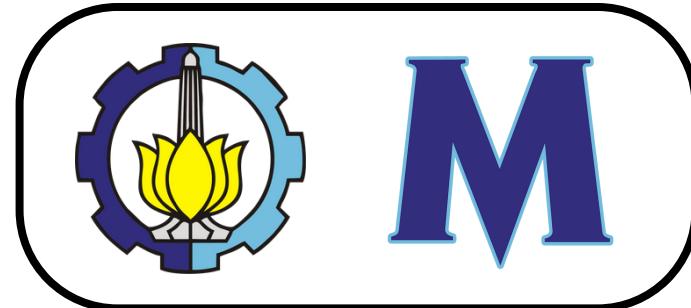
1. Menerapkan model *Enhanced Super-Resolution Generative Adversarial Networks* (ESRGAN) untuk meningkatkan resolusi citra daun kentang berpenyakit yang beresolusi rendah.
2. Mengevaluasi kinerja model *Enhanced Super-Resolution Generative Adversarial Networks* (ESRGAN) dalam meningkatkan resolusi citra daun kentang berpenyakit yang beresolusi rendah.
3. Menganalisis bagaimana kualitas citra hasil model *Enhanced Super-Resolution Generative Adversarial Networks* (ESRGAN) dapat meningkatkan akurasi model klasifikasi berbasis *Convolutional Neural Network* untuk mengidentifikasi penyakit pada daun kentang.

# MANFAAT PENELITIAN



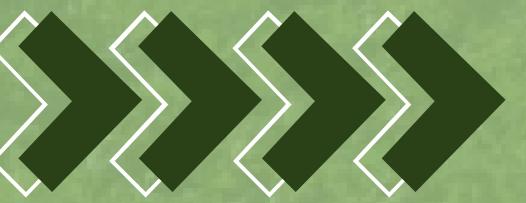
1. Sebagai referensi bagi pemerintah dalam merancang strategi peningkatan produktivitas hasil pertanian di Indonesia, khususnya melalui pemanfaatan teknologi *super-resolution* untuk mendukung deteksi dan pengelolaan penyakit tanaman.
2. Sebagai acuan bagi penelitian berikutnya yang berfokus pada teknologi *super-resolution*, terutama dibidang pertanian.

# DIAGRAM ALIR PENELITIAN

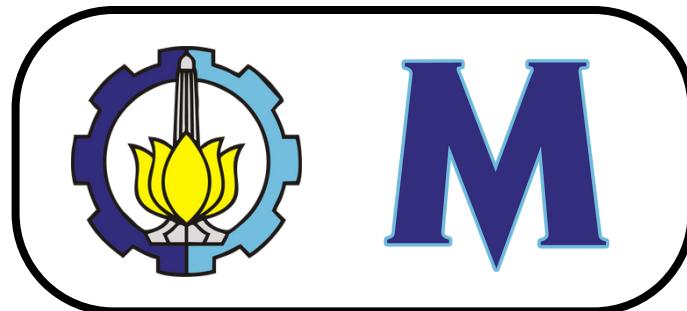




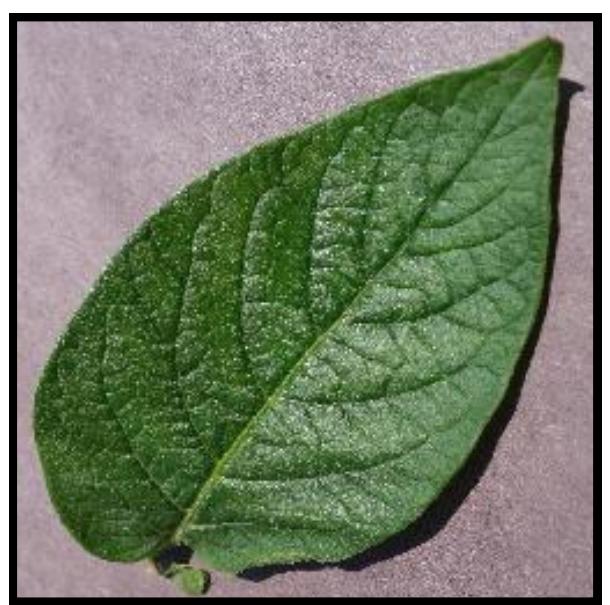
# PERANCANGAN DAN IMPLEMENTASI



# PENGUMPULAN DAN PERSIAPAN DATA



## 1 Informasi Dataset



152 citra  
RGB  
 $256 \times 256$  piksel

**Healthy**



1000 citra  
RGB  
 $256 \times 256$  piksel

**Early Blight**

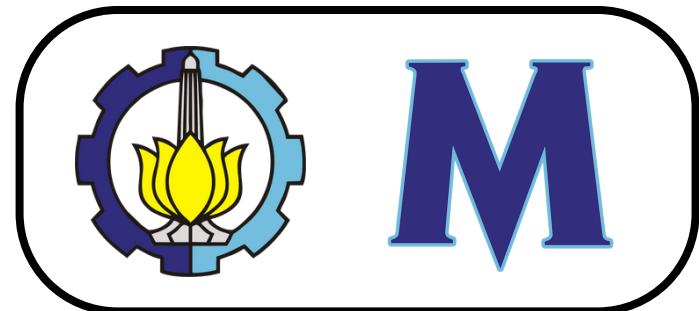


1000 citra  
RGB  
 $256 \times 256$  piksel

**Late Blight**

**Potato Dataset** berasal dari Kaggle yang merupakan modifikasi dari **Plant Village Dataset** yang dibuat oleh Plant Village, Pennsylvania State University. Seluruh data citra berformat *Joint Photographic Experts Group* (JPEG).

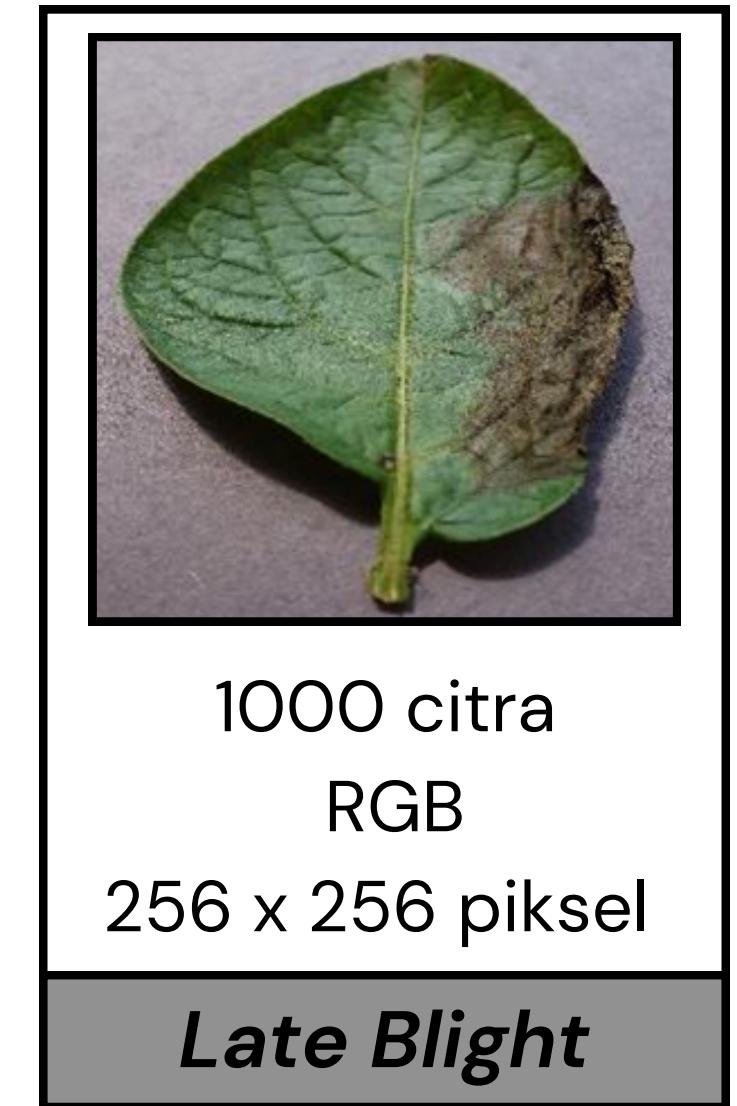
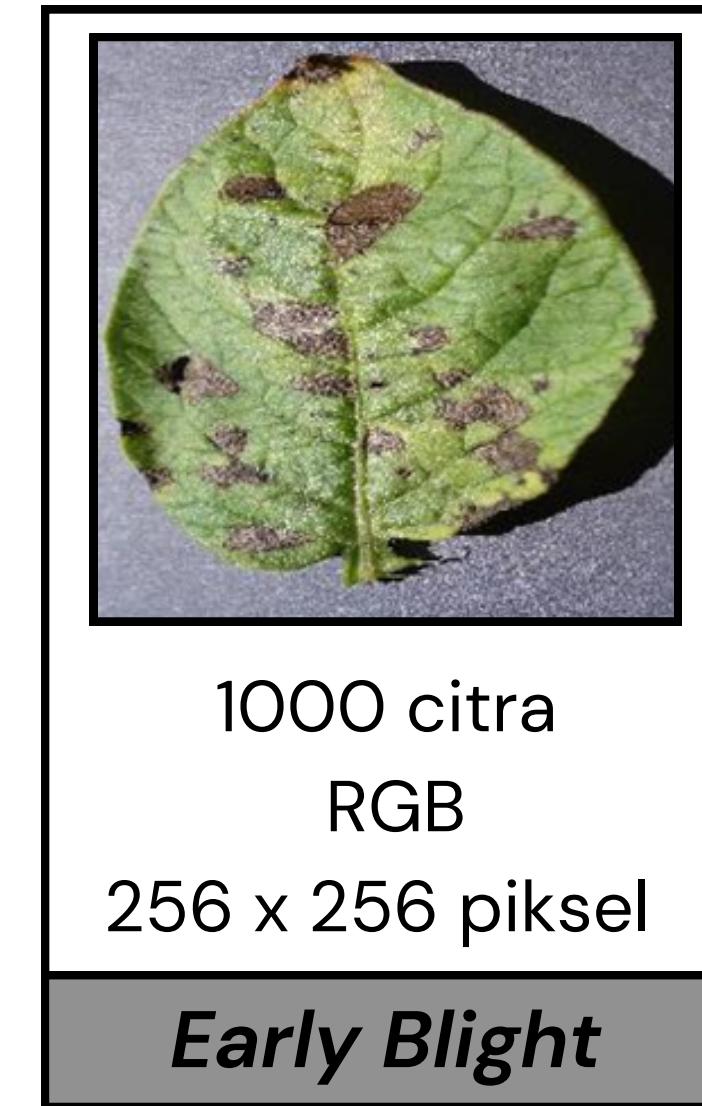
# PENGUMPULAN DAN PERSIAPAN DATA



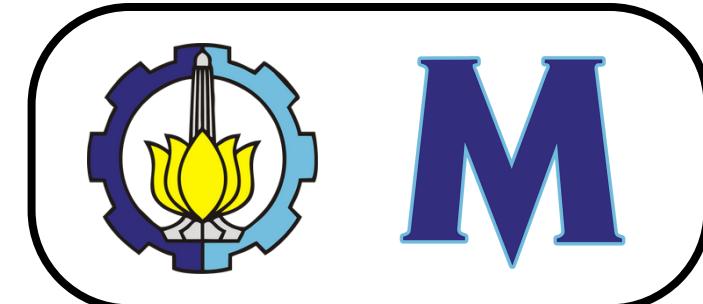
## Augmentasi Kelas *Imbalance*



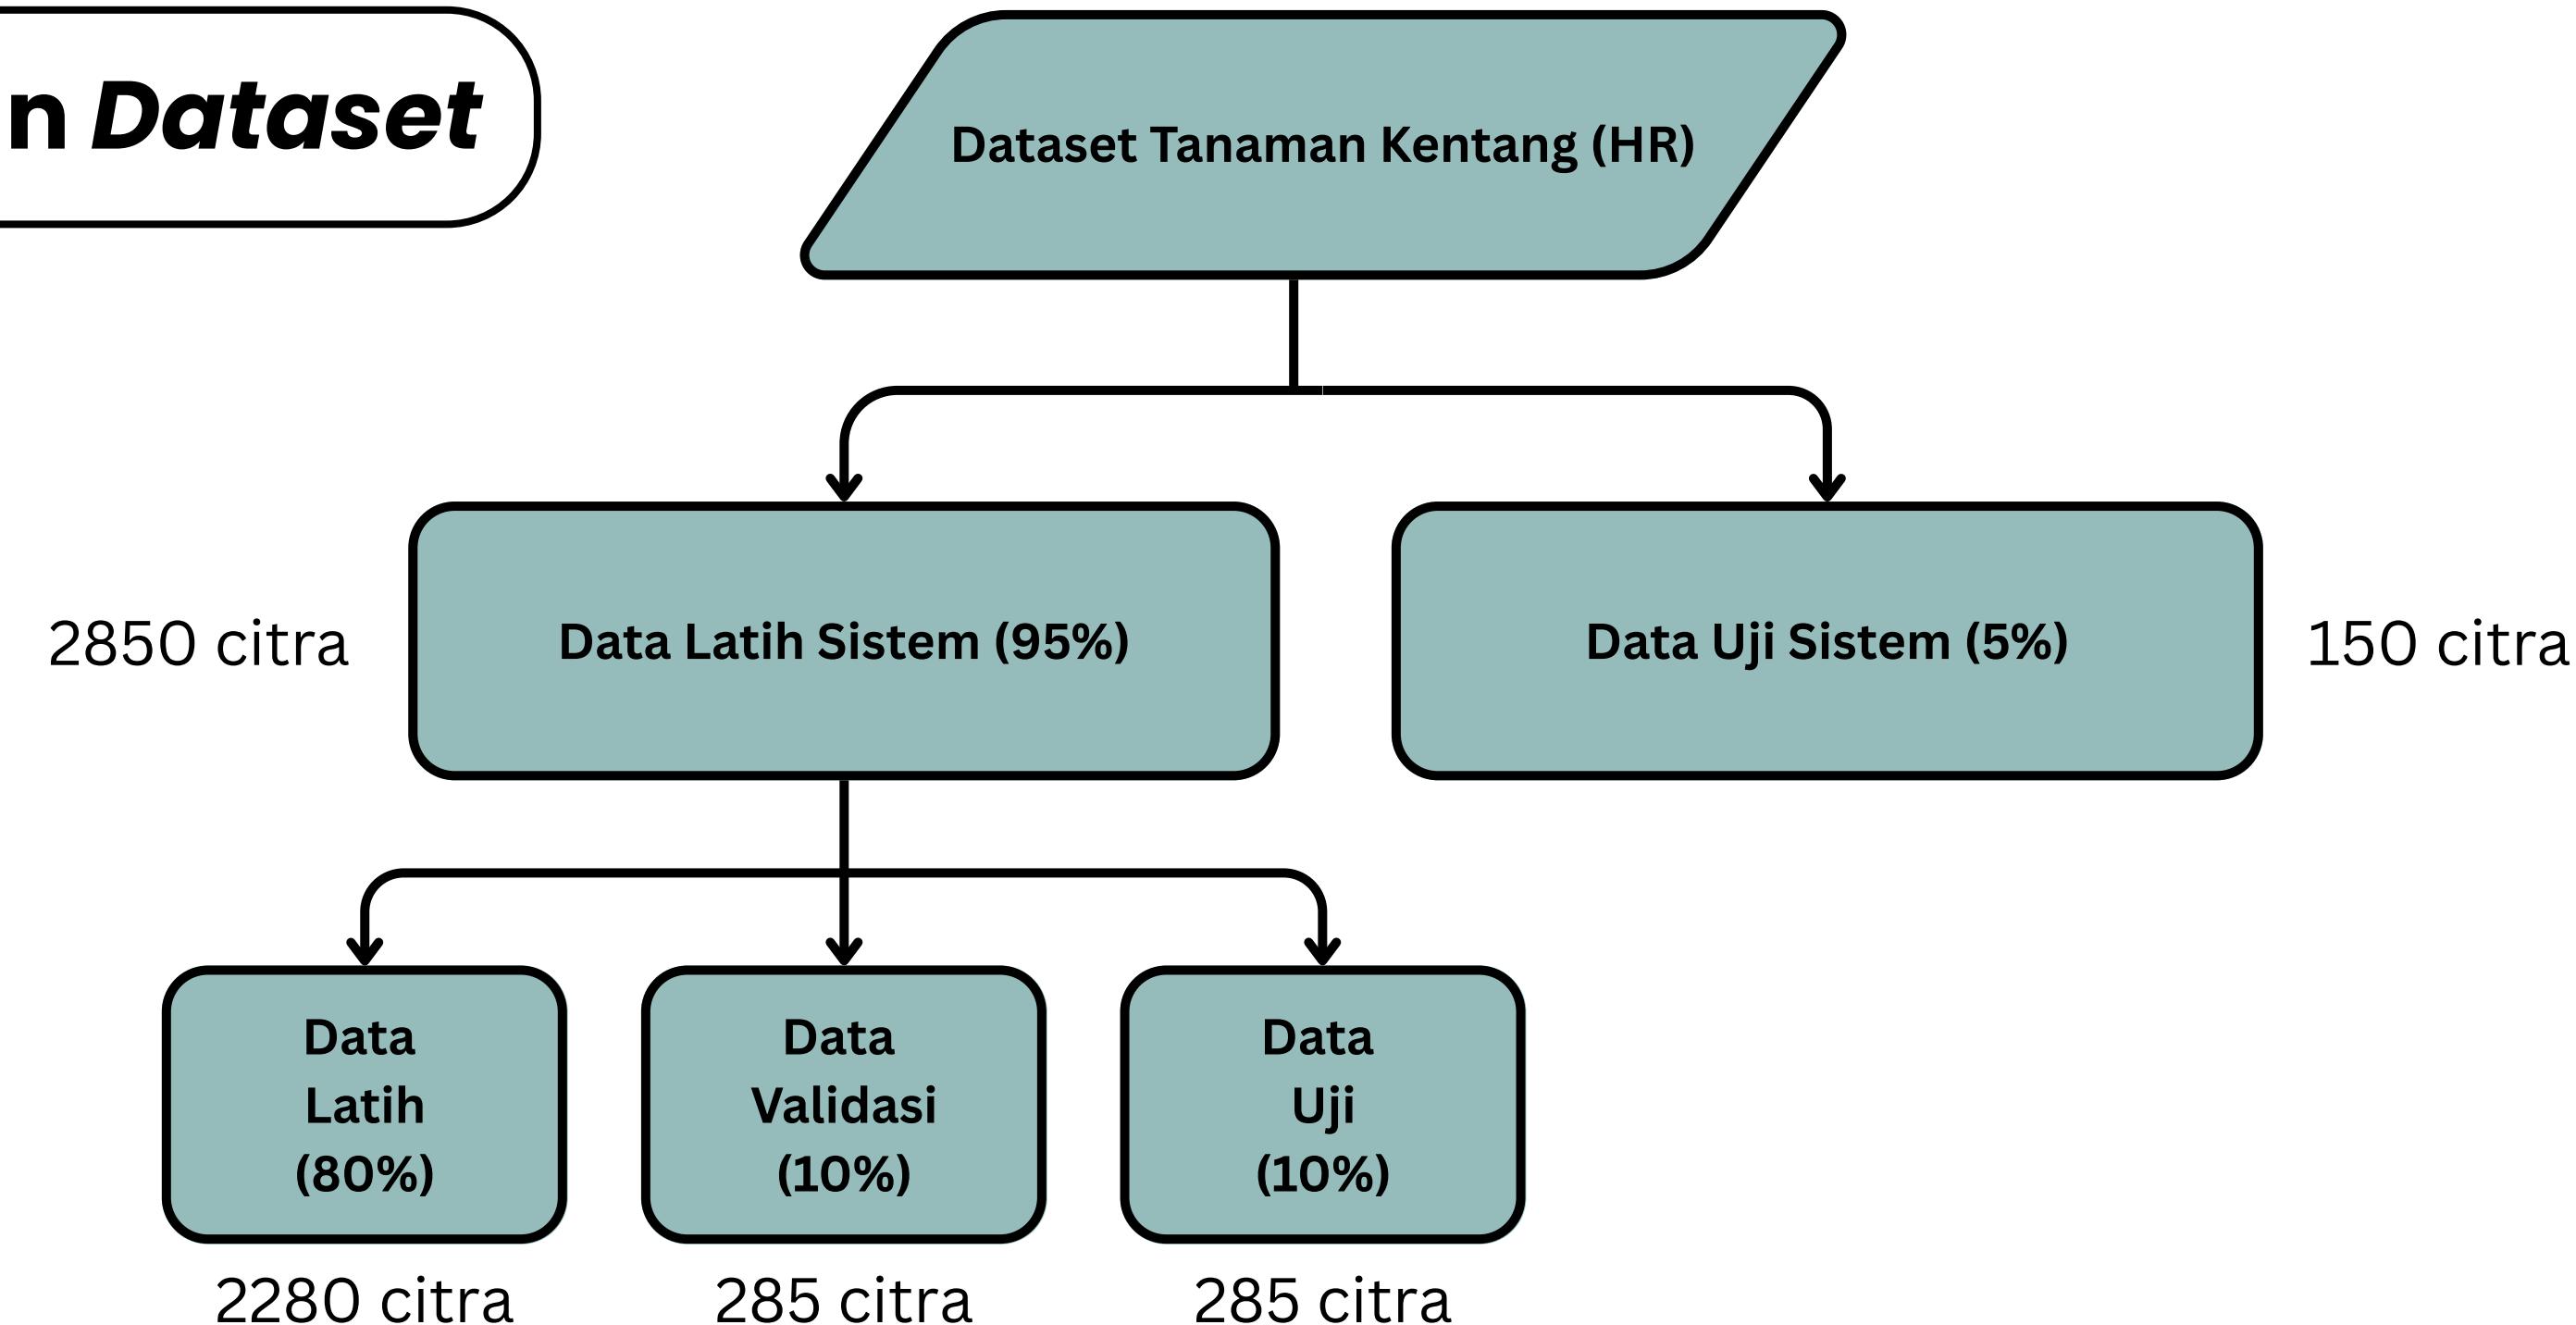
*Random Flip*  
*Random Rotation*



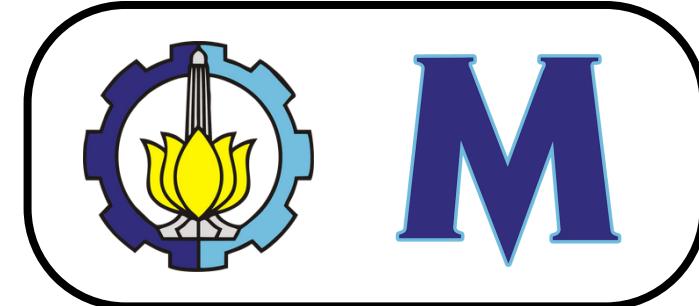
# PENGUMPULAN DAN PERSIAPAN DATA



## 2 Pembagian Dataset



# PENGUMPULAN DAN PERSIAPAN DATA



## 3 Augmentasi Data Pelatihan

Data Latih  
ESRGAN



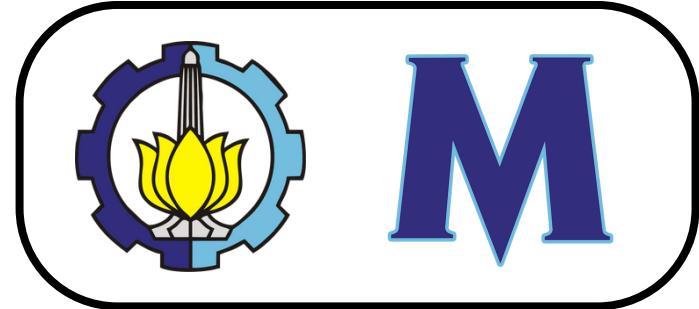
Augmentasi *Offline*

Data Latih  
EfficientNetV2



Augmentasi *On-the-Fly*

# PENGUMPULAN DAN PERSIAPAN DATA



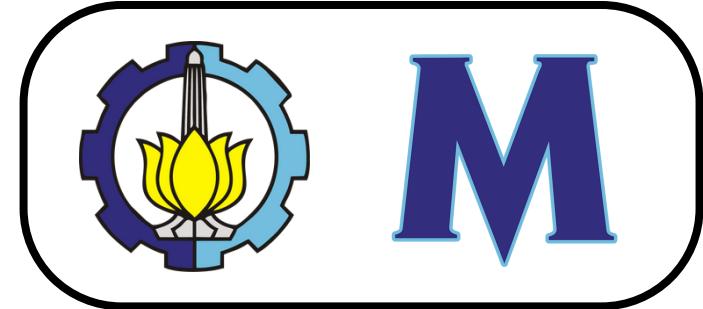
***Horizontal Flipping***



***Vertical Flipping***



# PENGUMPULAN DAN PERSIAPAN DATA



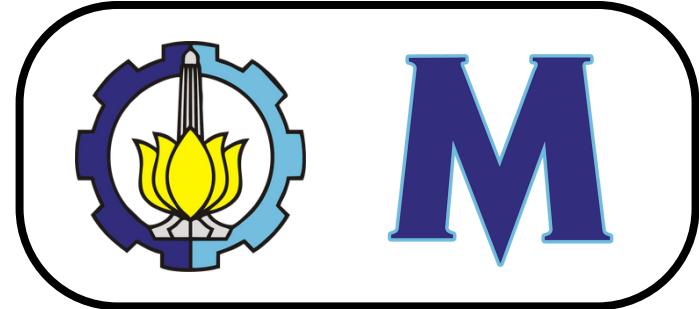
***Rotation***



***Translation***



# PENGUMPULAN DAN PERSIAPAN DATA



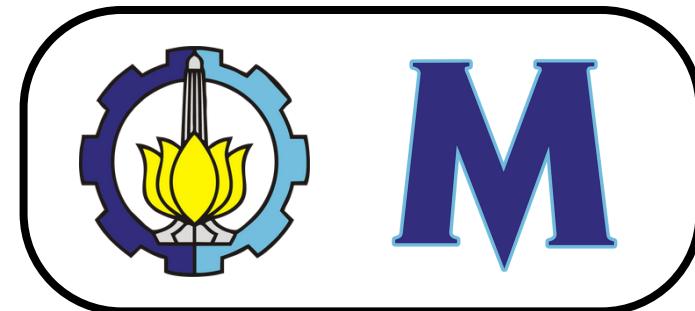
***Contrast***



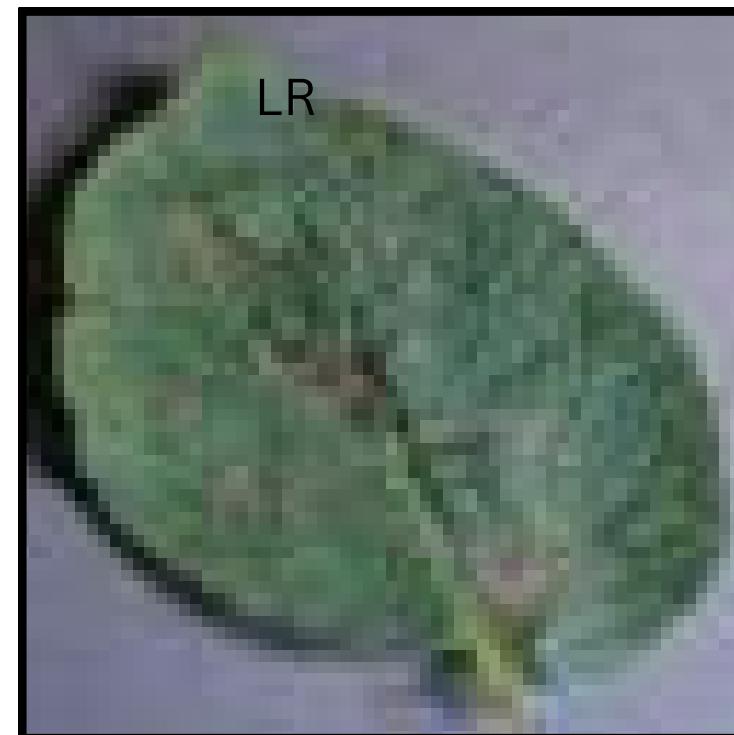
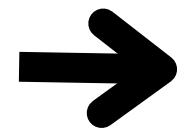
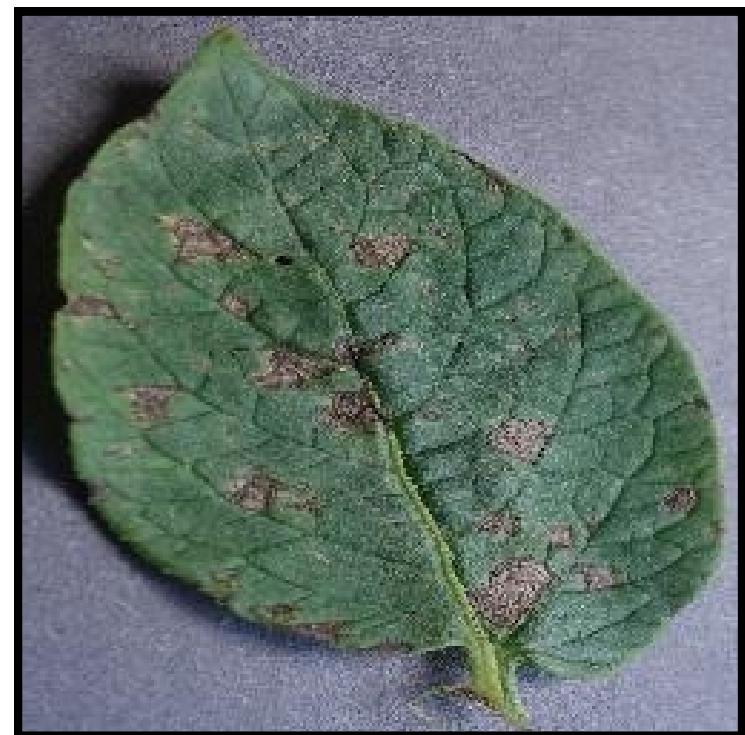
***Crop***



# PENGUMPULAN DAN PERSIAPAN DATA



## 4 Pembangkitan Citra LR

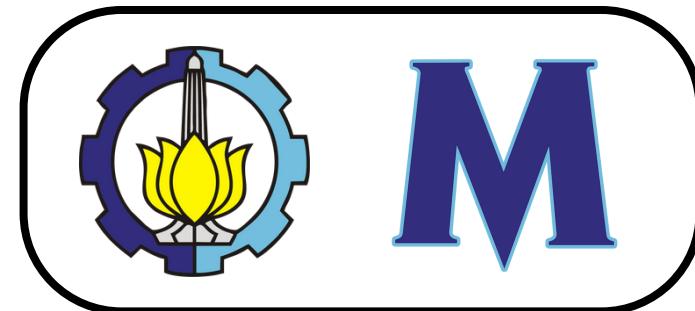


**HR**

**LR**

Pasangan data LR-HR diperlukan untuk pelatihan model ESRGAN. Data LR di *generate* melalui proses *downsampling* dengan metode interpolasi *bicubic*.

# PENGUMPULAN DAN PERSIAPAN DATA



5

## *Data Pre-processing*

- ***Resize***

Tujuan dilakukan *resize* pada tahap awal adalah menyesuaikan ukuran minimum dimensi *input* pada model *pre-trained*. Contoh *resize*:

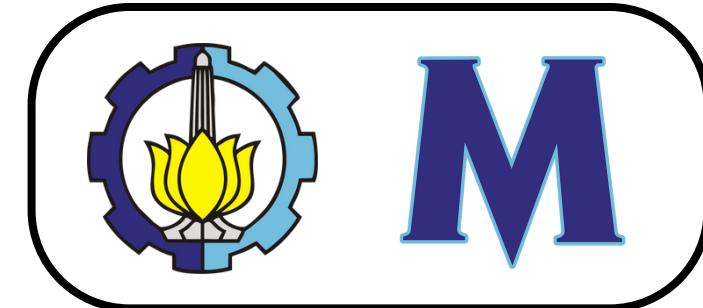
*ukuran sebelum  
256 x 256 px*



*ukuran sesudah  
300 x 300 px*



# PENGUMPULAN DAN PERSIAPAN DATA

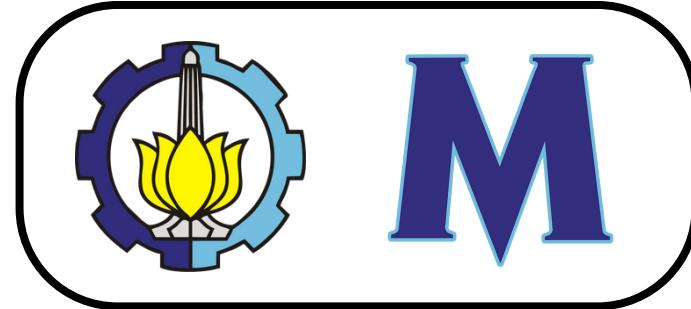


## • Normalisasi

Tujuan dilakukan normalisasi adalah agar nilai piksel menjadi seimbang (mean  $\sim 0$ ), mempercepat konvergensi model dan menjaga stabilitas *training*.

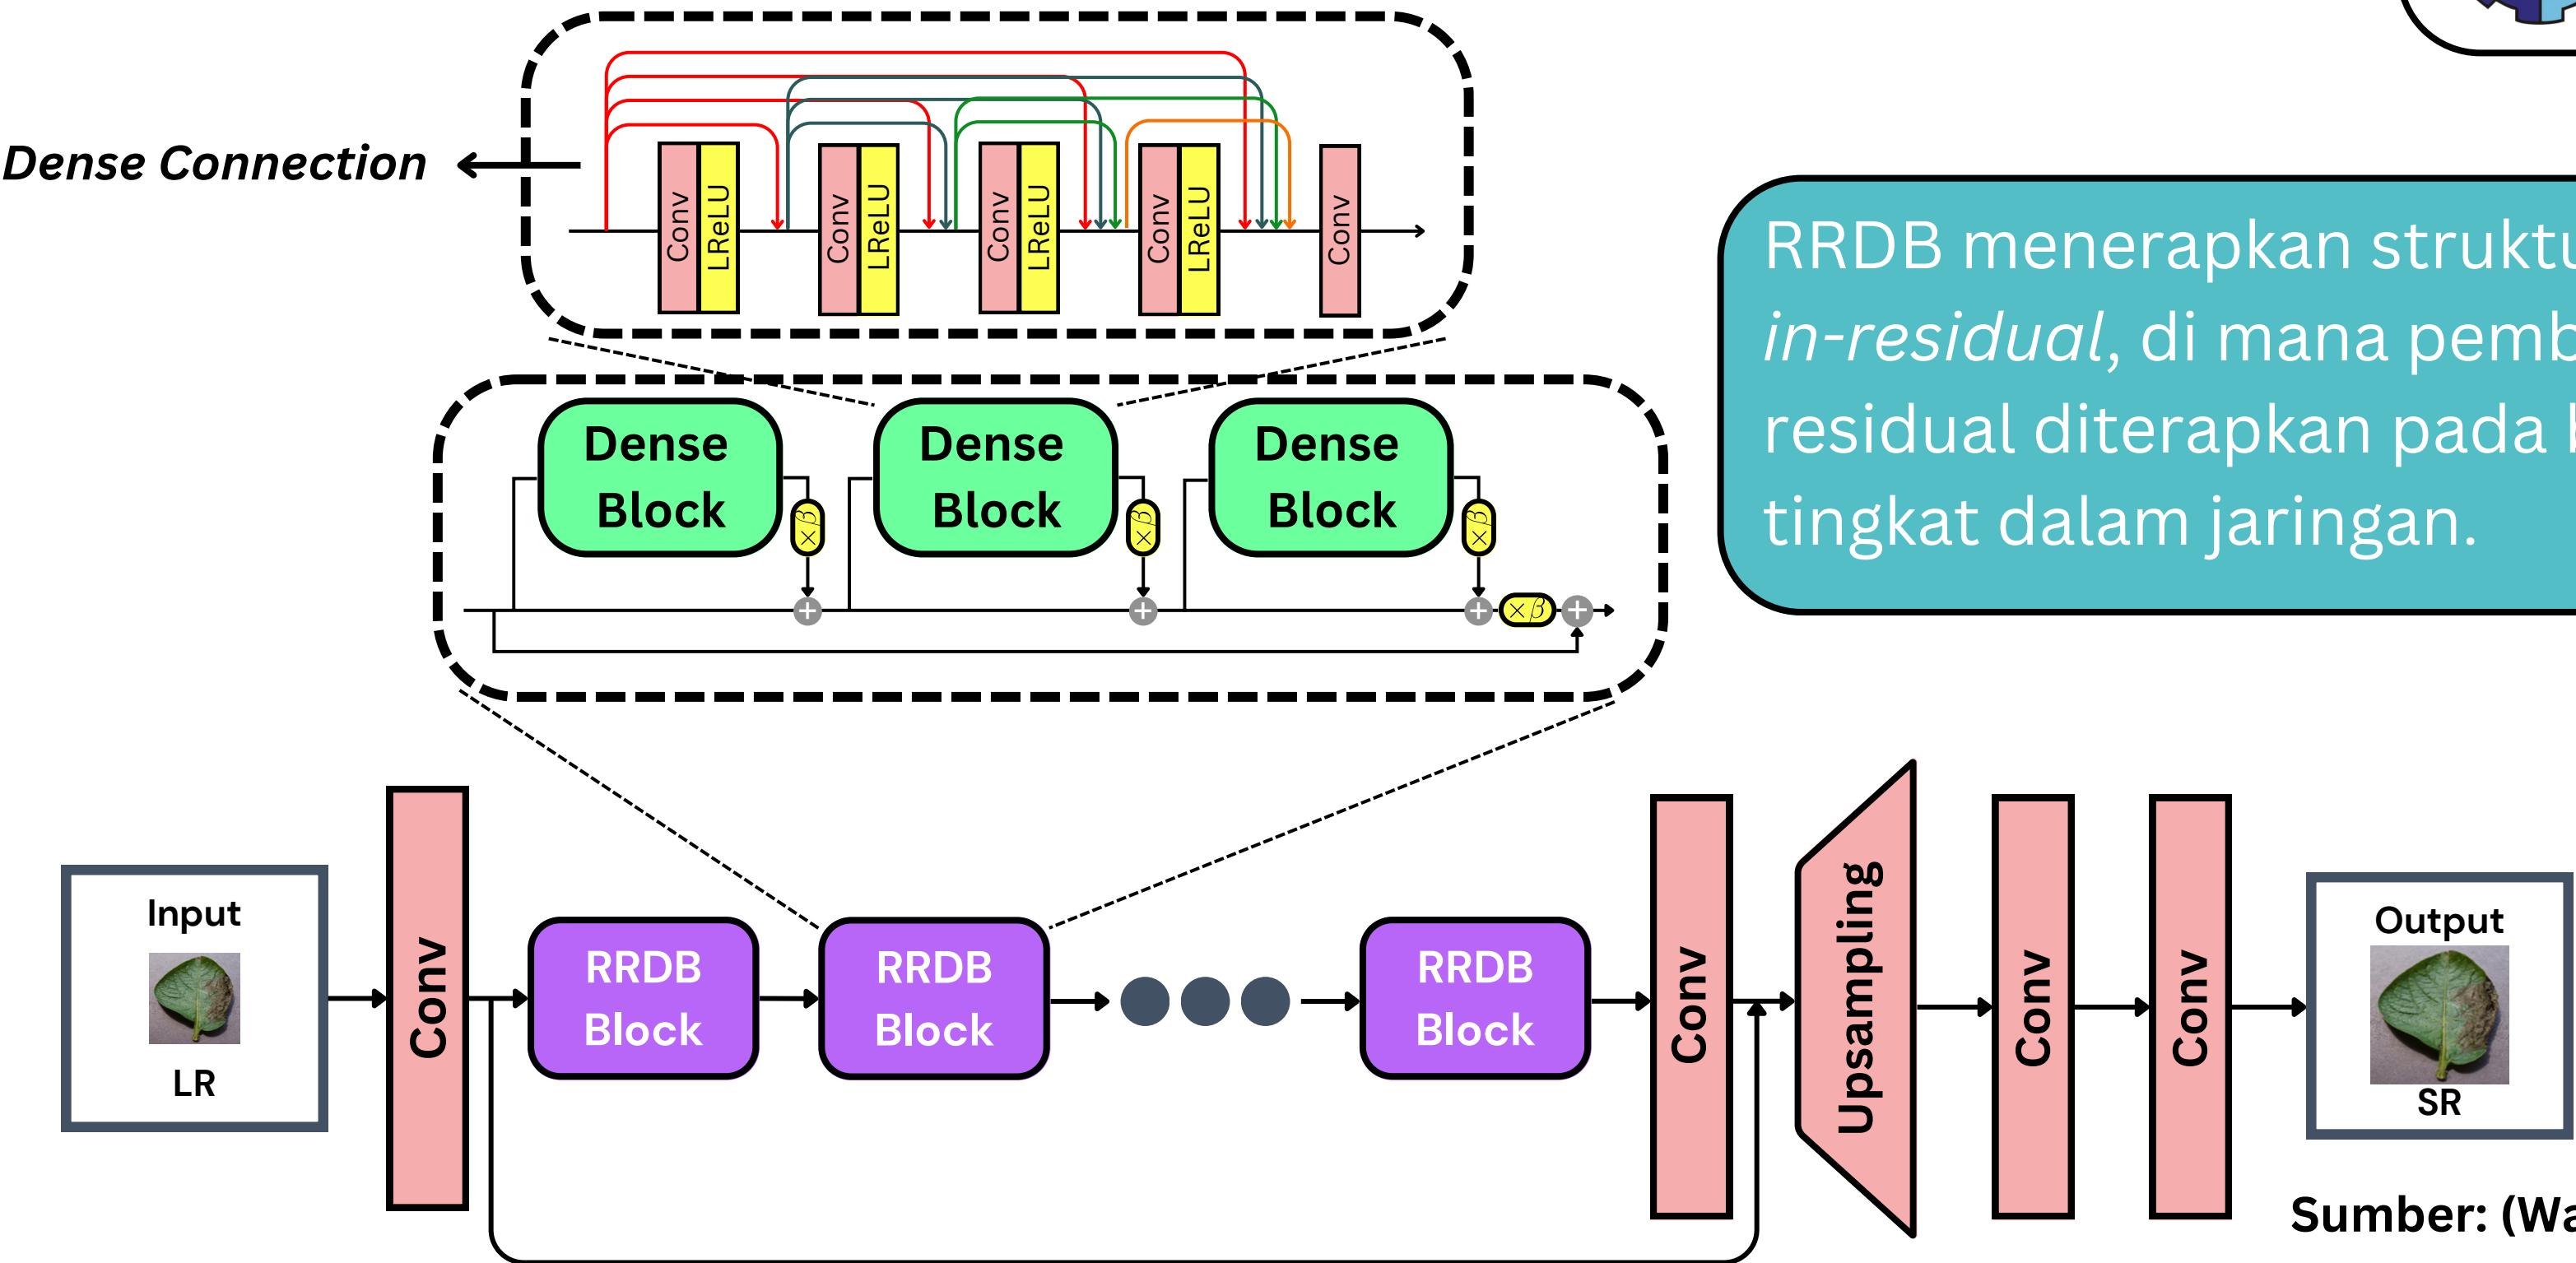
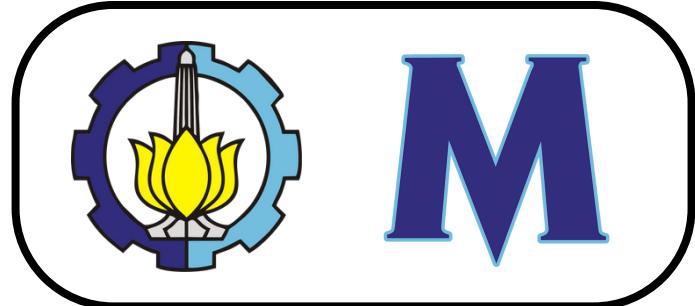
Skala Asli	Warna Piksel	Setelah Normalisasi ke [-1, 1]
0	Hitam	-1
128	Abu-Abu	0
255	Putih	1

# ***ENHANCED SUPER-RESOLUTION GENERATIVE ADVERSARIAL NETWORKS (ESRGAN)***



Model ini terdiri dari dua jaringan utama, yaitu *generator* dan *discriminator*, yang bekerja saling berlawanan untuk mencapai objektif yang ditentukan. Dalam konteks *super-resolution*, *generator* dirancang untuk menghasilkan citra beresolusi tinggi (HR) dari citra beresolusi rendah (LR), sementara *discriminator* bertugas menilai apakah citra yang dihasilkan oleh *generator* sudah menyerupai citra asli atau tidak.

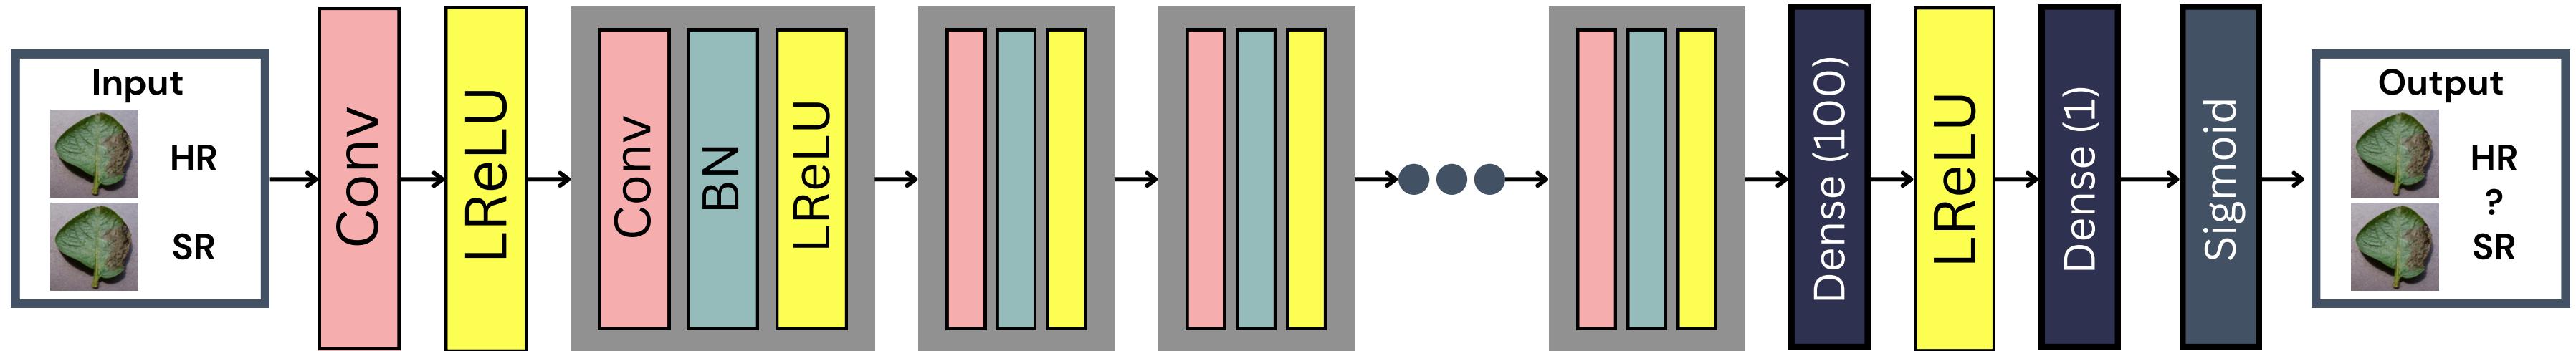
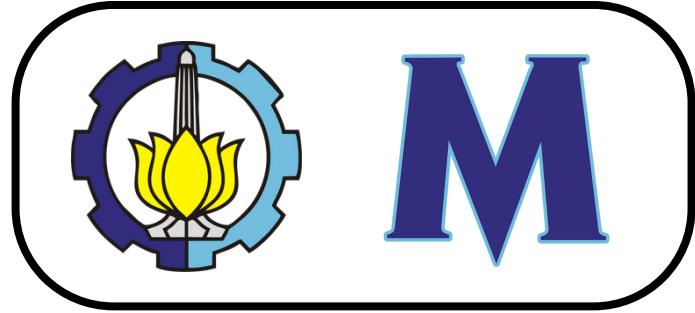
# ARSITEKTUR GENERATOR RRDBNet



Sumber: (Wang et al., 2018)

# ARSITEKTUR ***DISCRIMINATOR***

## VGGStyleDiscriminator



Sumber: Yamashita & Markov, 2020

*Relativistic average Discriminator*

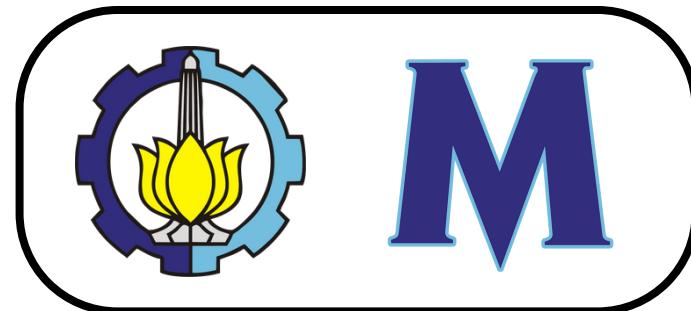
$$D_{Ra}(x_r, x_f) = \sigma(C(x_r) - \mathbb{E}_{x_f}[C(x_f)])$$

$$D_{Ra}(x_f, x_r) = \sigma(C(x_f) - \mathbb{E}_{x_r}[C(x_r)])$$

$$L_D^{Ra} = -\mathbb{E}_{x_r} [\log(D_{Ra}(x_r, x_f))] - \mathbb{E}_{x_f} [\log(1 - D_{Ra}(x_f, x_r))]$$

$$L_G^{Ra} = -\mathbb{E}_{x_r} [\log(1 - D_{Ra}(x_r, x_f))] - \mathbb{E}_{x_f} [\log(D_{Ra}(x_f, x_r))]$$

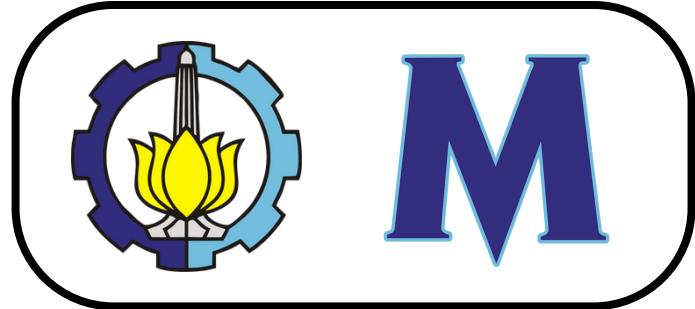
# **PERCEPTUAL LOSS**



*Perceptual loss* dalam ESRGAN meminimumkan jarak dua fitur **sebelum** fungsi aktivasi alih-alih **setelah** aktivasi yang diterapkan pada SRGAN untuk meningkatkan akurasi dan kualitas citra SR. Dengan demikian *total loss* untuk generator G diformulasikan seperti pada persamaan berikut:

$$L_G = L_{percep} + \lambda L_G^{Ra} + \eta L_1$$

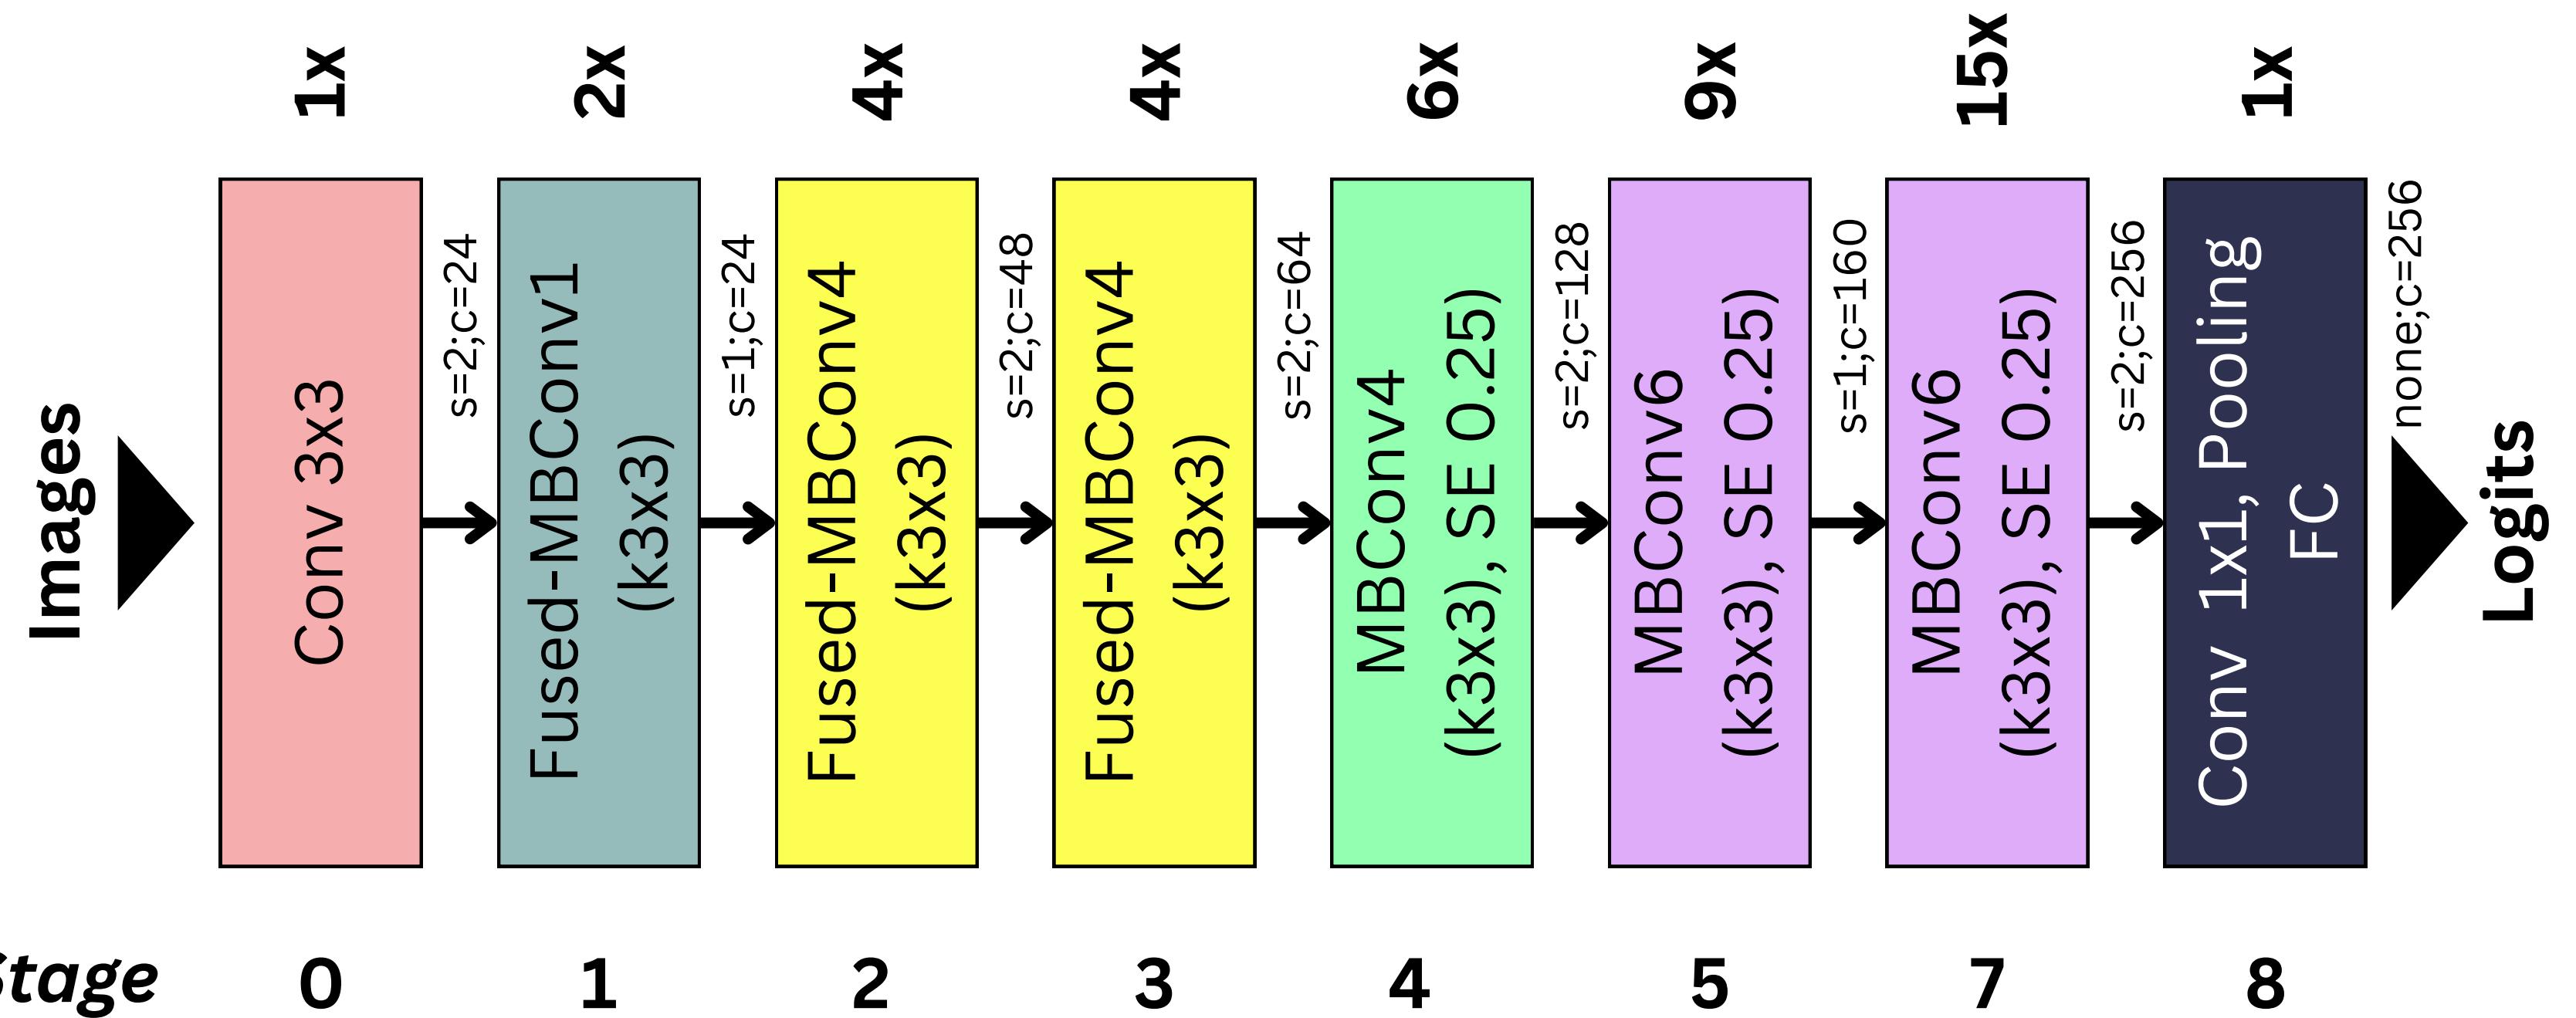
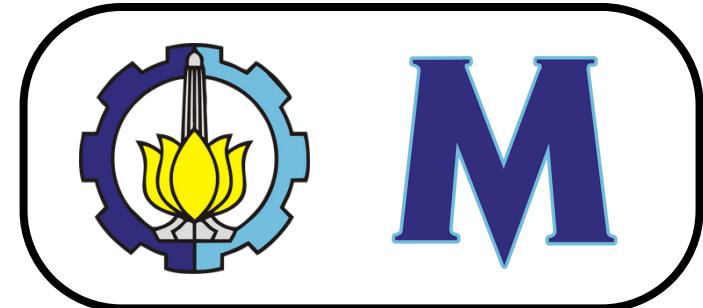
dimana  $L1 = \mathbb{E}_{xi} \|G(xi) - y\|_1$  adalah *content loss* yang mengevaluasi jarak 1-norm antara citra hasil rekonstruksi  $G(xi)$  dan citra *ground-truth*  $y$ , dan  $\lambda, \eta$  adalah koefisien untuk menyeimbangkan *loss*.



## ***EFFICIENTNETV2***

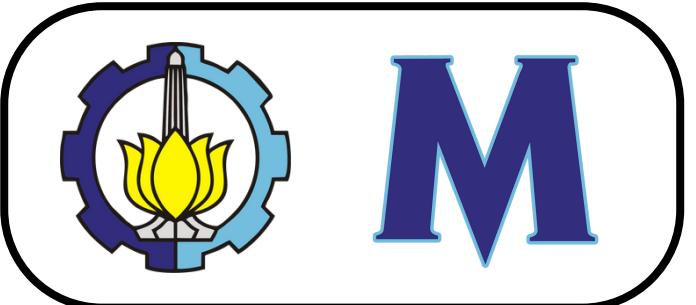
*EfficientNetV2* merupakan arsitektur *Convolutional Neural Network* (CNN) yang dikembangkan untuk meningkatkan akurasi sekaligus efisiensi komputasi. Berbeda dengan *EfficientNetV1* yang hanya menggunakan MBConv, *EfficientNetV2* juga memperkenalkan *Fused-MBConv* pada tahap awal jaringan dan strategi pelatihan yang lebih cepat untuk mempercepat konvergensi serta meningkatkan performa pada berbagai skala dataset (Tan & Le, 2021). Terdapat beberapa varian dari *EfficientNetV2*, yaitu S, M, dan L. Pada penelitian ini digunakan varian S.

# ARSITEKTUR *EFFICIENTNETV2-S*

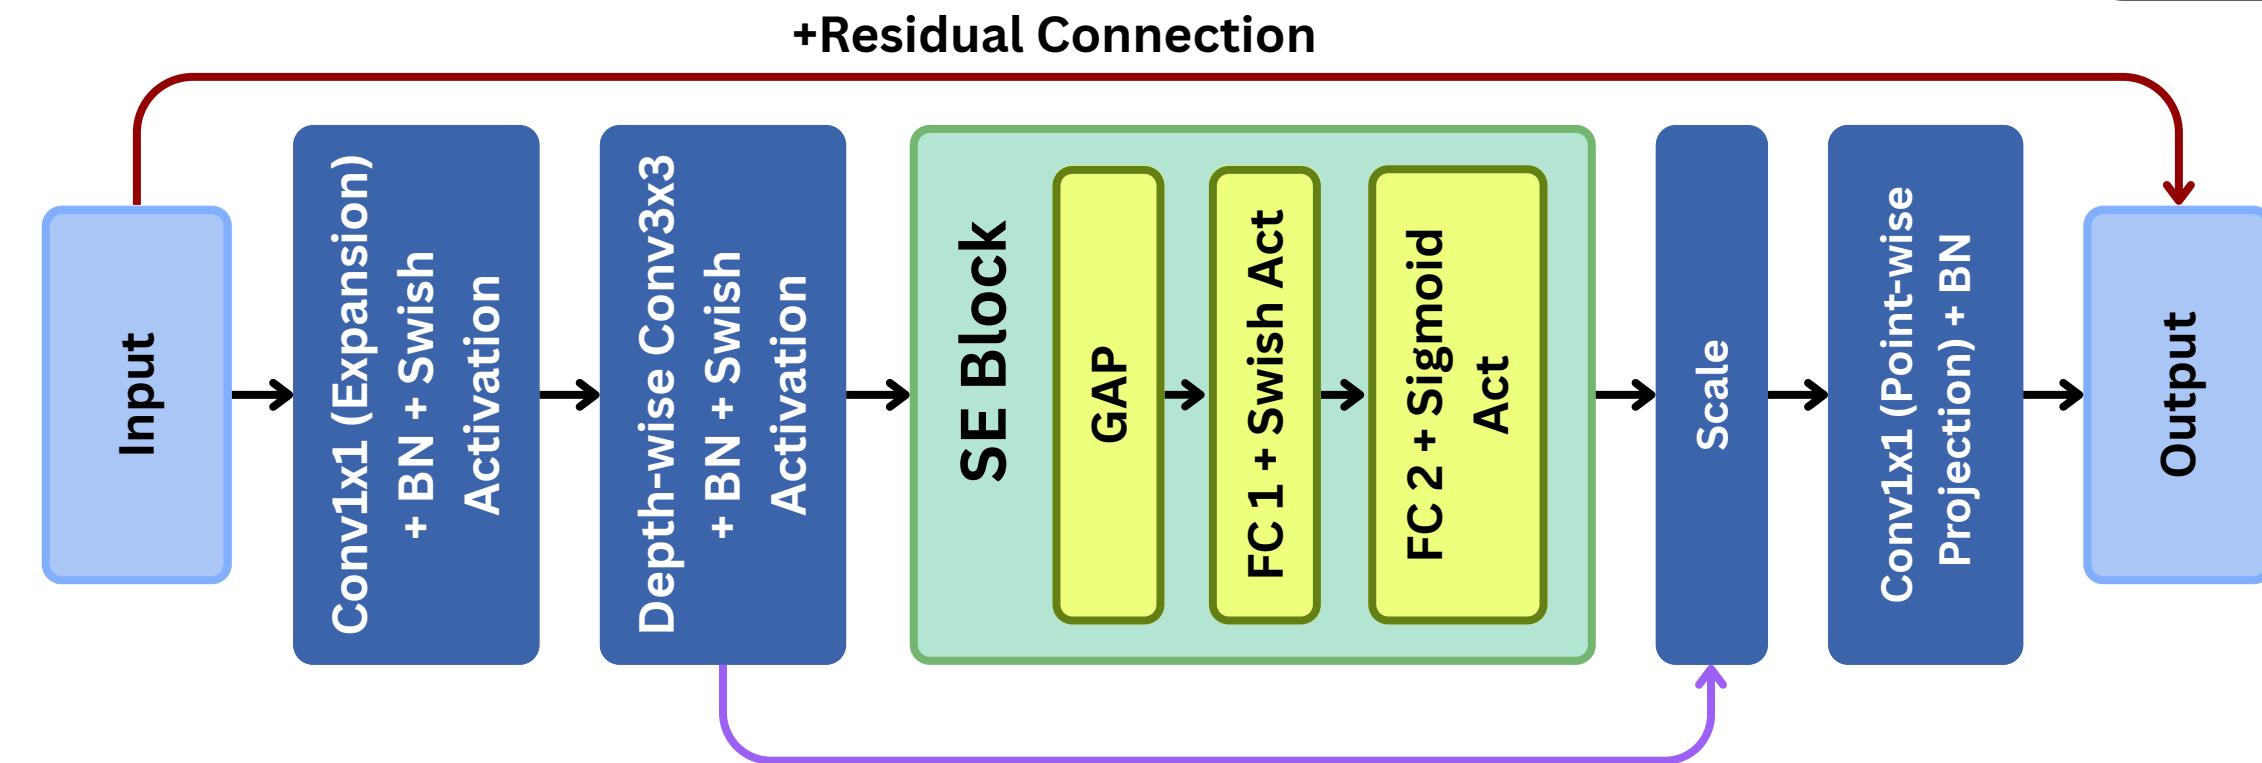


Sumber: (Lee et al., 2023)

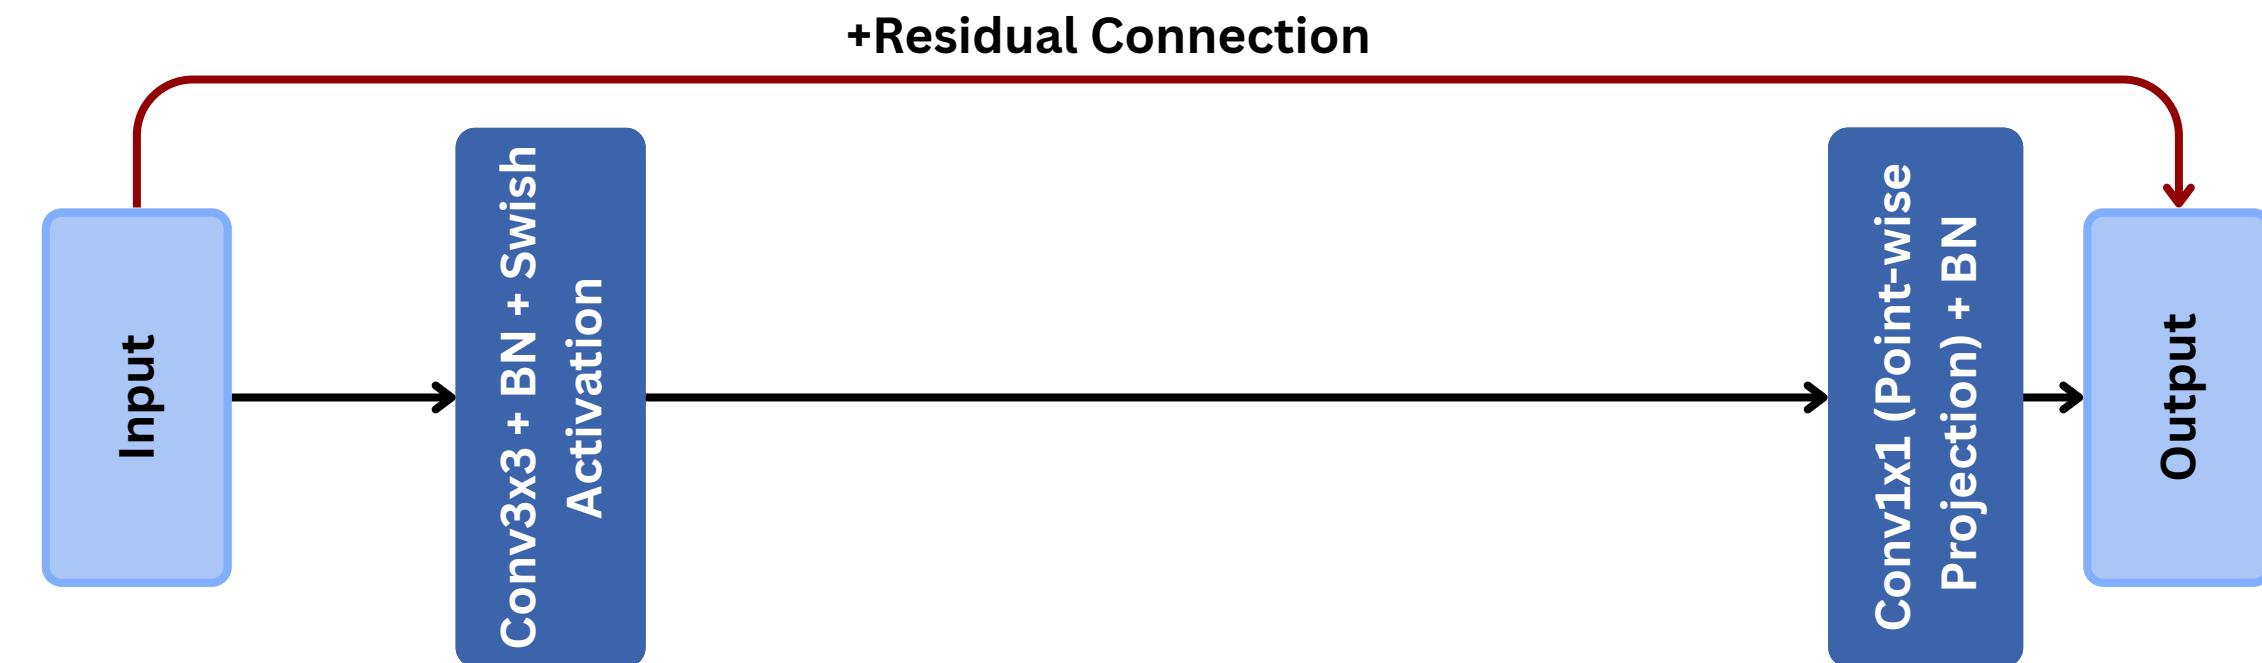
# MBConv VS FUSED-MBConv



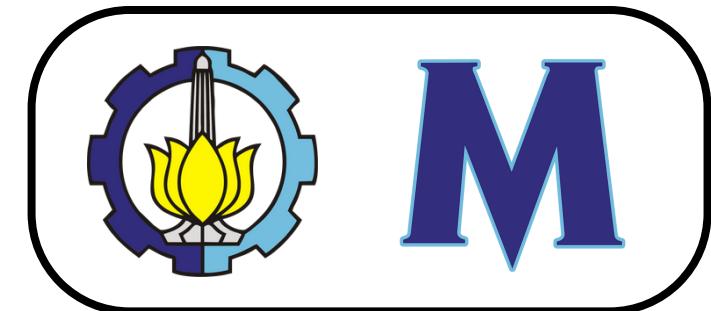
**MBConv**



**Fused-MBConv**



# METRIK EVALUASI



1

## ESRGAN

### *Peak Signal-to-Noise Ratio (PSNR)*

$$\text{PSNR} = 20 \log_{10} \left( \frac{255}{\sqrt{\text{MSE}_{\text{RGB}}}} \right)$$

### *Structural Similarity Index (SSIM)*

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

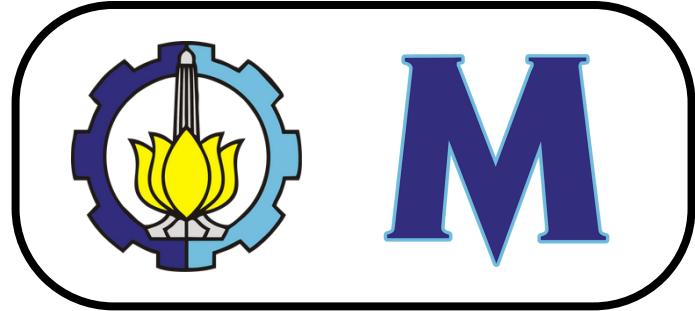
dengan:

$$\text{MSE}_{\text{RGB}} = \frac{1}{3} (\text{MSE}_R + \text{MSE}_G + \text{MSE}_B)$$

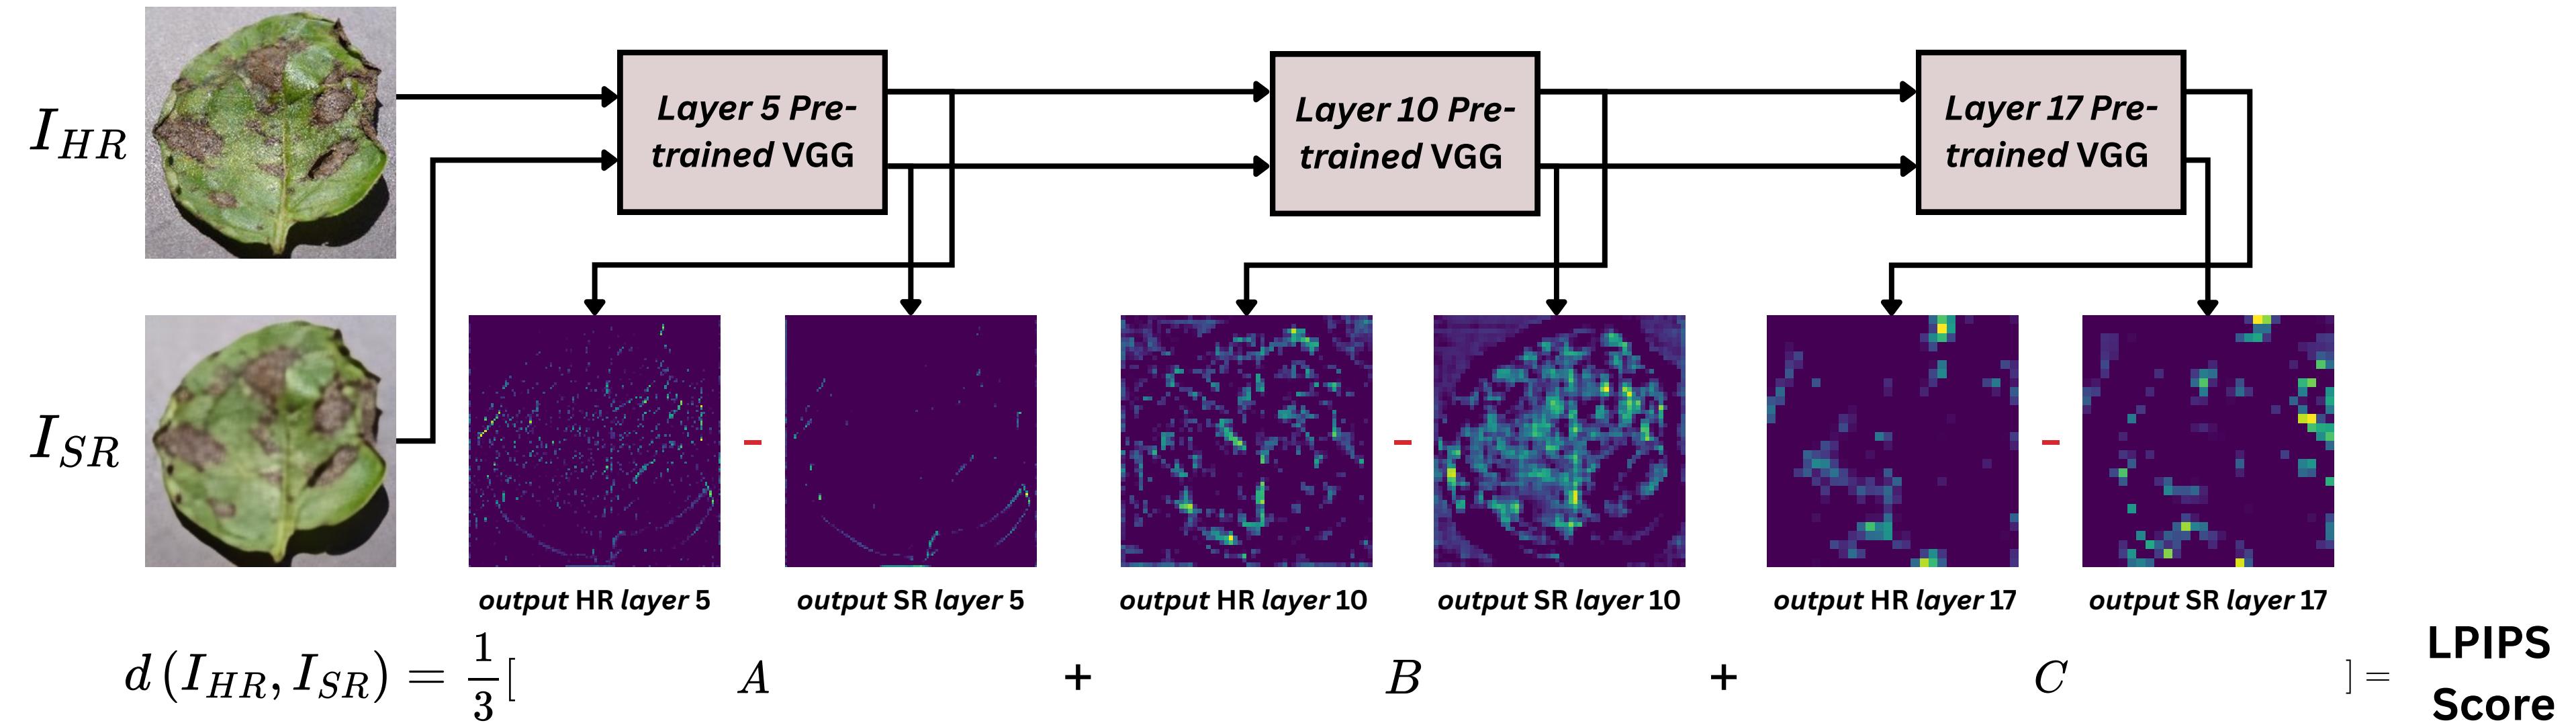
$$\text{SSIM}_{\text{RGB}} = \frac{1}{3} \sum_{c \in \{R,G,B\}} \text{SSIM}(x^c, y^c)$$

# METRIK EVALUASI

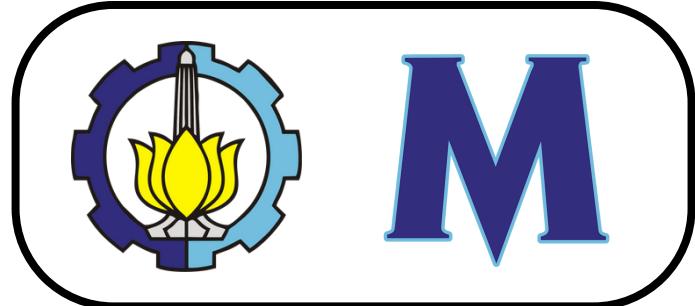
## *Learned Perceptual Image Patch Similarity (LPIPS)*



$$d(x, x_0) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \|w_l \odot (\hat{y}_{hw}^l - \hat{y}_{0hw}^l)\|_2^2$$



# METRIK EVALUASI



2

## EfficientNetV2

### 1. Accuracy

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

### 2. Recall

$$Recall = \frac{TP}{TP + FN}$$

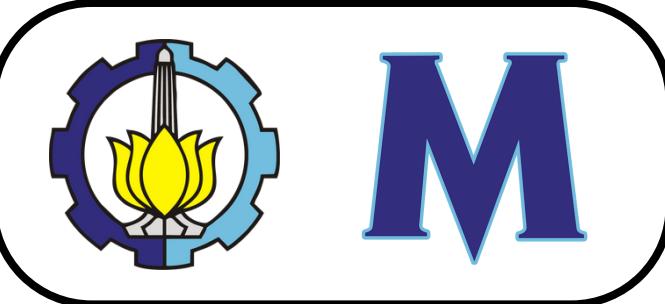
### 3. Precision

$$Precision = \frac{TP}{TP + FP}$$

### 4. F1-score

$$F1\text{-score} = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

# TAHAPAN KERJA SISTEM



1

## *Input Data Citra Daun Kentang*



1000 citra  
daun sehat (HR)



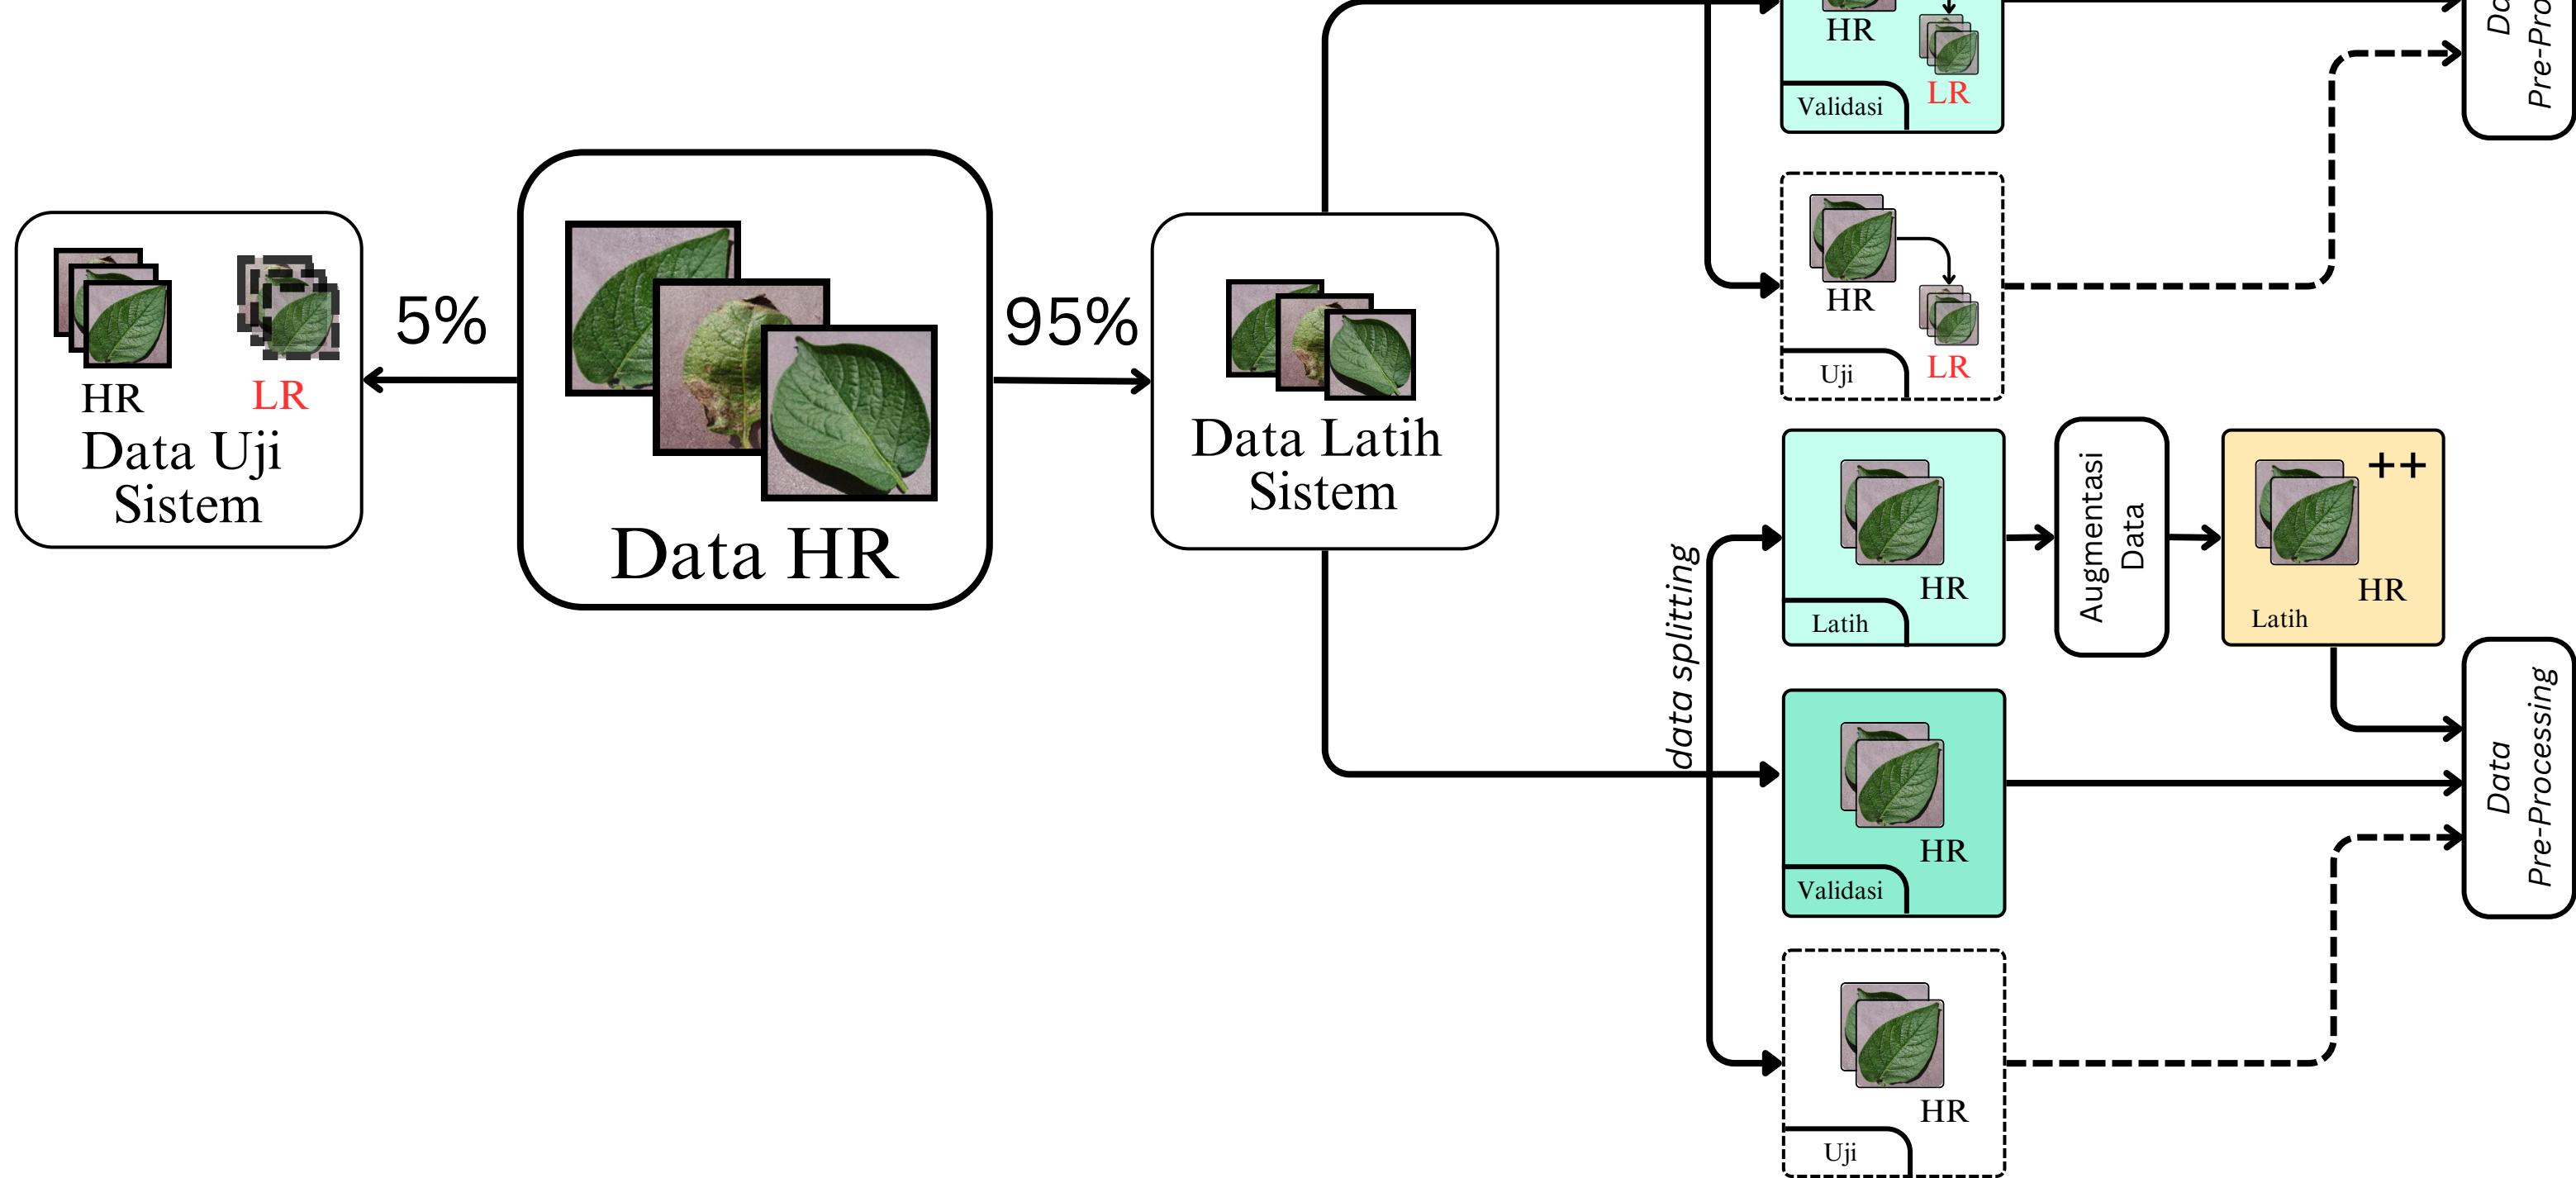
1000 citra  
*early blight* (HR)



1000 citra  
*late blight* (HR)

2

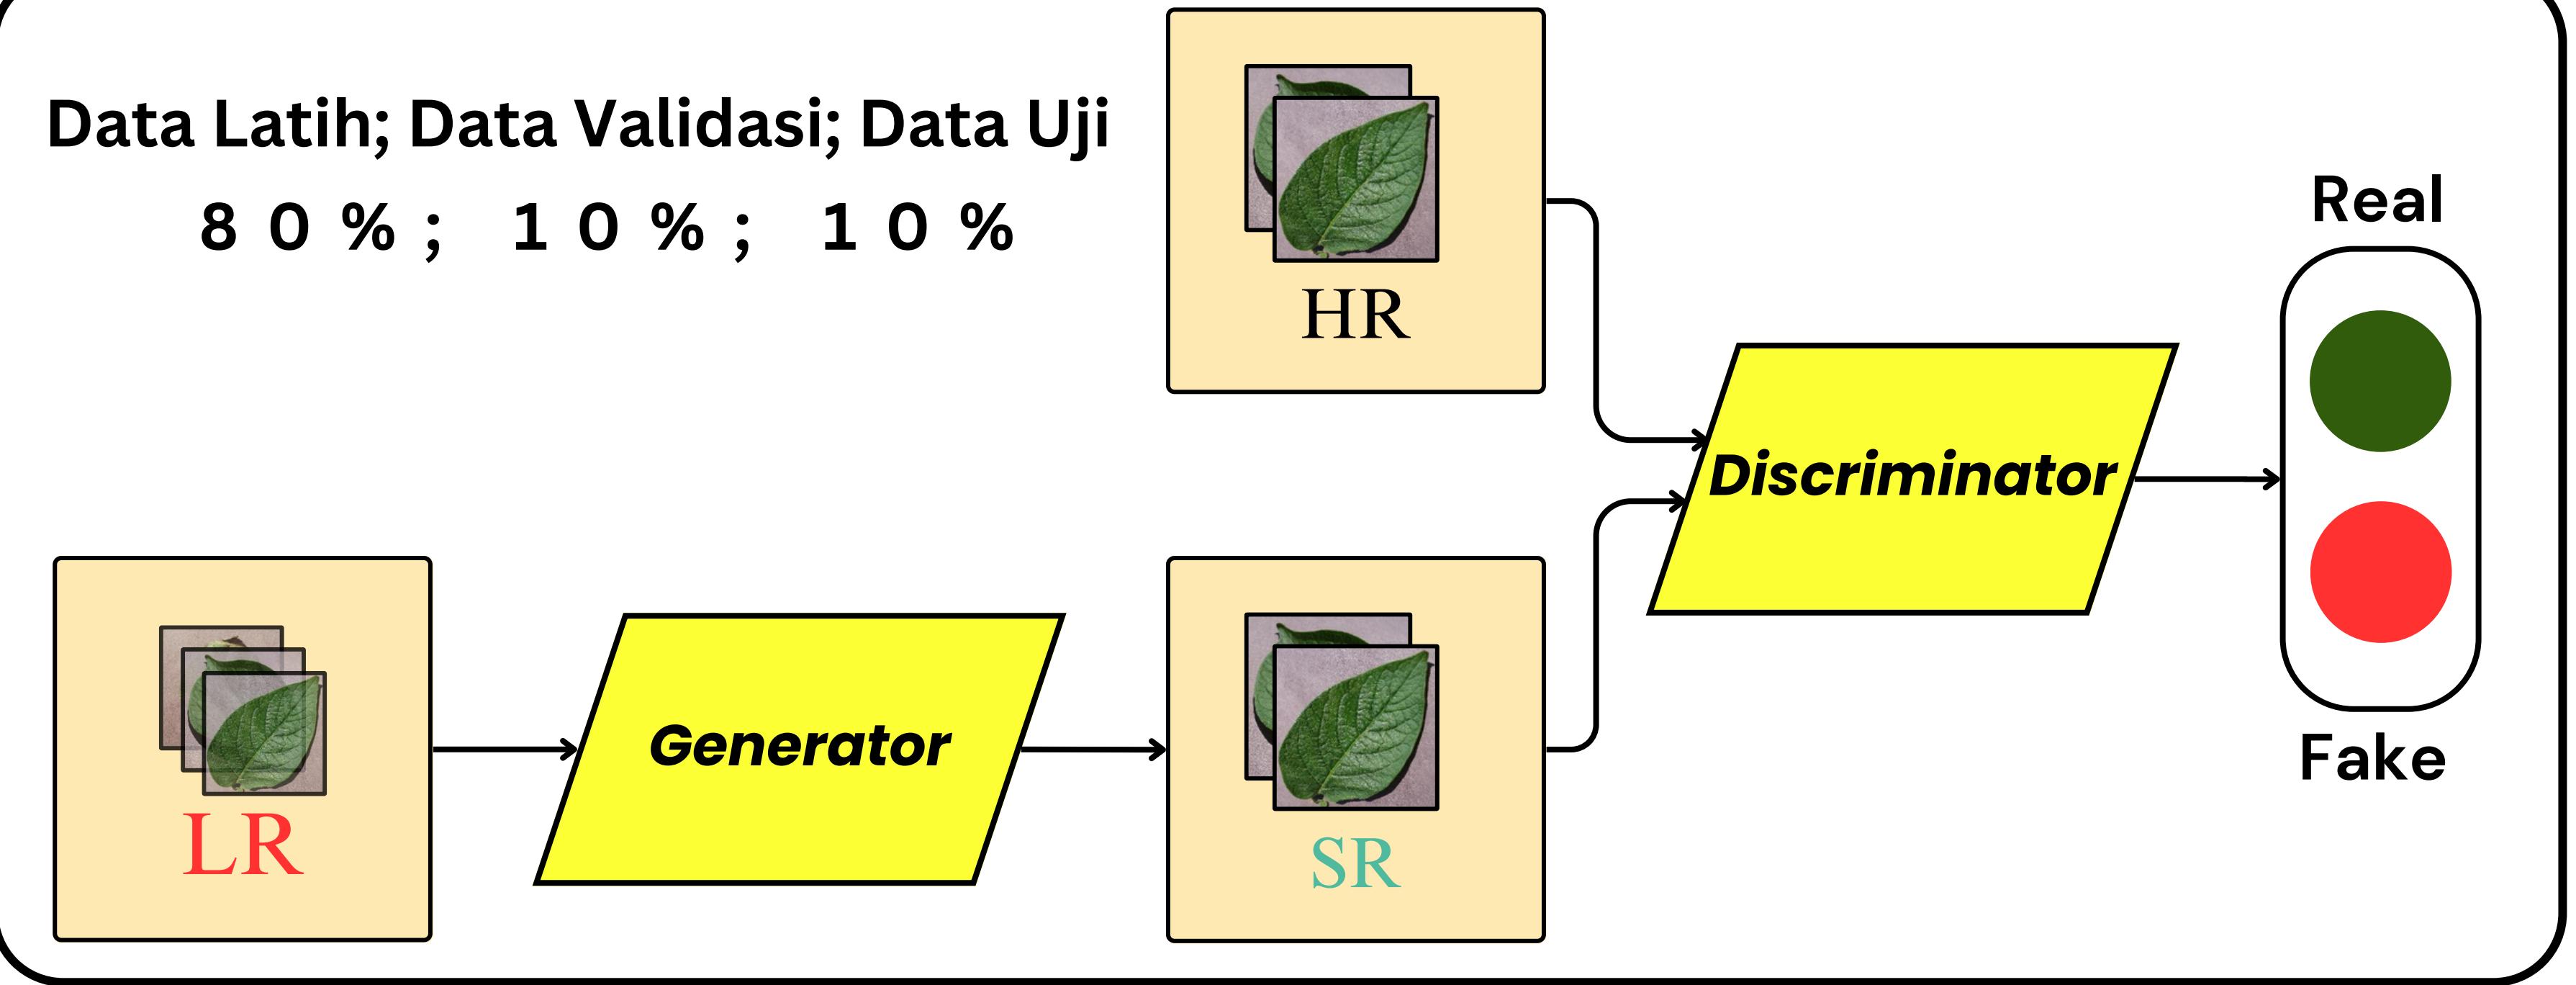
## Persiapan Data



# 3

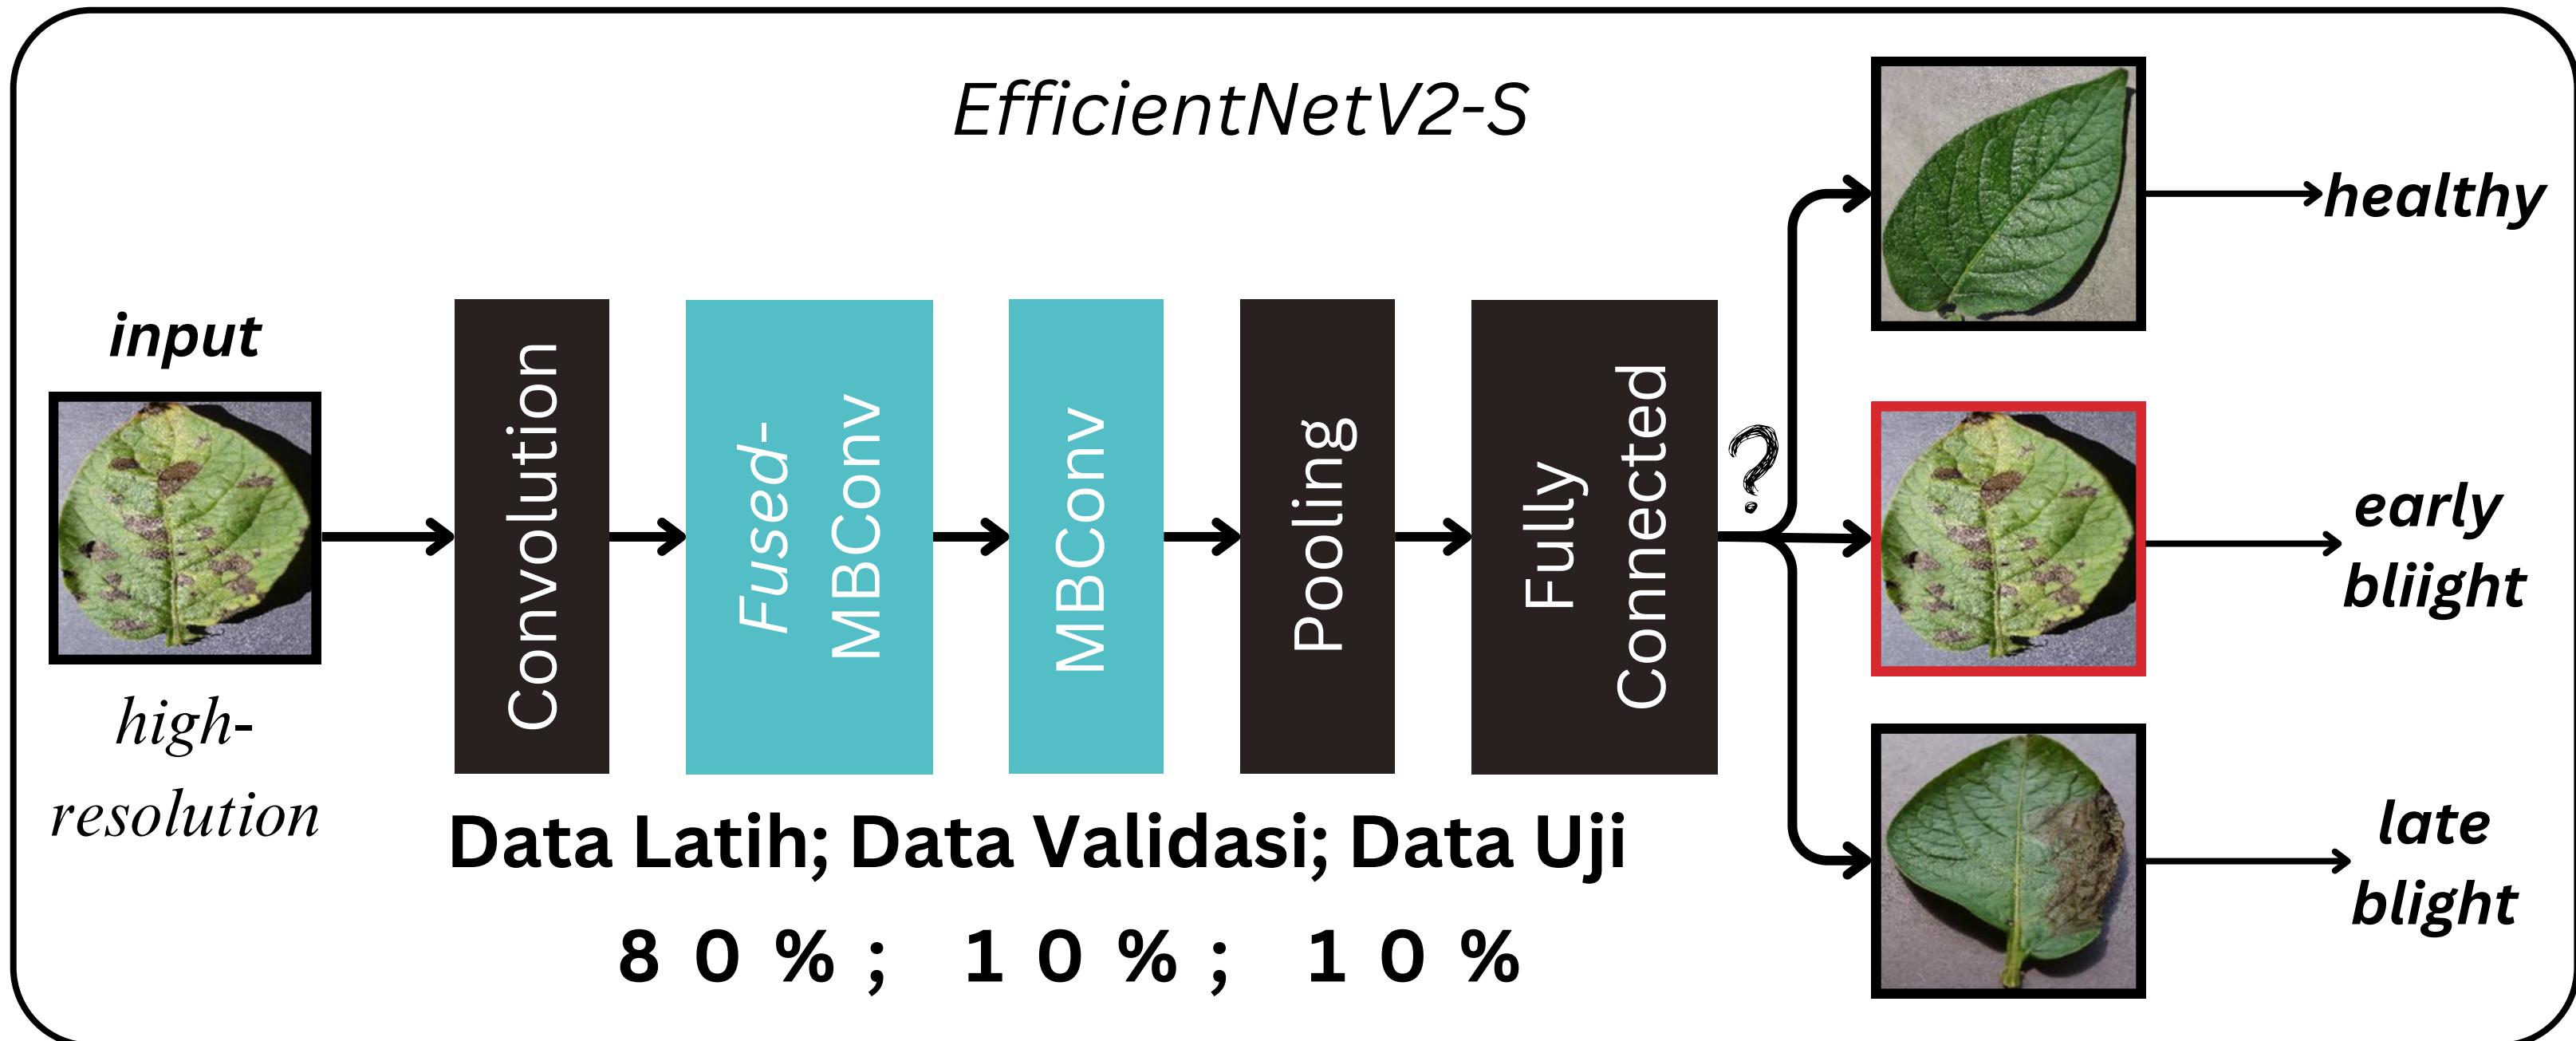
## Pelatihan, Validasi, dan Pengujian Model ESRGAN

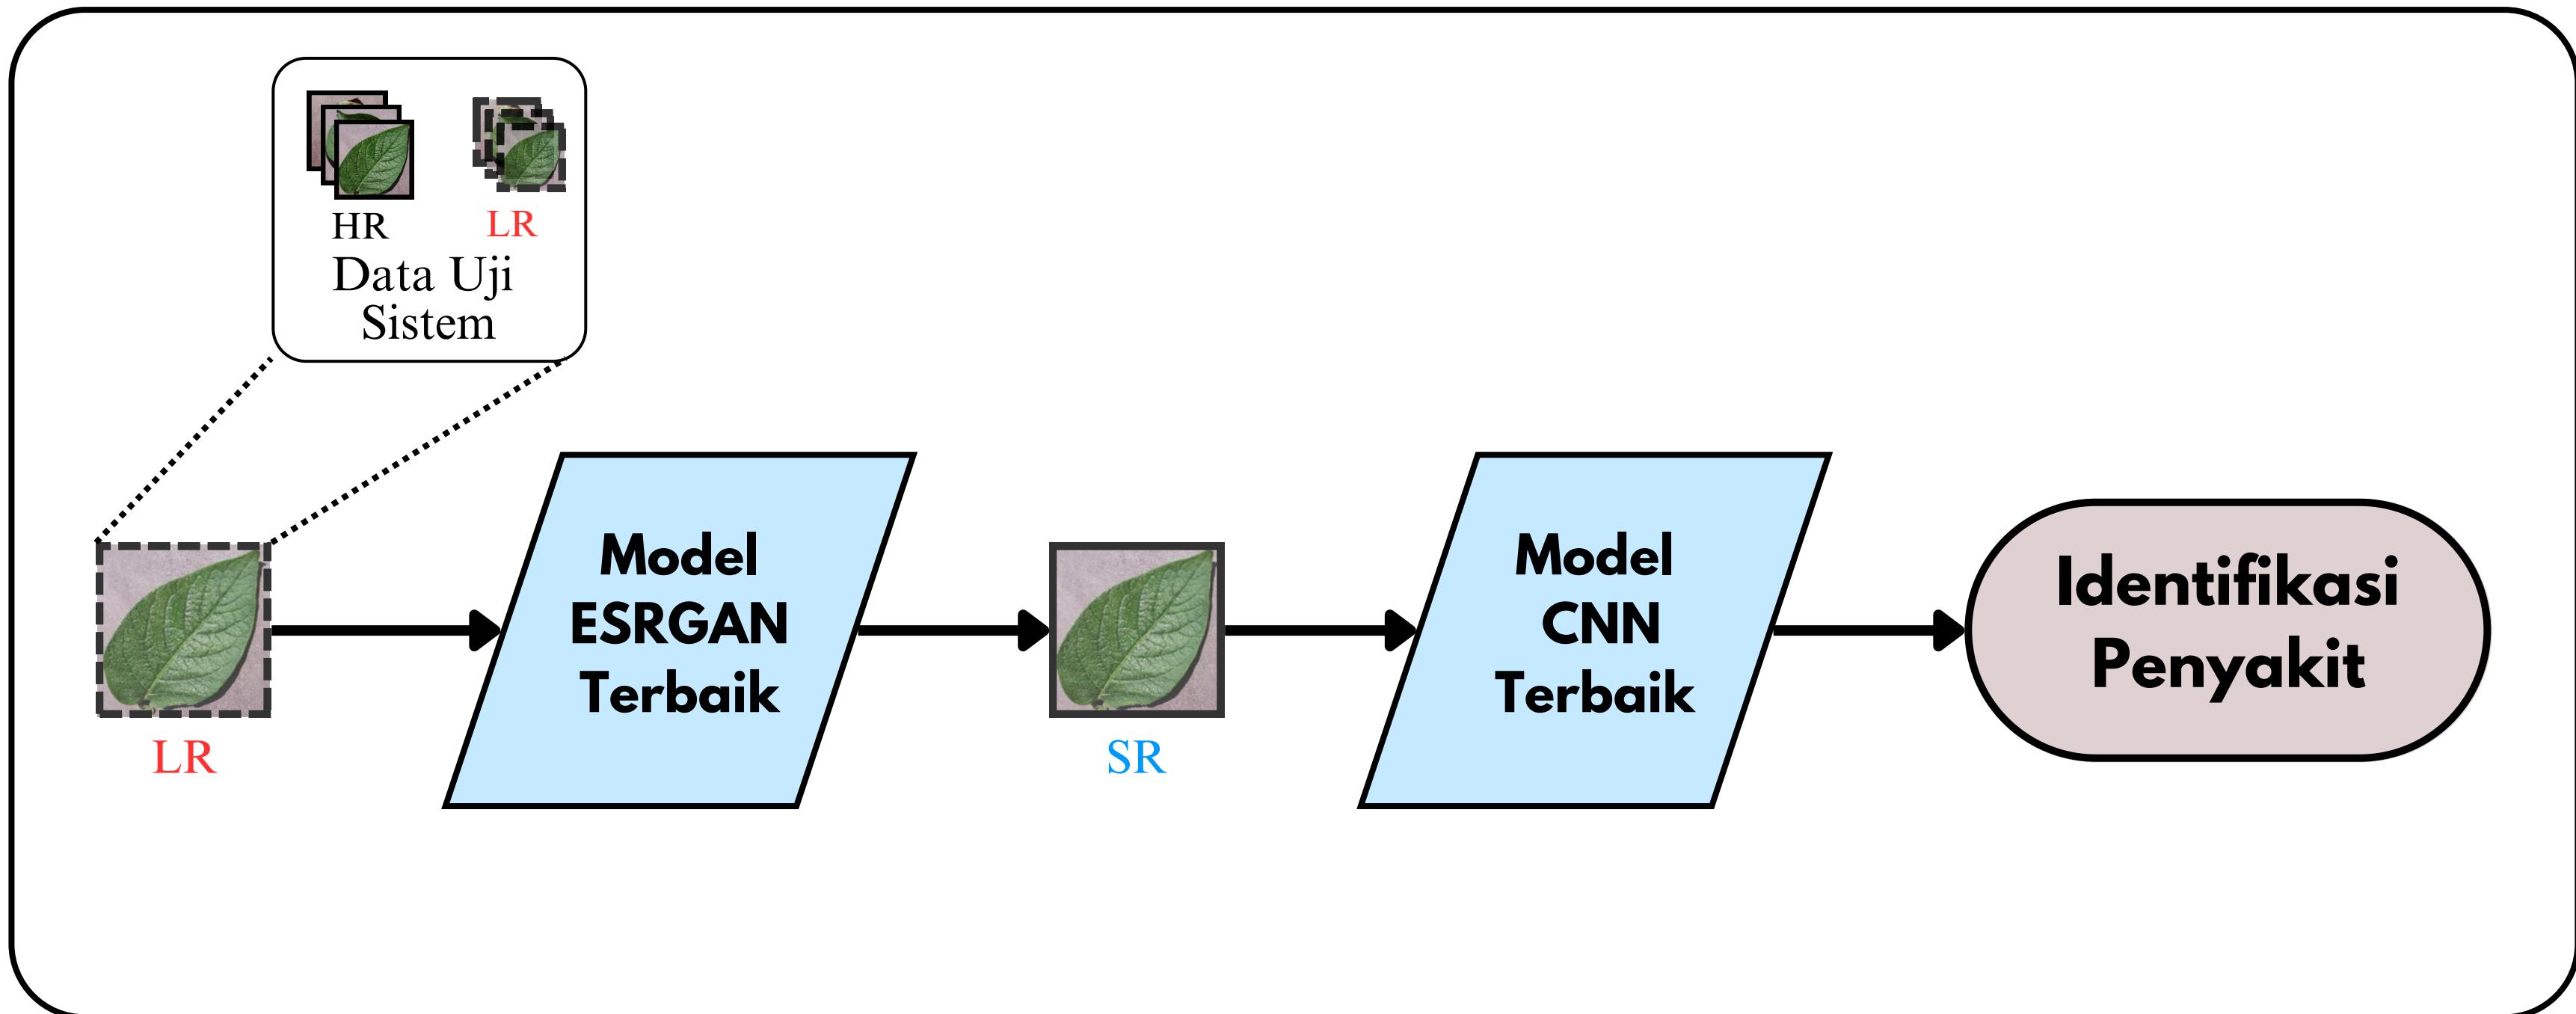
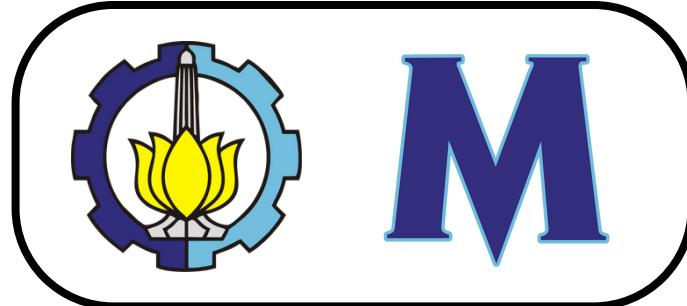
Data Latih; Data Validasi; Data Uji  
8 0 % ; 1 0 % ; 1 0 %



# 4

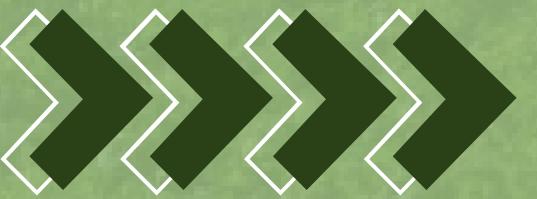
## Pelatihan, Validasi, dan Pengujian Model CNN



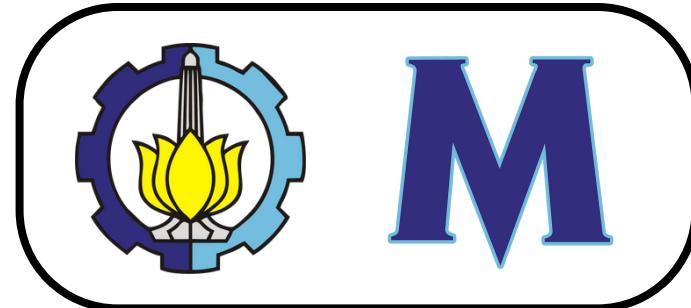




# HASIL DAN PEMBAHASAN



# **SKENARIO PELATIHAN ESRGAN**

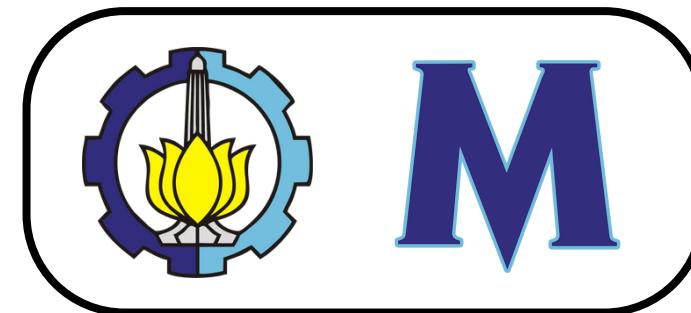


	<b><i>Default</i></b>	<b><i>Pixel-Dominant</i></b>
	0.01	15
	1.0	0.1
	0.005	0.001

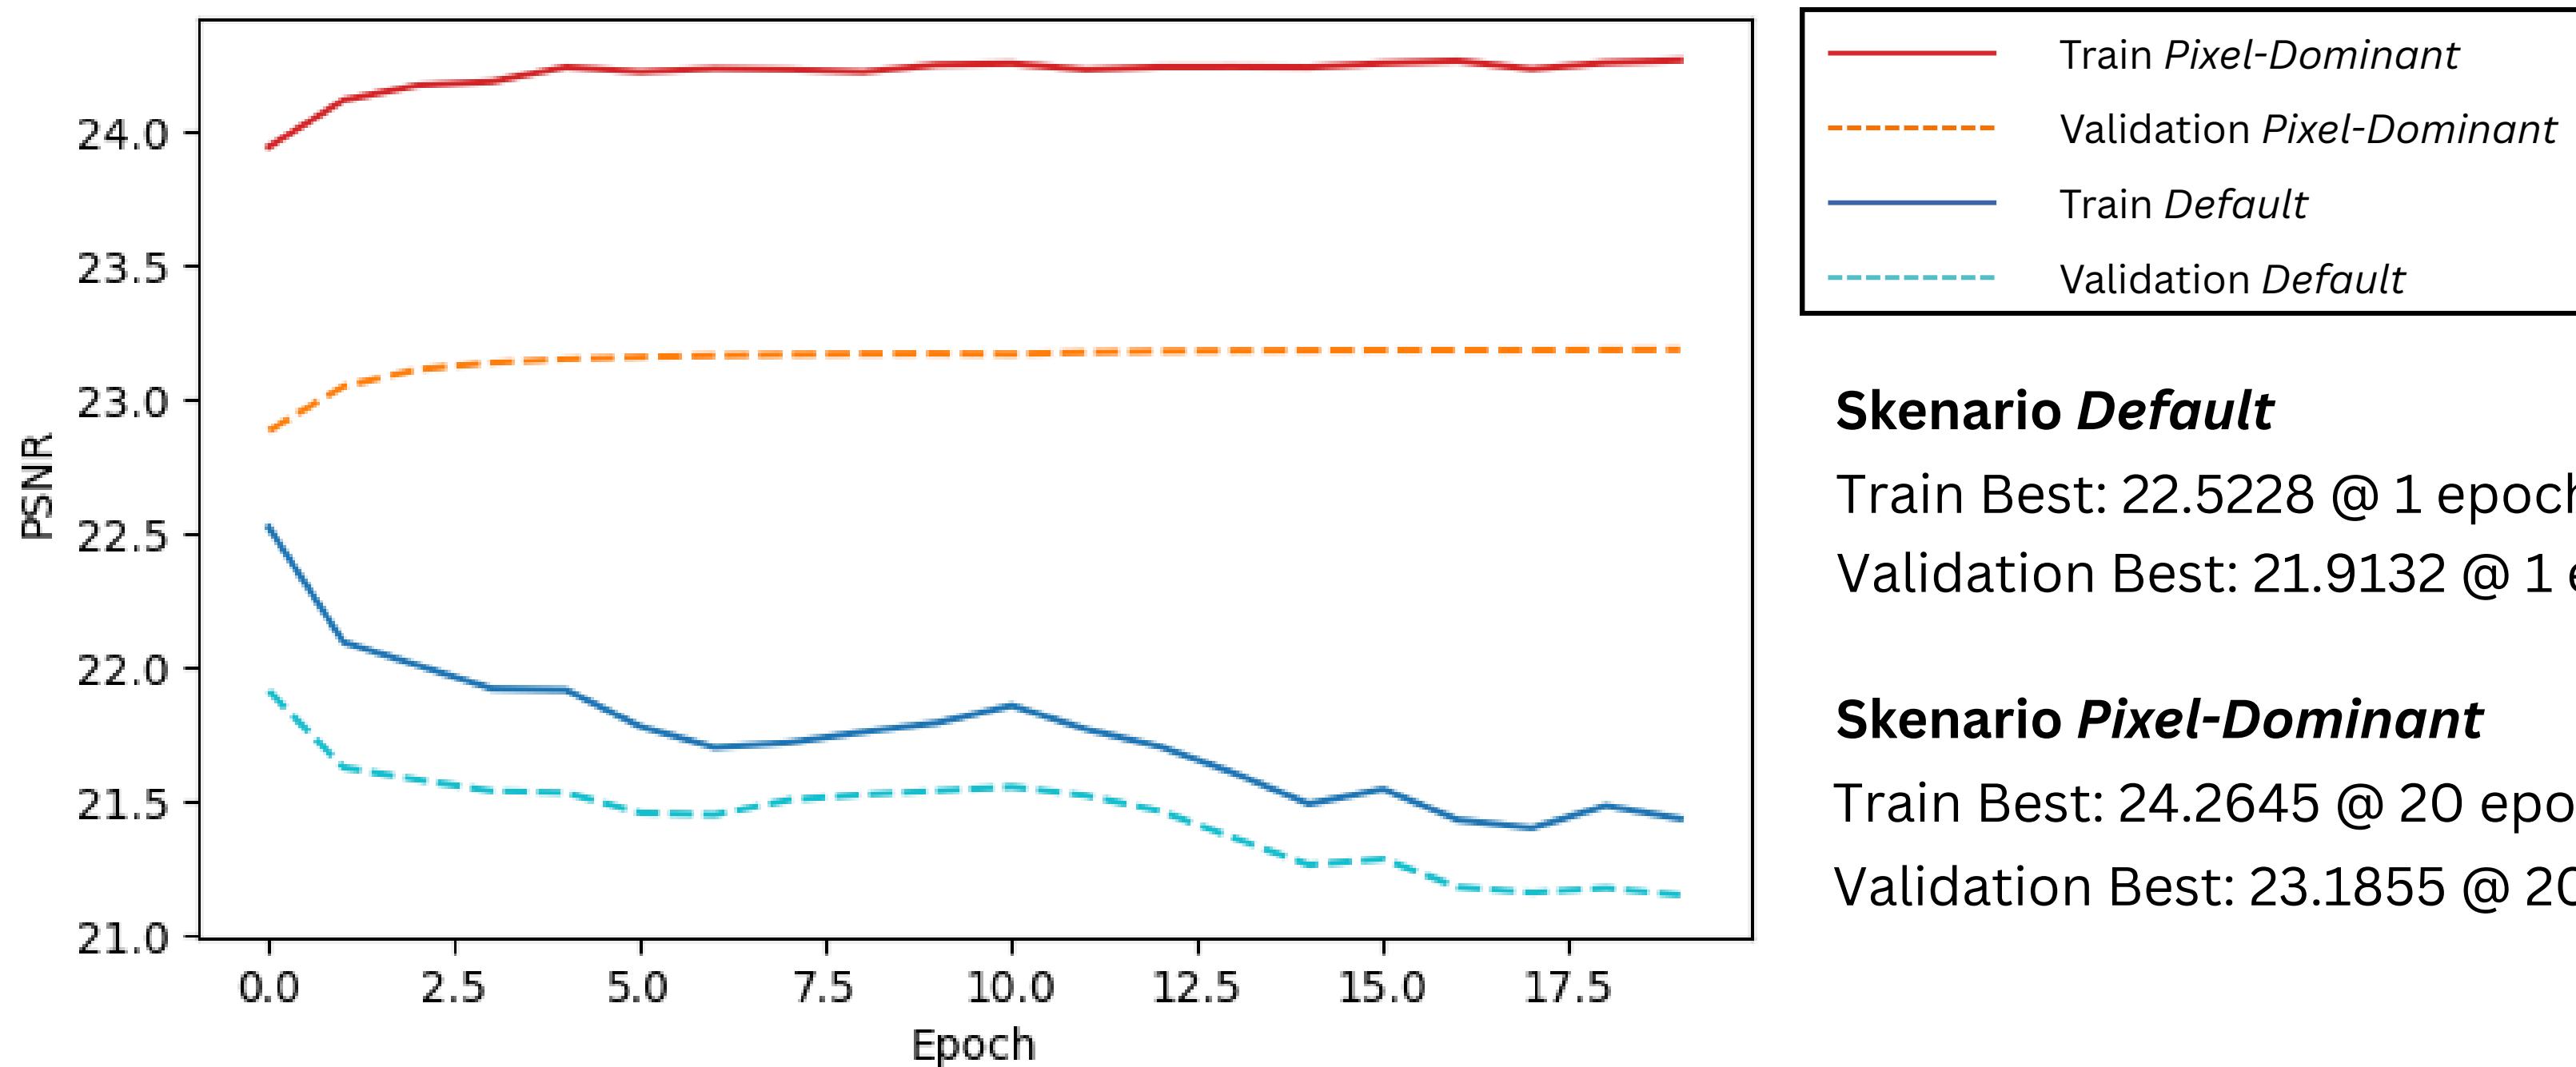
\*Skenario Default mengutamakan persepsi visual (LPIPS), sedangkan Pixel-Dominant fokus pada akurasi piksel (PSNR, SSIM)



# HASIL PELATIHAN DAN VALIDASI ESRGAN



## *Peak Signal-To-Noise-Ratio (PSNR)*



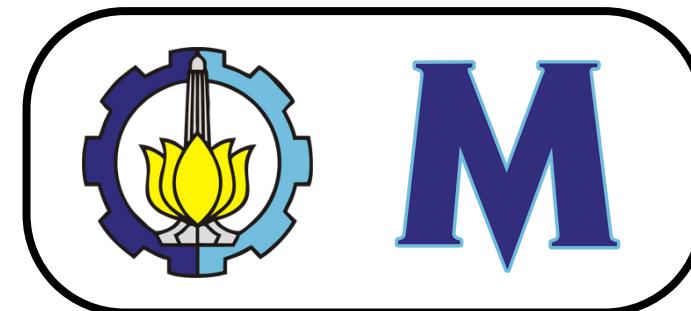
### **Skenario Default**

Train Best: 22.5228 @ 1 epoch  
Validation Best: 21.9132 @ 1 epoch

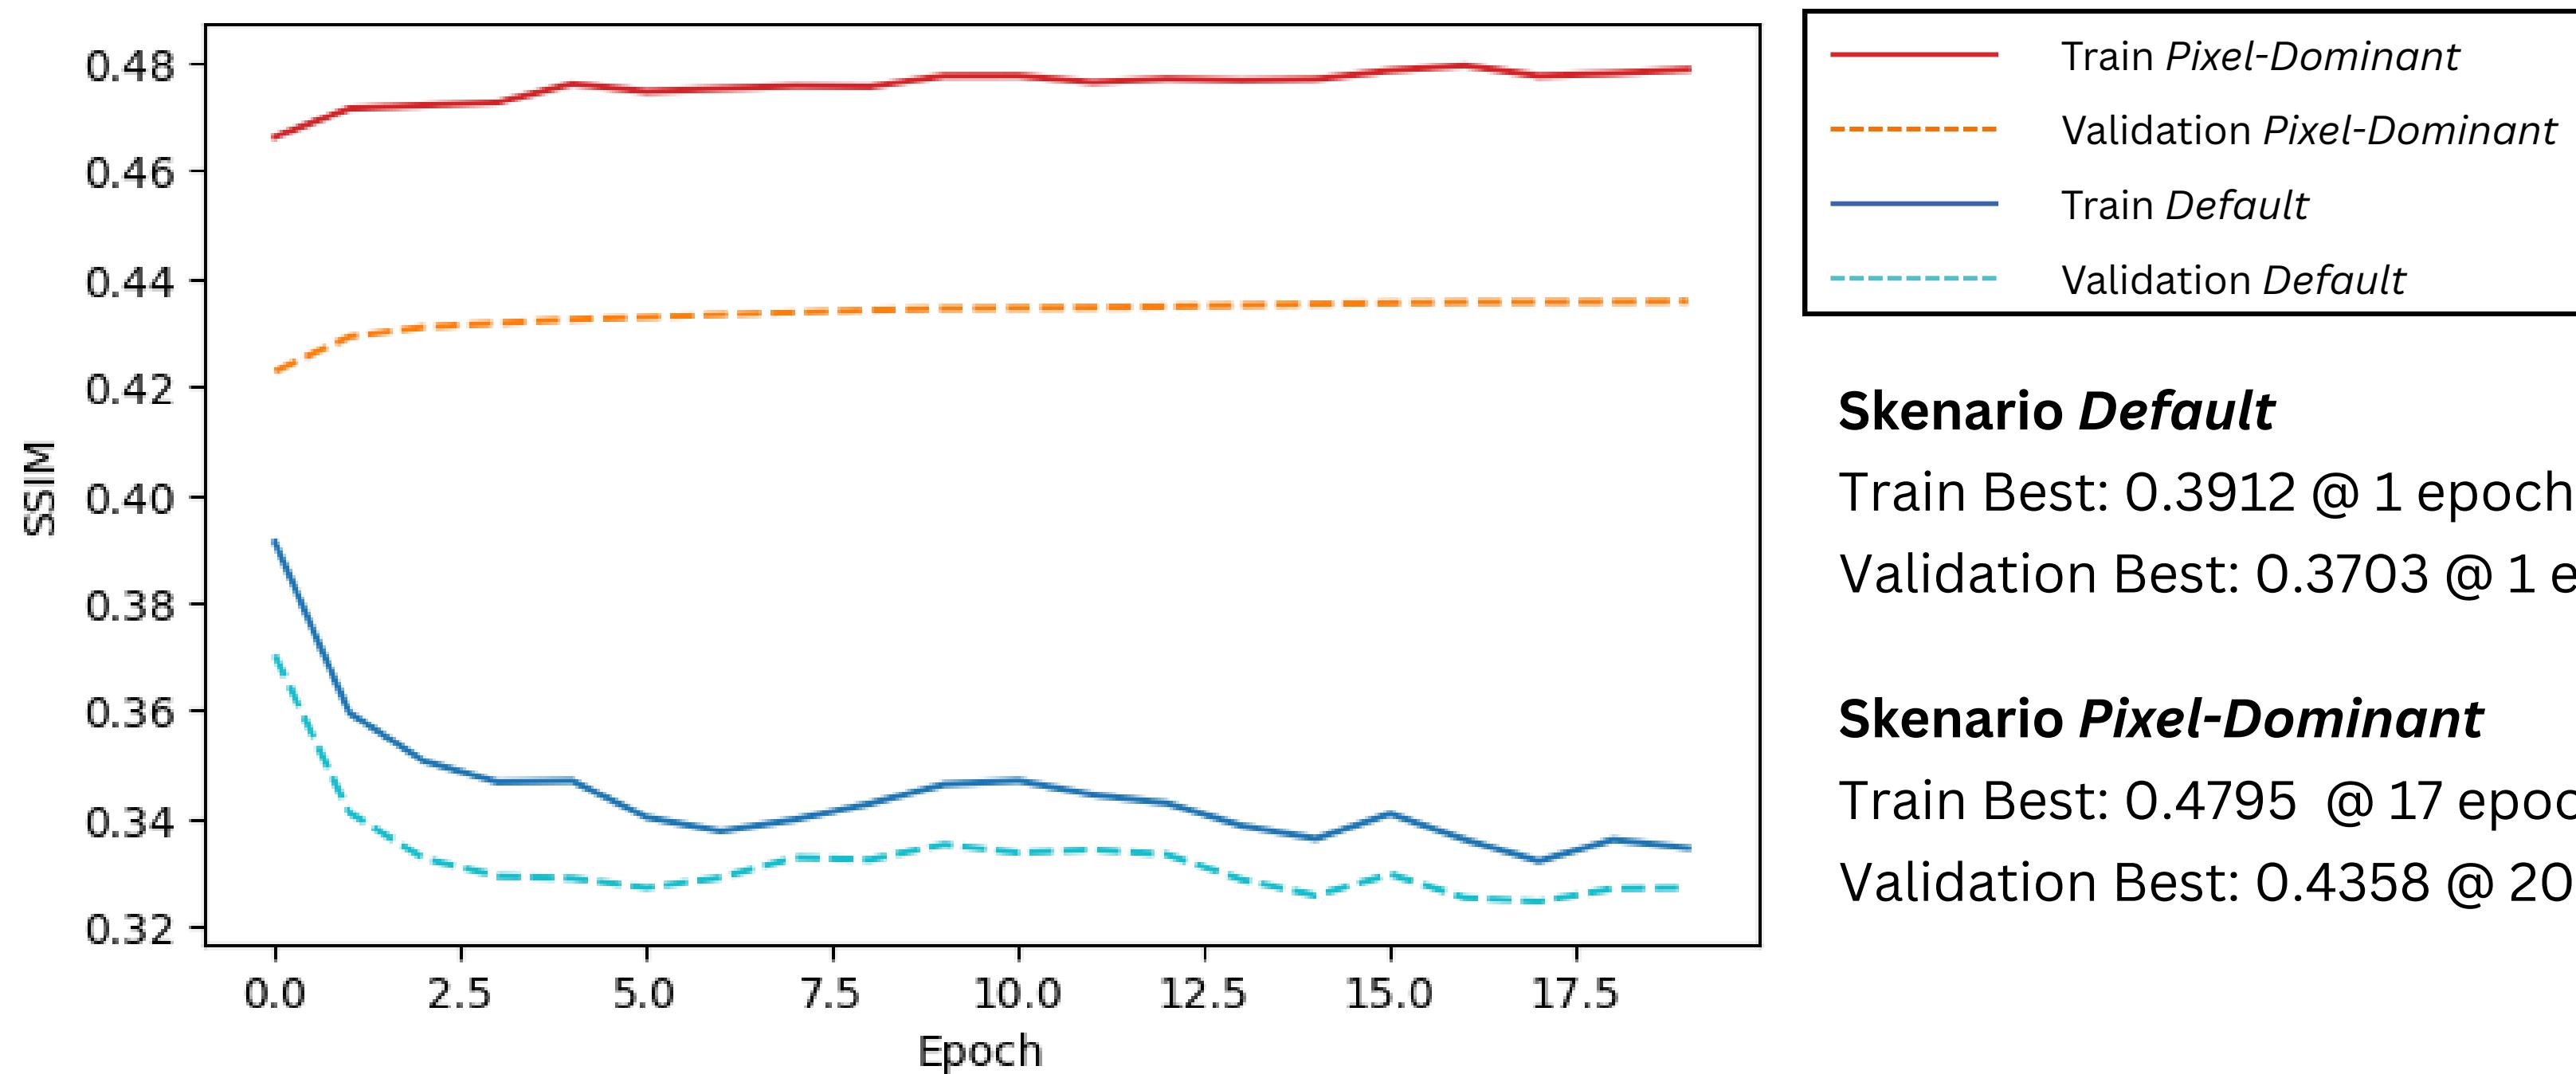
### **Skenario Pixel-Dominant**

Train Best: 24.2645 @ 20 epoch  
Validation Best: 23.1855 @ 20 epoch

# HASIL PELATIHAN DAN VALIDASI ESRGAN



## *Structural Similarity Index (SSIM)*



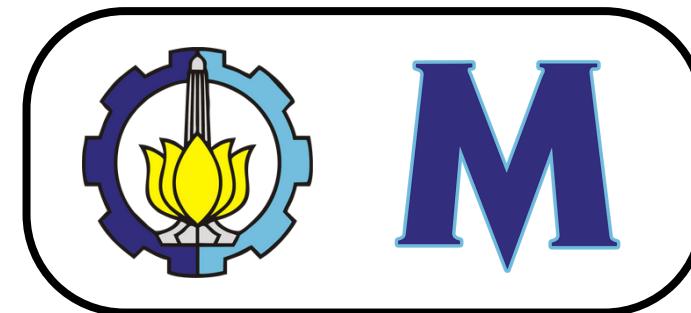
### **Skenario Default**

Train Best: 0.3912 @ 1 epoch  
Validation Best: 0.3703 @ 1 epoch

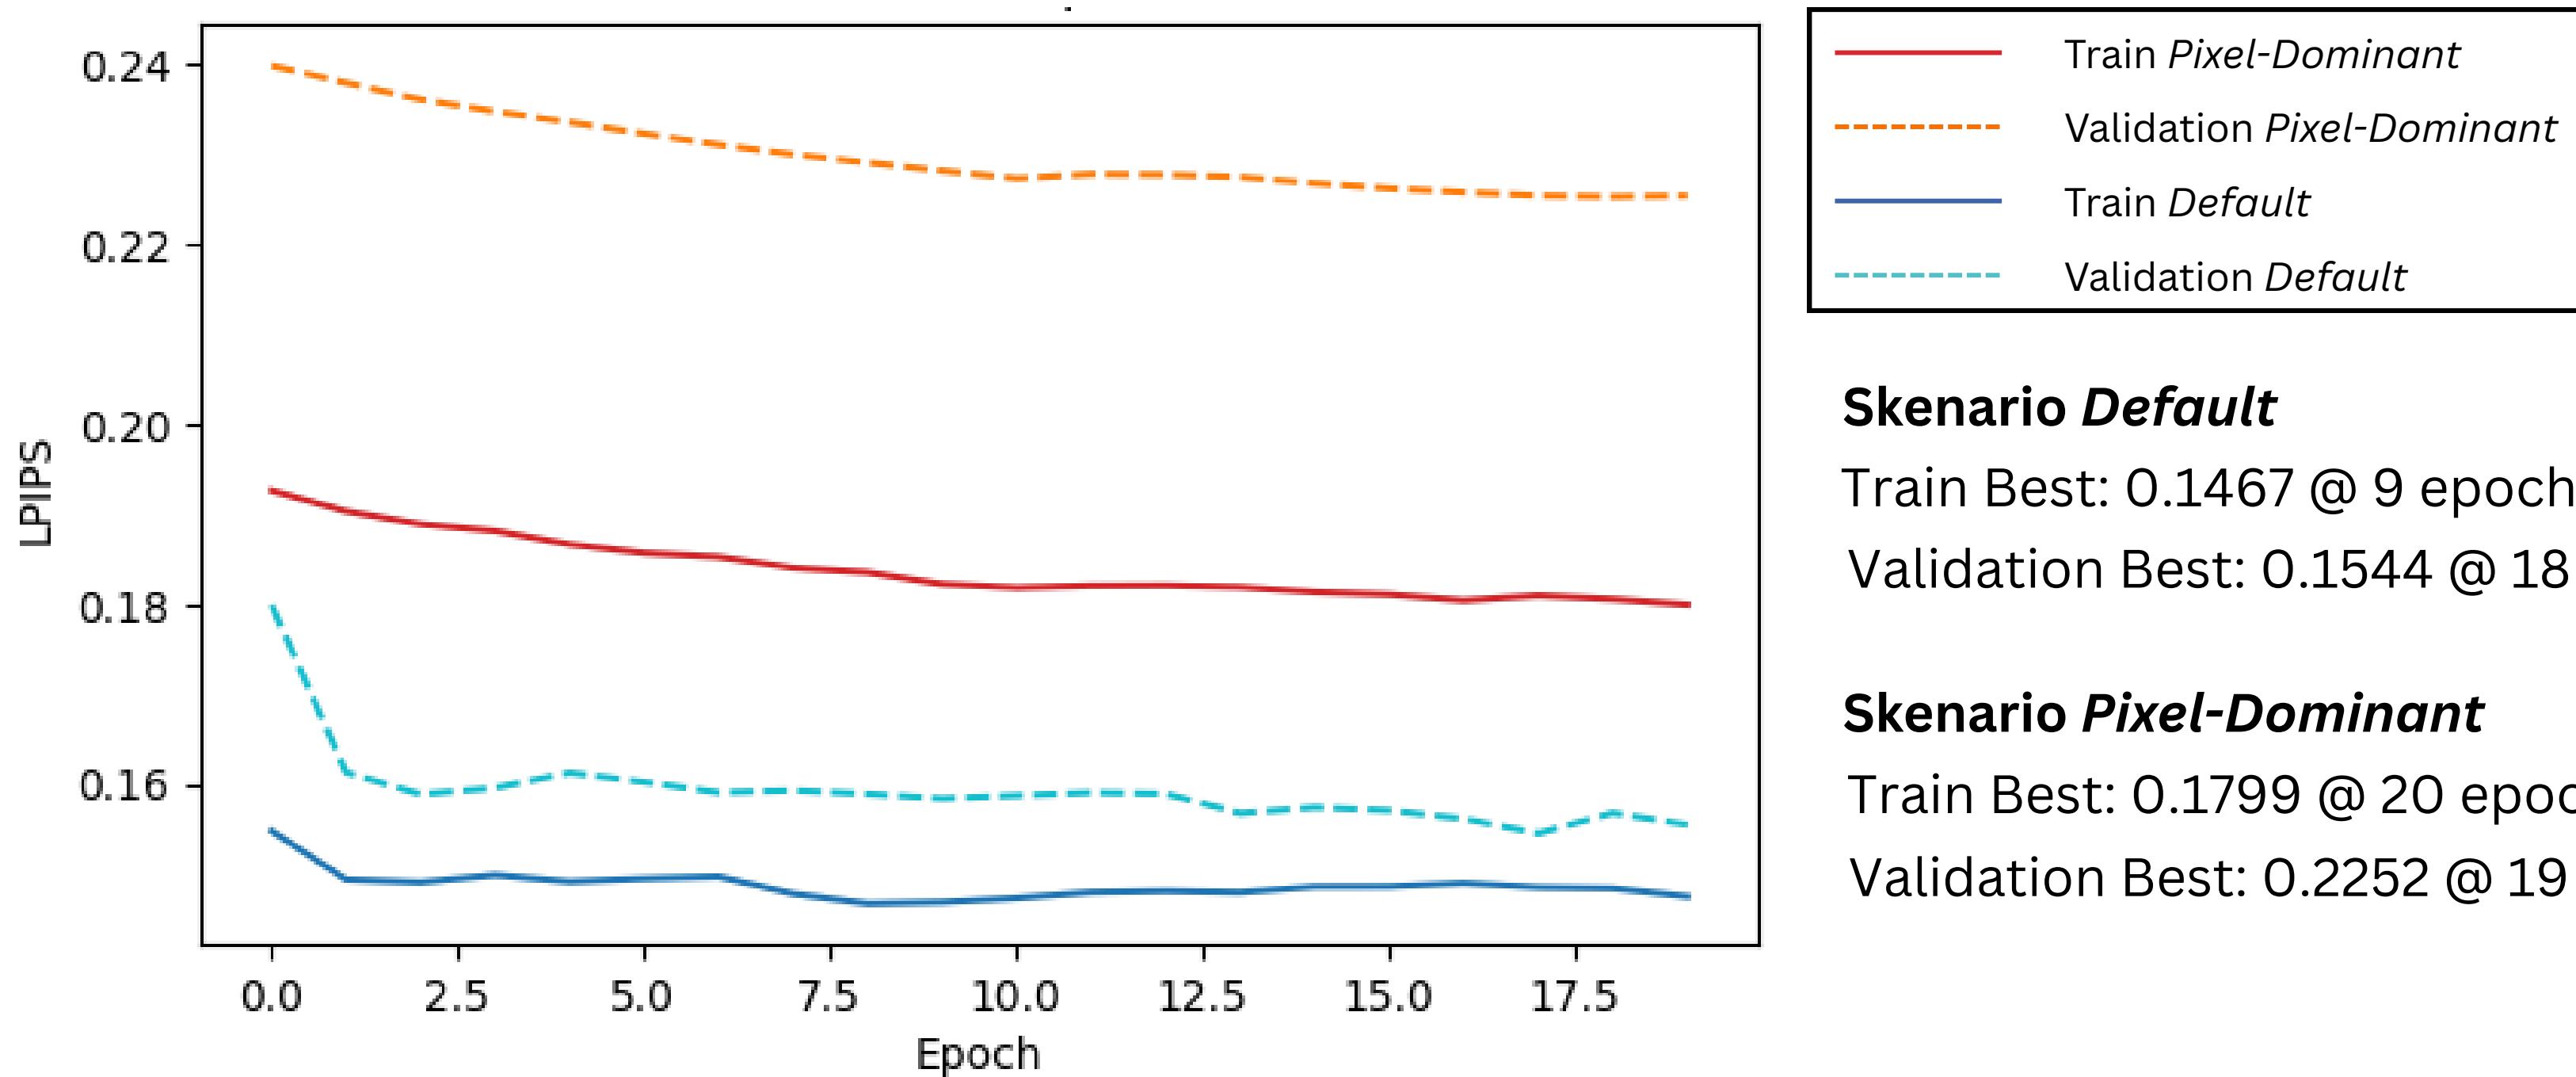
### **Skenario Pixel-Dominant**

Train Best: 0.4795 @ 17 epoch  
Validation Best: 0.4358 @ 20 epoch

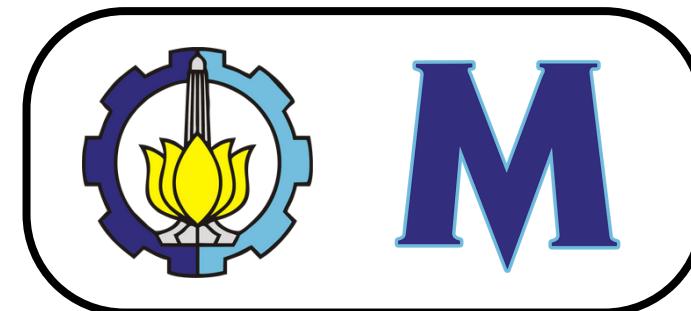
# HASIL PELATIHAN DAN VALIDASI ESRGAN



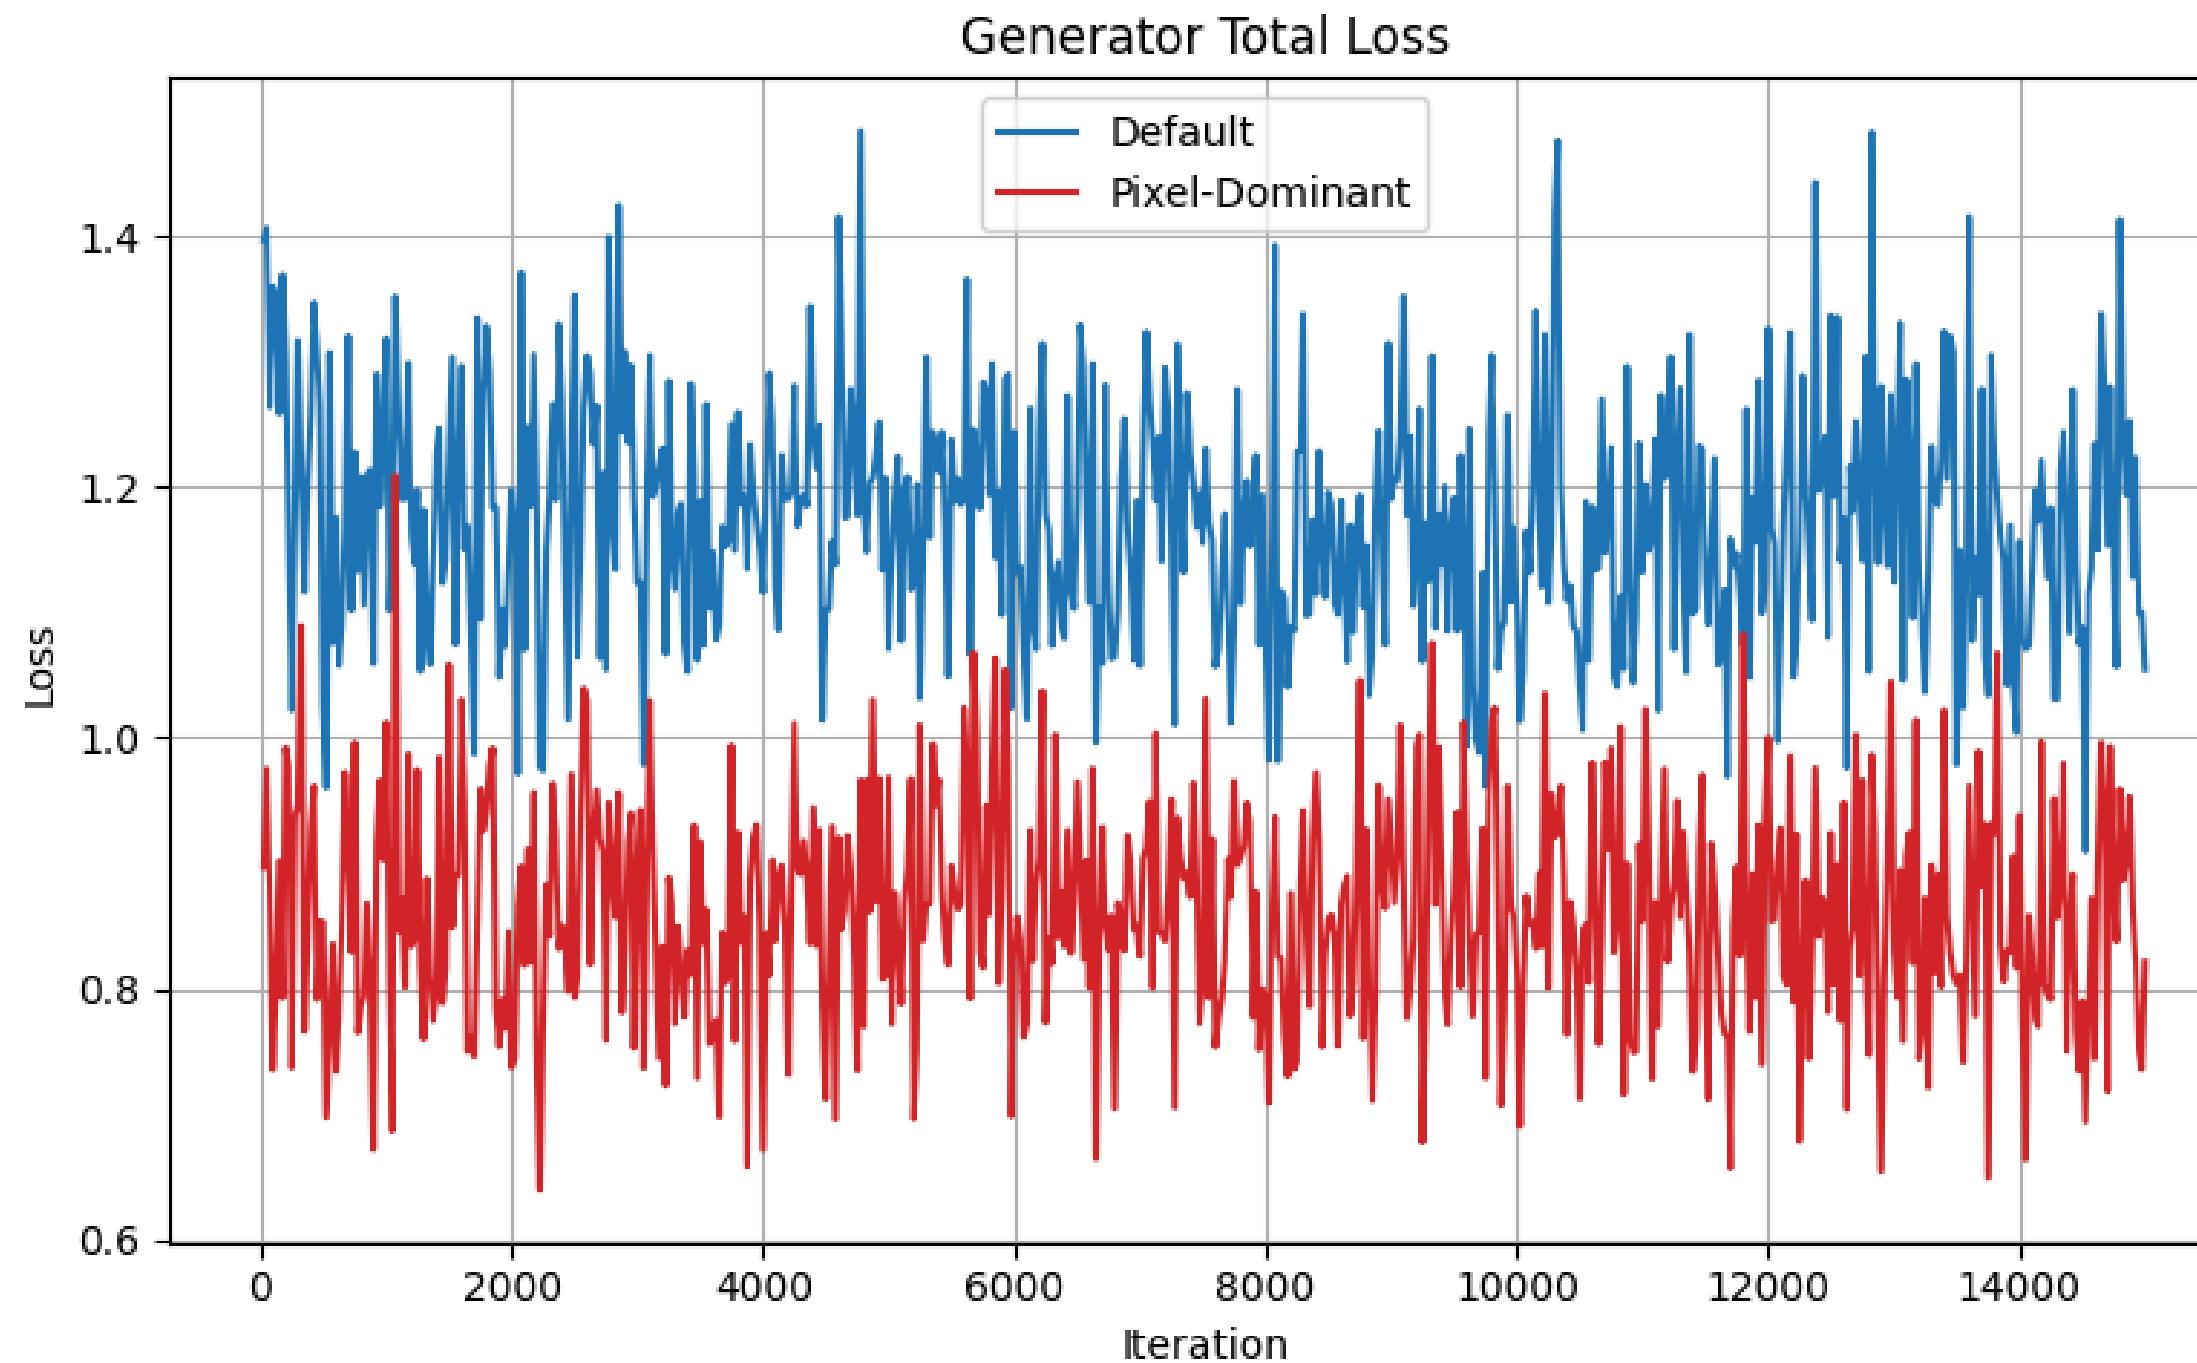
## *Learned Perceptual Image Patch Similarity (LPIPS)*



# HASIL PELATIHAN DAN VALIDASI ESRGAN

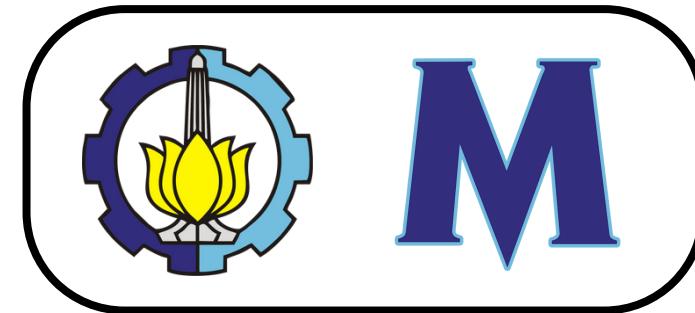


## *Generator Total Loss*



### **Skenario Default dan Pixel-Dominant**

Pada skenario *default*, nilai *generator loss* berfluktuasi cukup tinggi dalam rentang sekitar 0.9 hingga 1.4. Sebaliknya, pada skenario *pixel-dominant*, nilai *total generator loss* tampak lebih stabil, berada di kisaran 0.7 hingga 1.1.



# HASIL PENGUJIAN ESRGAN

Hasil evaluasi menunjukkan bahwa skenario *default* memberikan nilai LPIPS terendah (0.1654), menandakan kualitas perceptual yang lebih baik. Sebaliknya, skenario *pixel-dominant* menghasilkan PSNR dan SSIM lebih tinggi (22.9620 dan 0.4291), namun dengan LPIPS yang lebih tinggi pula (0.2286), yang menunjukkan bahwa citra cenderung lebih halus namun kurang tajam secara visual.

Skenario	PSNR	SSIM	LPIPS
<i>Default</i>	21.8451	0.4078	<b>0.1654</b>
<i>Pixel-Dominant</i>	<b>22.9620</b>	<b>0.4291</b>	0.2286

# HASIL PENGUJIAN ESRGAN

## Perbandingan Visual Citra Hasil Super-Resolusi



LR



*SR Pixel-Dominant*

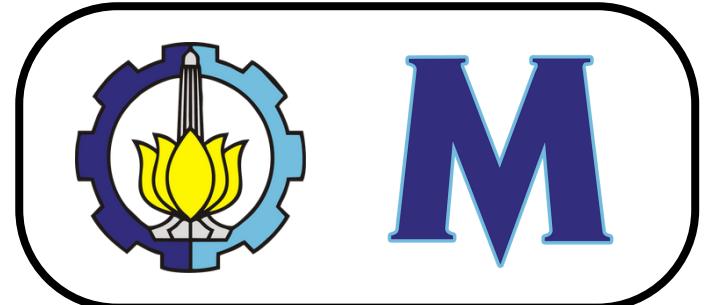


*SR Default*



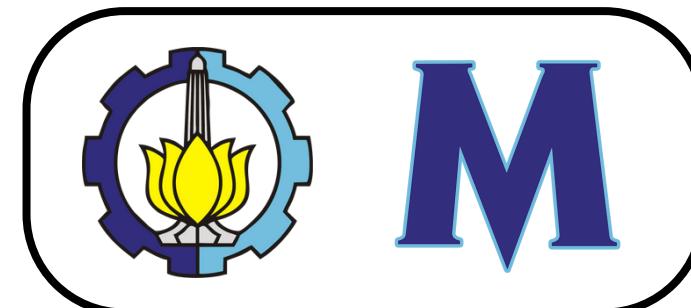
*High Resolution*

# KONFIGURASI HYPERPARAMETER EFFICIENTNETV2

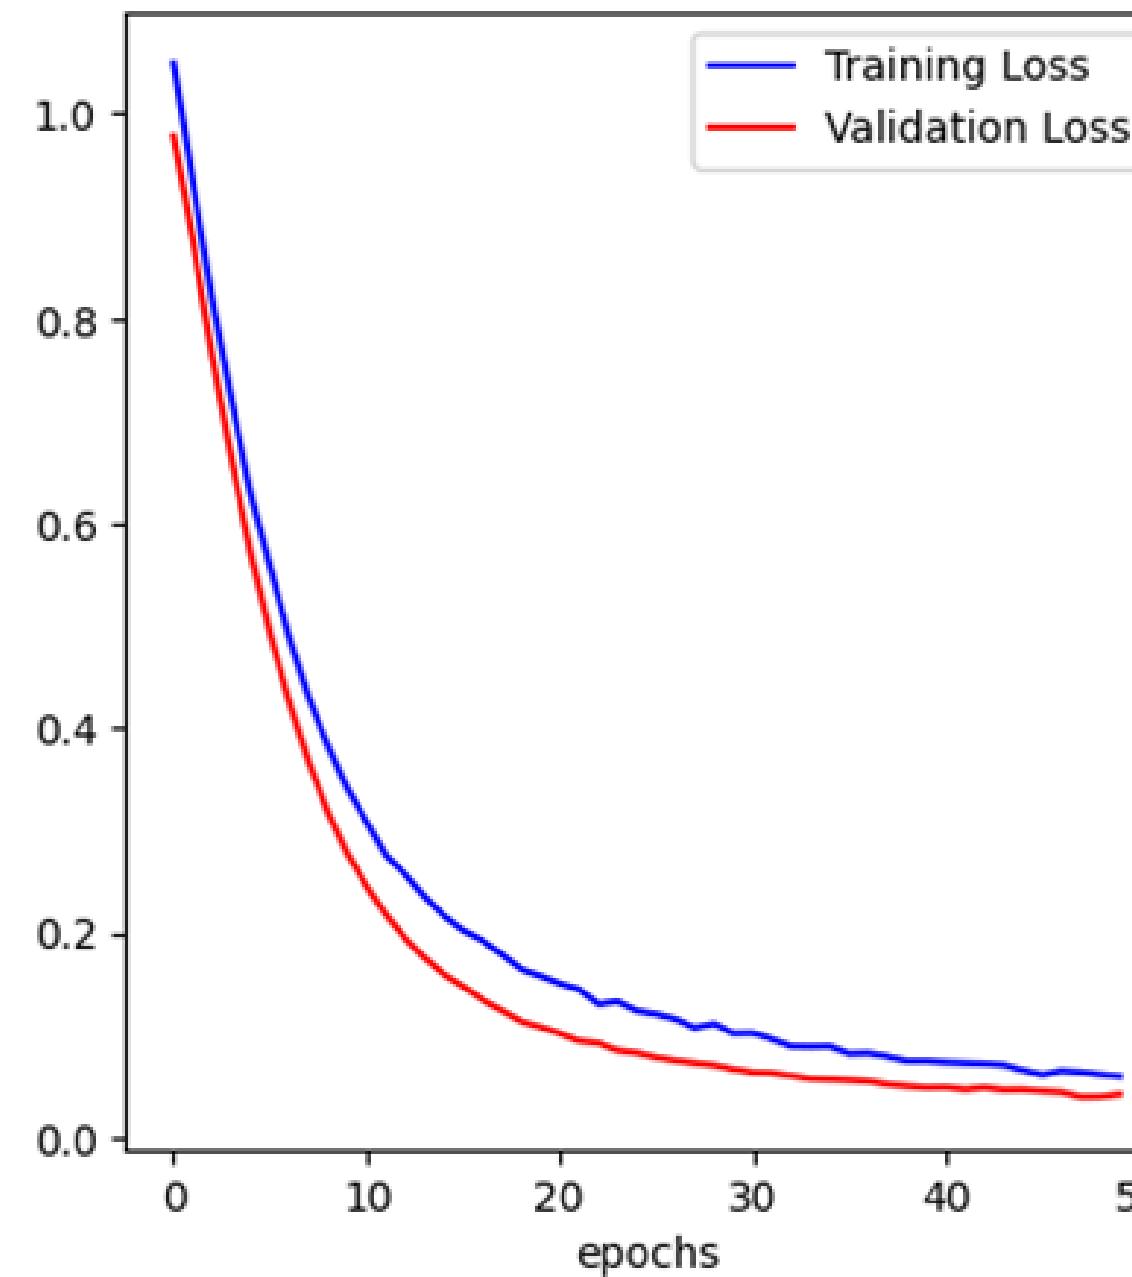
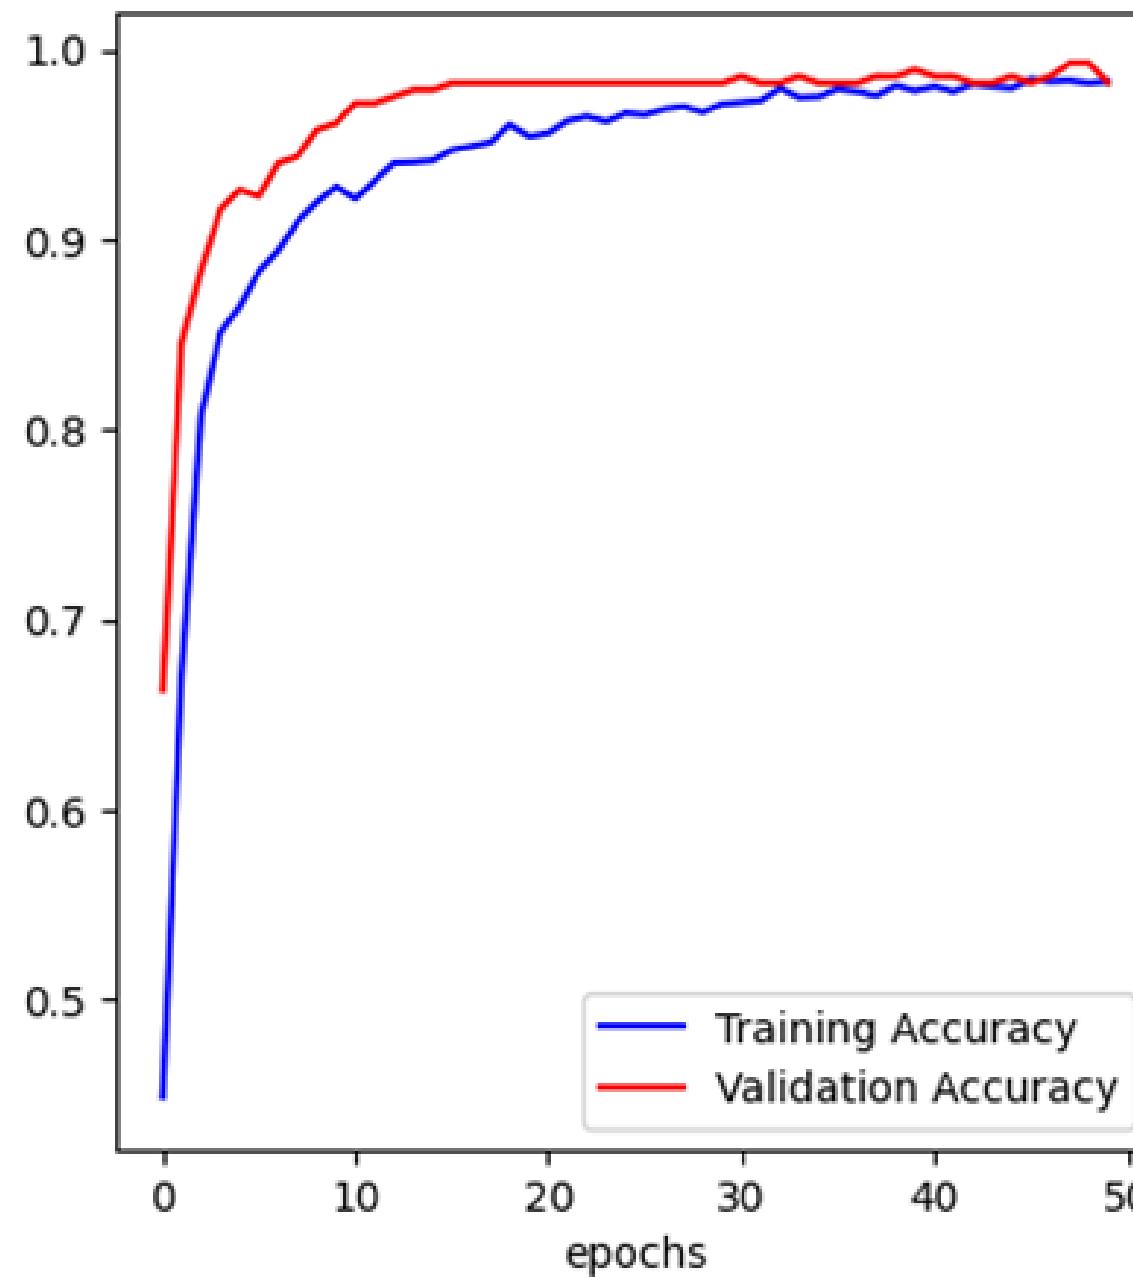


<i>Hyperparameter</i>	<i>Nilai</i>
<i>batch size</i>	32
<i>learning rate</i>	0.00001
<i>loss function</i>	<i>Categorical Cross Entropy</i> <i>(from_logits = True)</i>
<i>hidden units</i>	256, 128, 64
<i>number of epoch</i>	50

# HASIL PELATIHAN DAN VALIDASI EFFICIENTNETV2



Training and validation accuracy



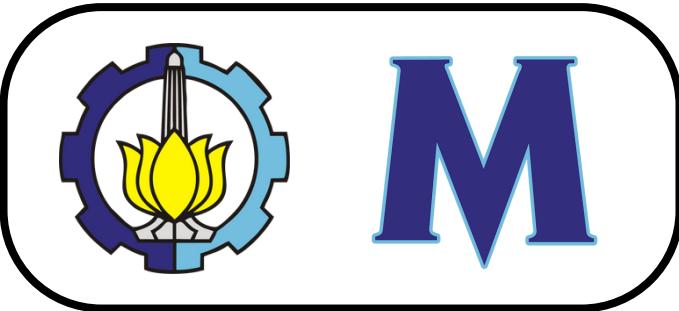
Hasil pengujian model selama 50 epoch:

*Train Accuracy 98.35%*

*Validation Accuracy 98.25%*

*Train Loss 0.0606*

*Validation Loss 0.0421*

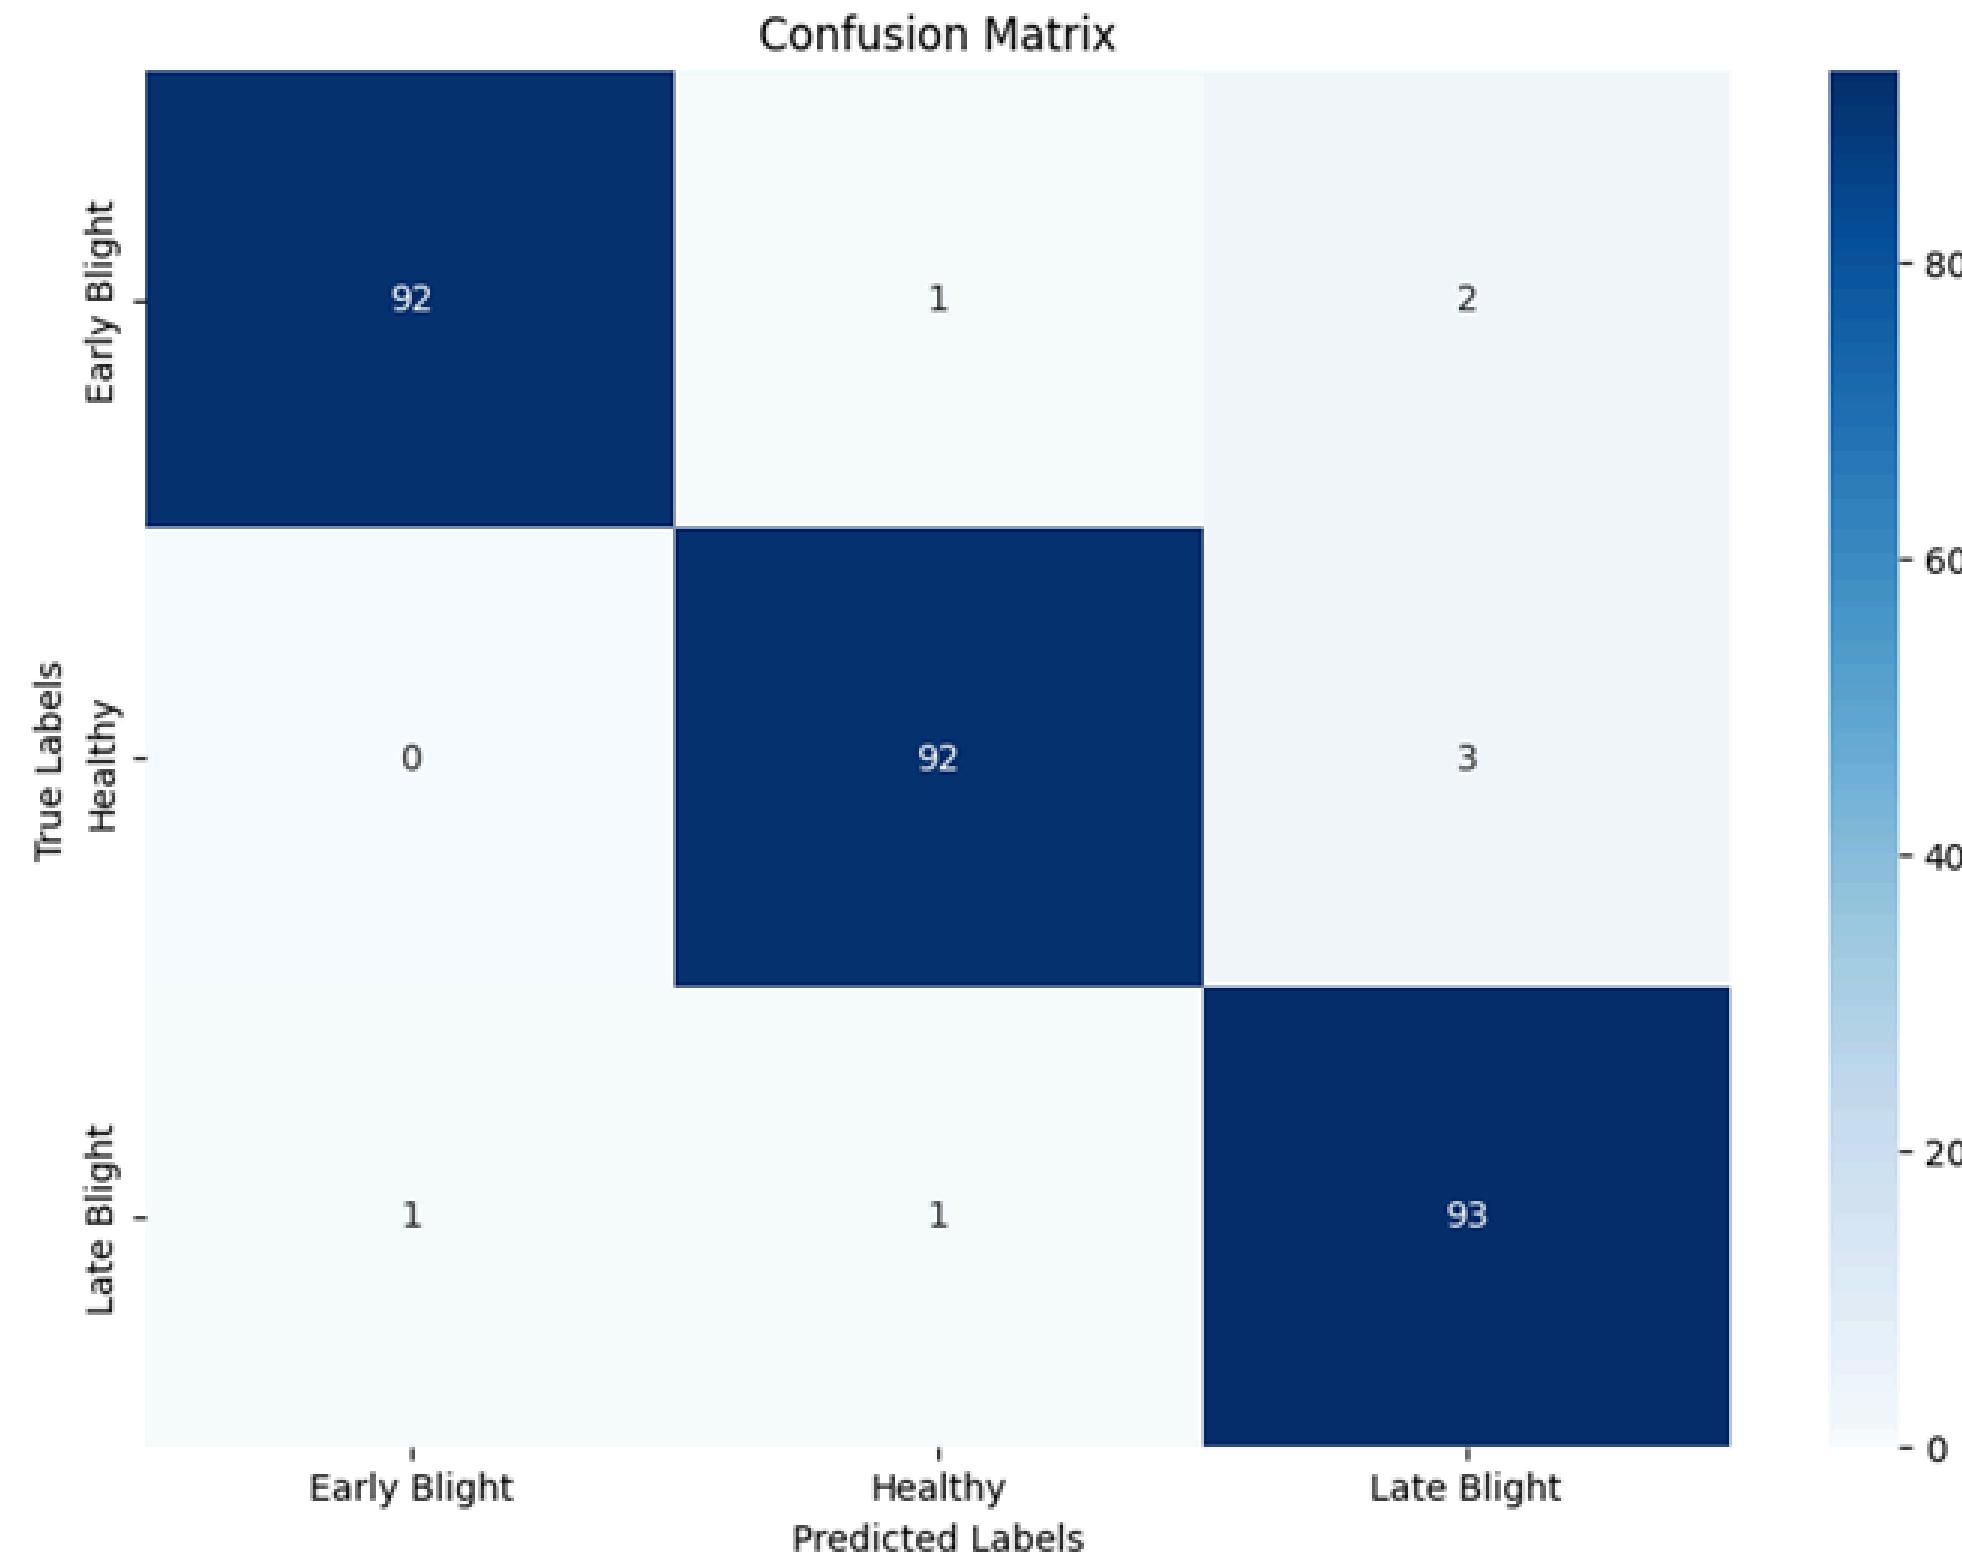
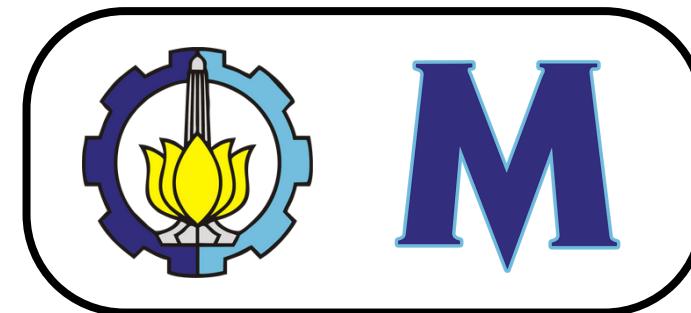


# HASIL PENGUJIAN EFFICIENTNETV2

Berdasarkan hasil pengujian yang telah dilakukan, model berhasil mencapai akurasi pengujian sebesar 97.19% dan nilai *loss* sebesar 0.0655, yang menunjukkan bahwa performa model sangat stabil dan konsisten terhadap data uji. Tabel dibawah menunjukkan perbandingan akurasi pelatihan, validasi, dan uji.

	Train	Validation	Test
<b>Accuracy</b>	98.35%	98.25%	97.19%
<b>Loss</b>	0.0606	0.0421	0.0655

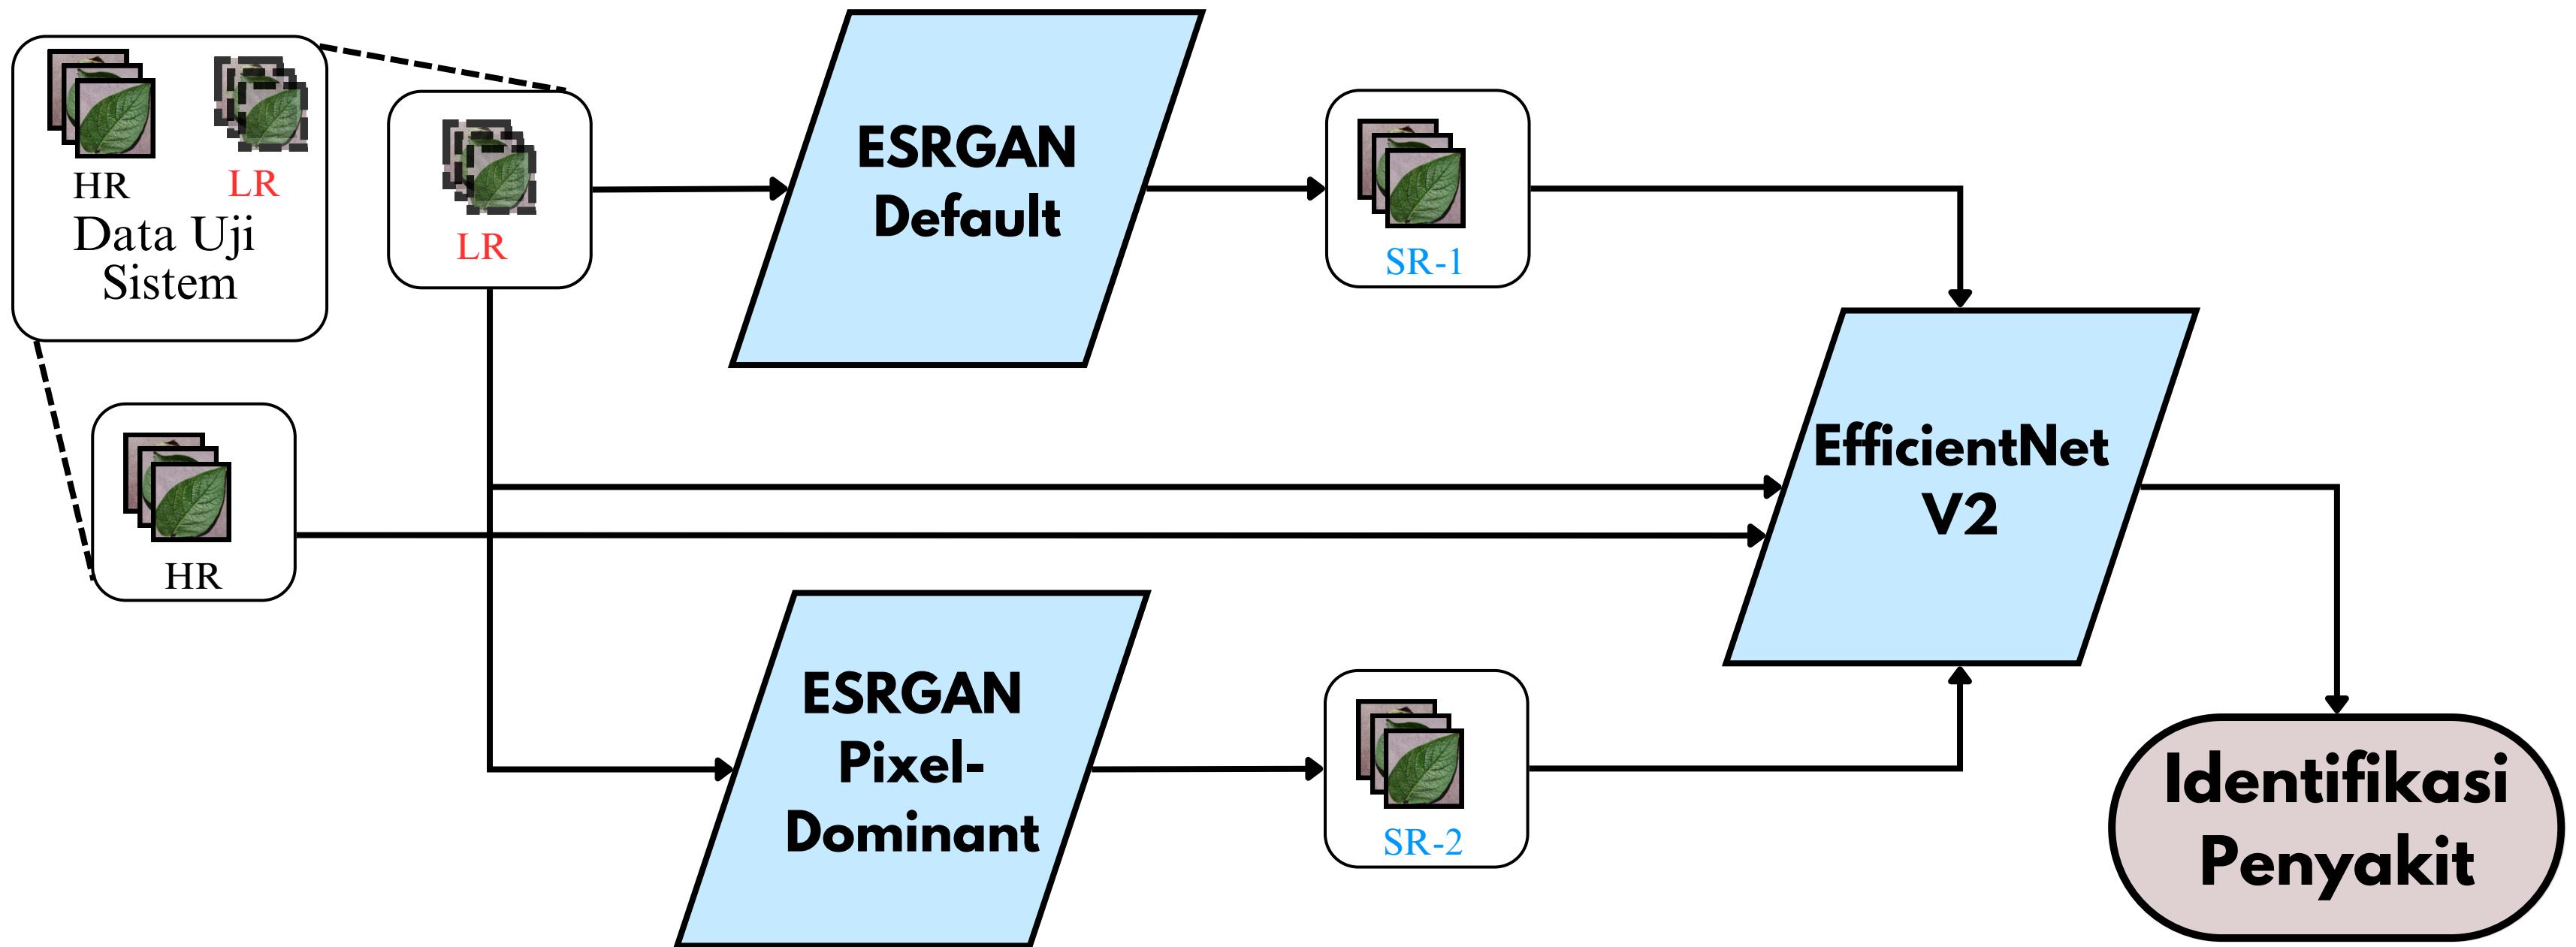
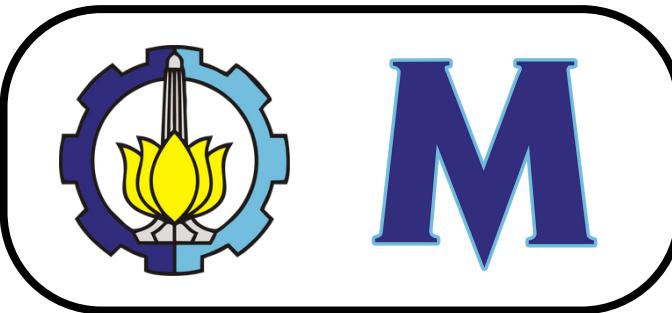
# HASIL PENGUJIAN EFFICIENTNETV2



## Classification Report

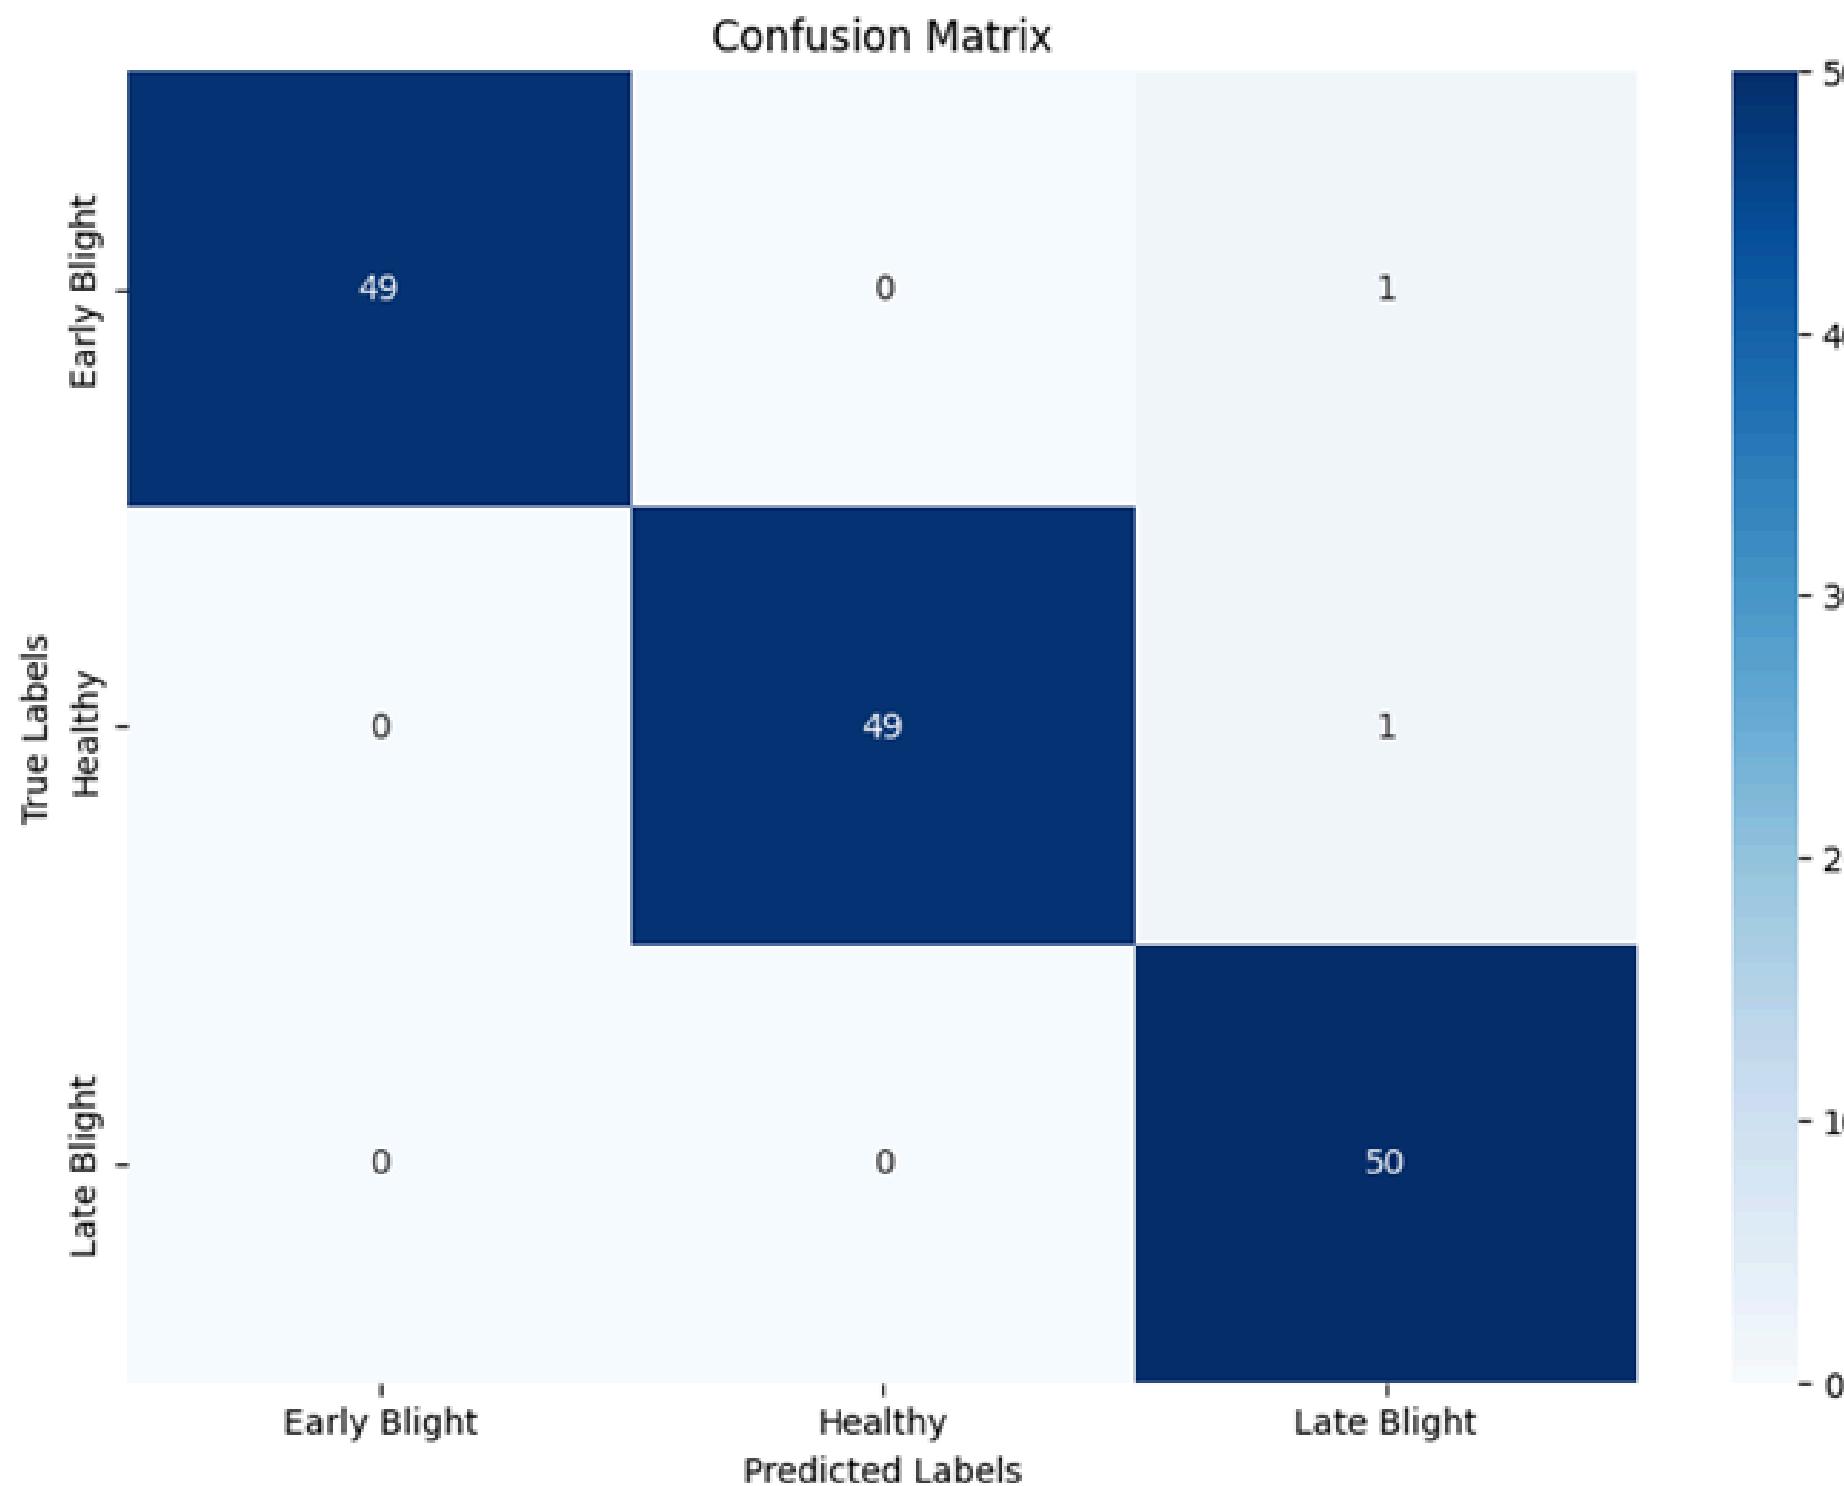
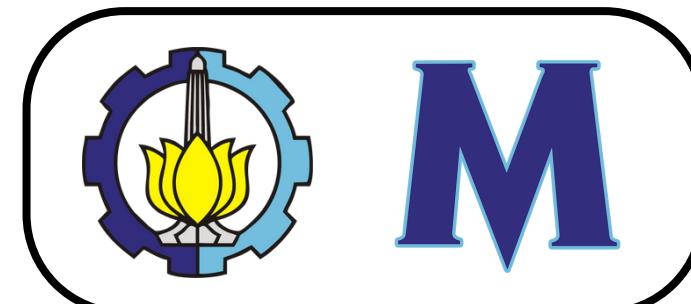
Class	Precision	Recall	F1-score
<i>Early Blight</i>	0.99	0.98	0.98
<i>Healthy</i>	0.98	0.97	0.97
<i>Late Blight</i>	0.95	0.98	0.96

# EVALUASI AKHIR SISTEM



# EVALUASI AKHIR SISTEM

## Pengujian pada Data HR



150 Data Uji Sistem HR

**Accuracy: 98.67%**

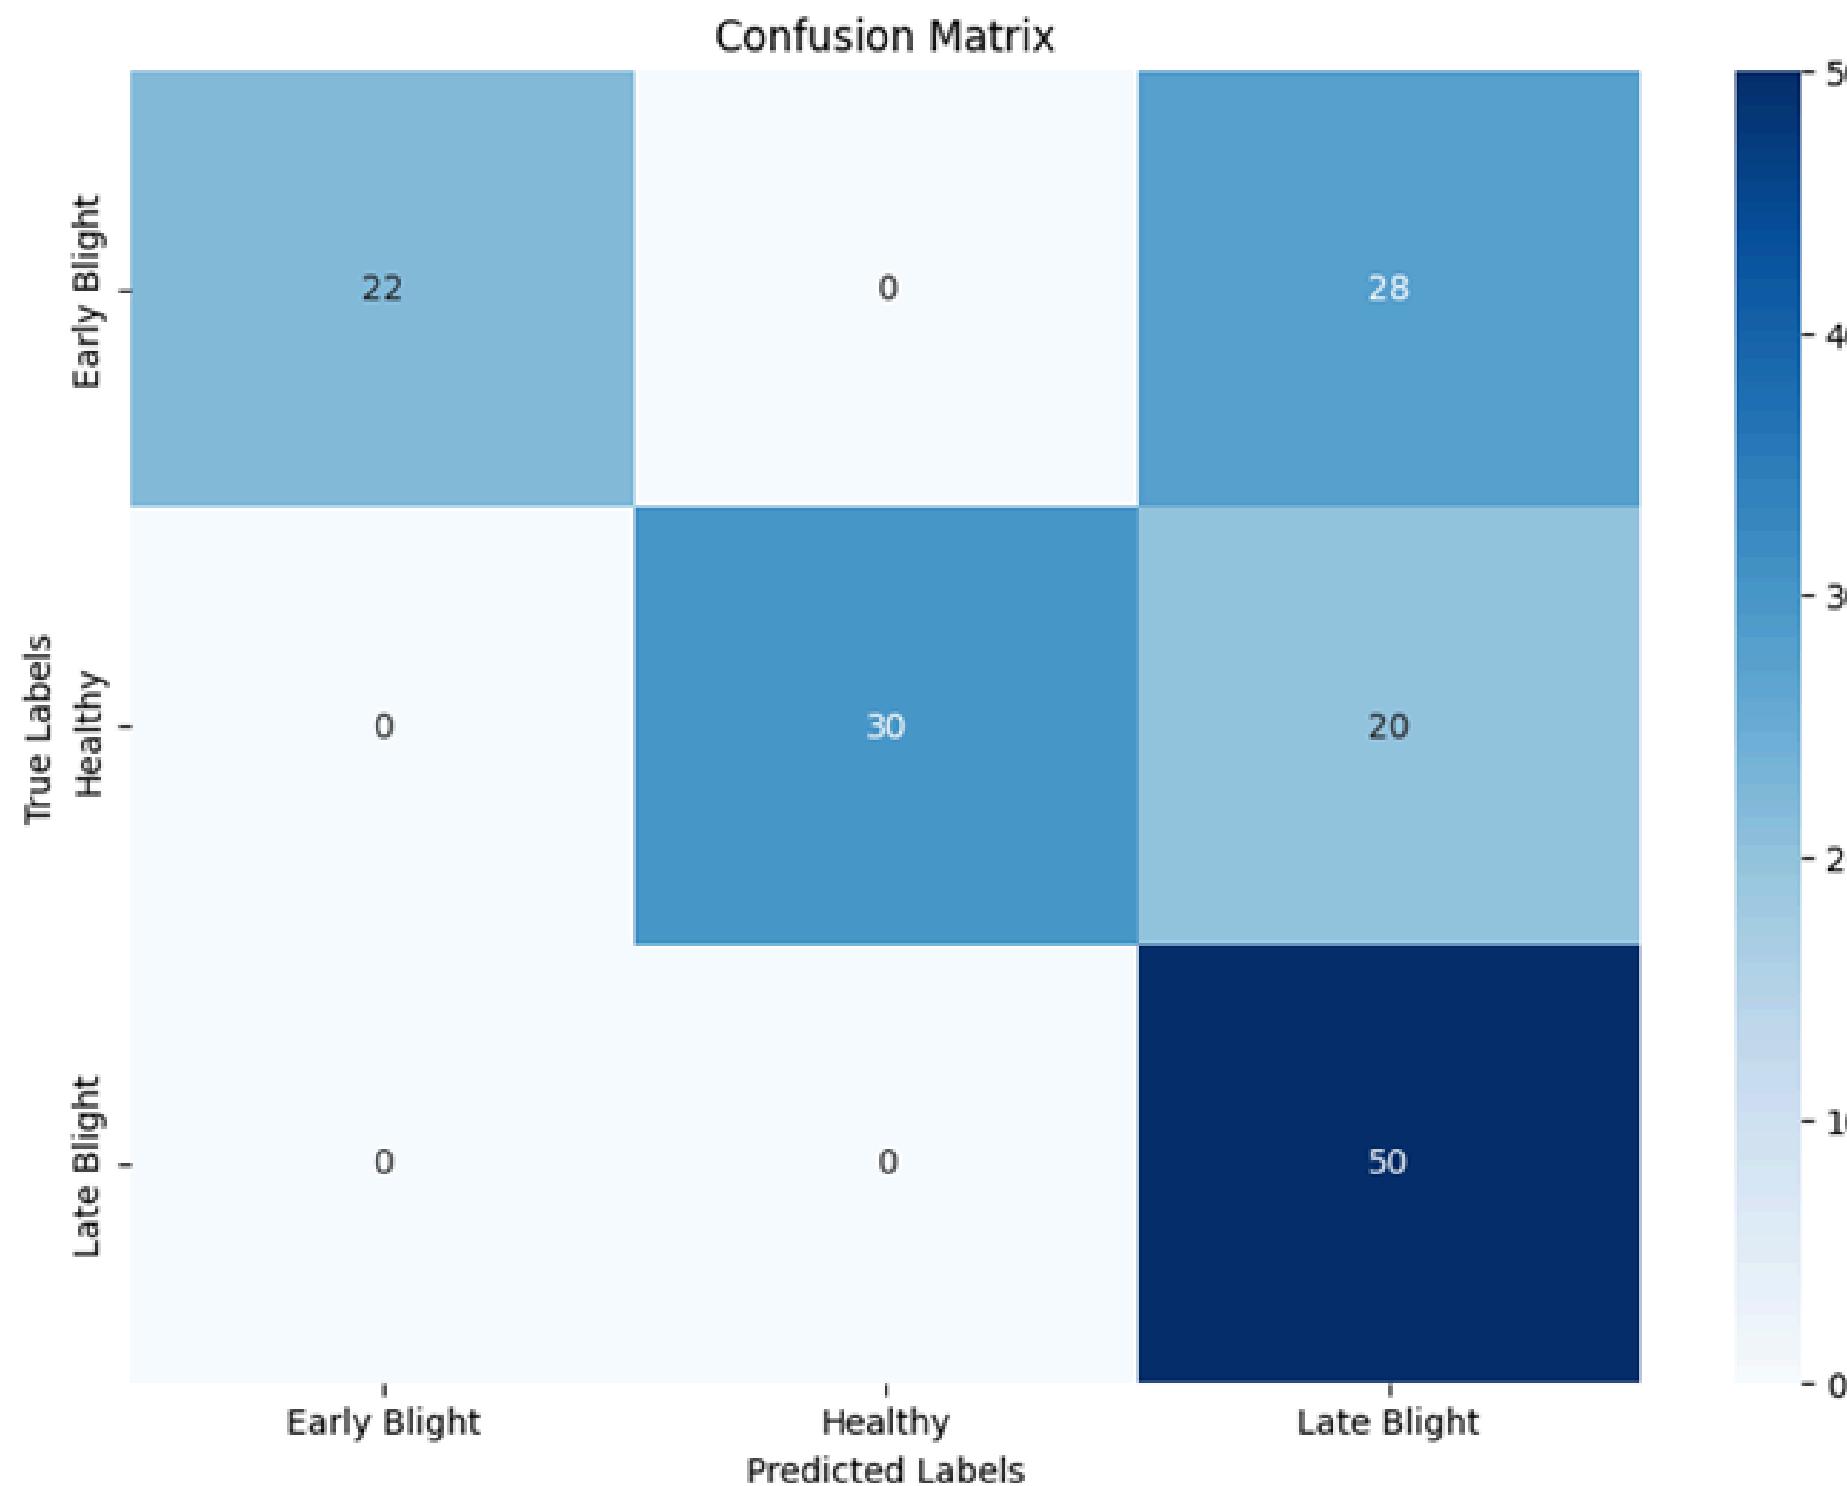
**Loss: 0.04830**

### ***Classification Report***

Class	Precision	Recall	F1-score
<i>Early Blight</i>	1.00	0.98	0.99
<i>Healthy</i>	1.00	0.98	0.99
<i>Late Blight</i>	0.96	1.00	0.98

# EVALUASI AKHIR SISTEM

## Pengujian pada Data LR



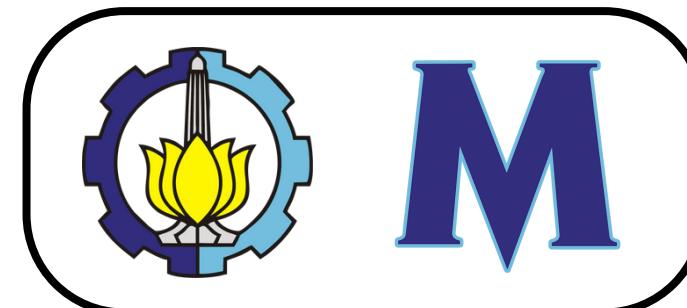
150 Data Uji Sistem LR

**Accuracy: 68.00%**

**Loss: 0.84819**

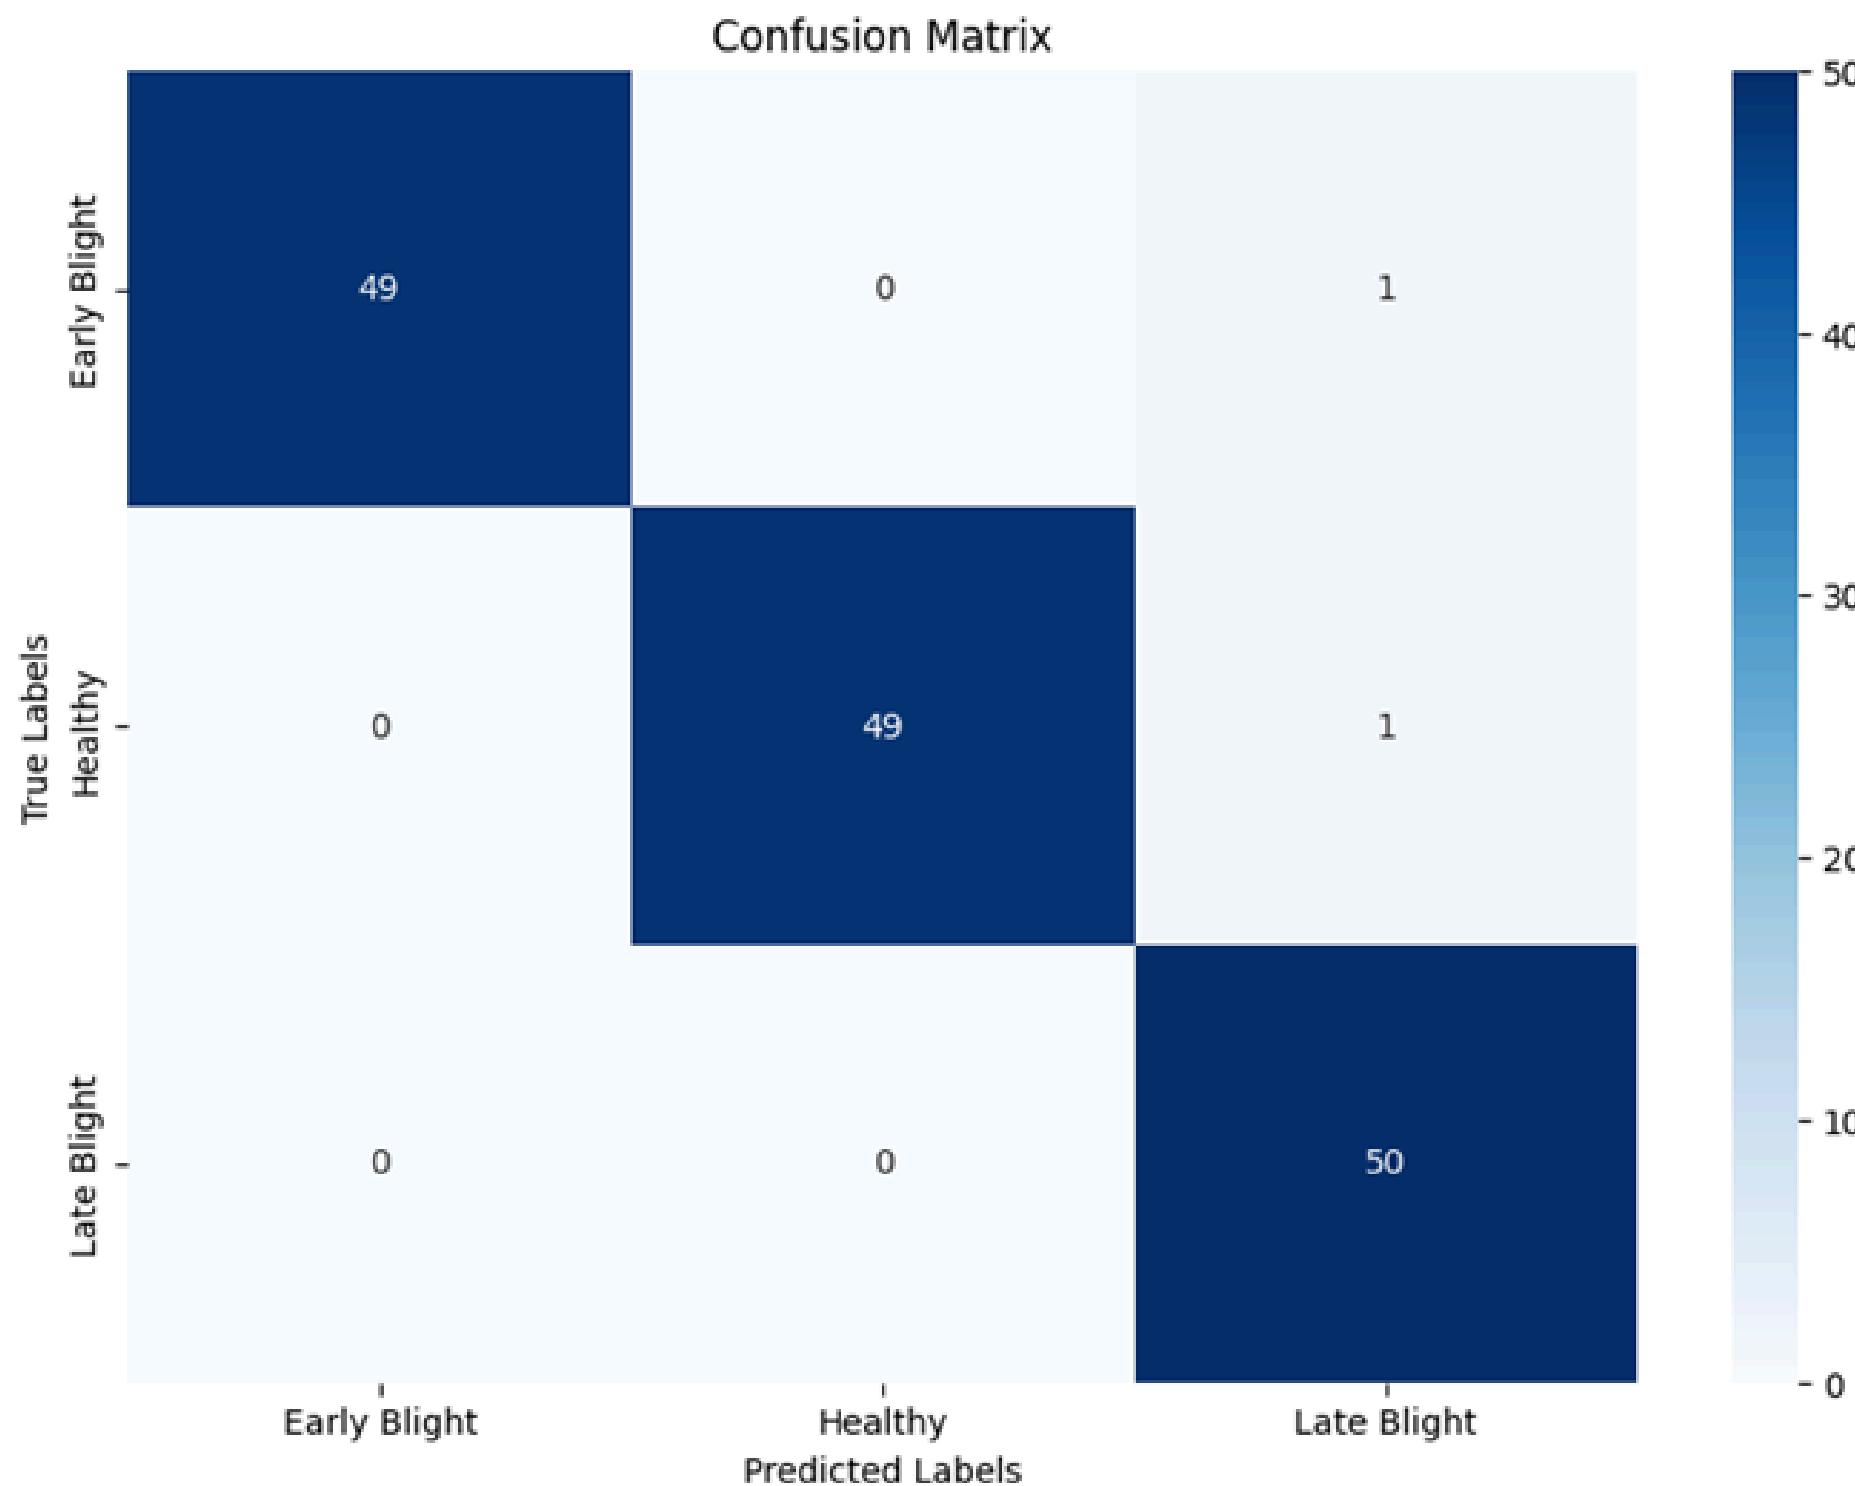
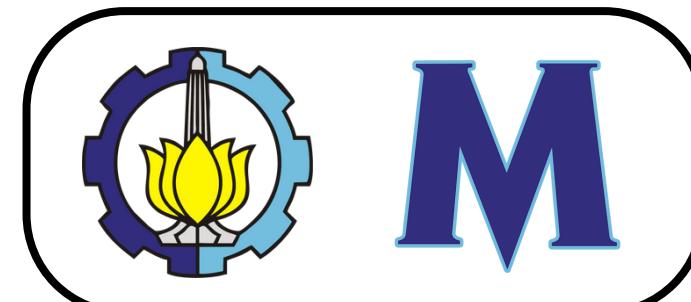
### ***Classification Report***

<i>Class</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
<i>Early Blight</i>	1.00	0.44	0.61
<i>Healthy</i>	1.00	0.60	0.75
<i>Late Blight</i>	0.51	1.00	0.68



# EVALUASI AKHIR SISTEM

## Pengujian pada Data SR Default



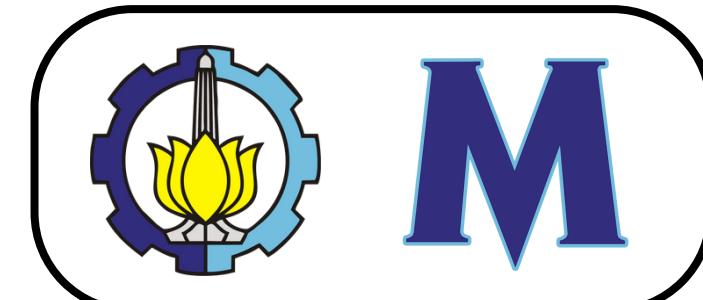
150 Data Uji Sistem SR Default

**Accuracy: 98.67%**

**Loss: 0.04830**

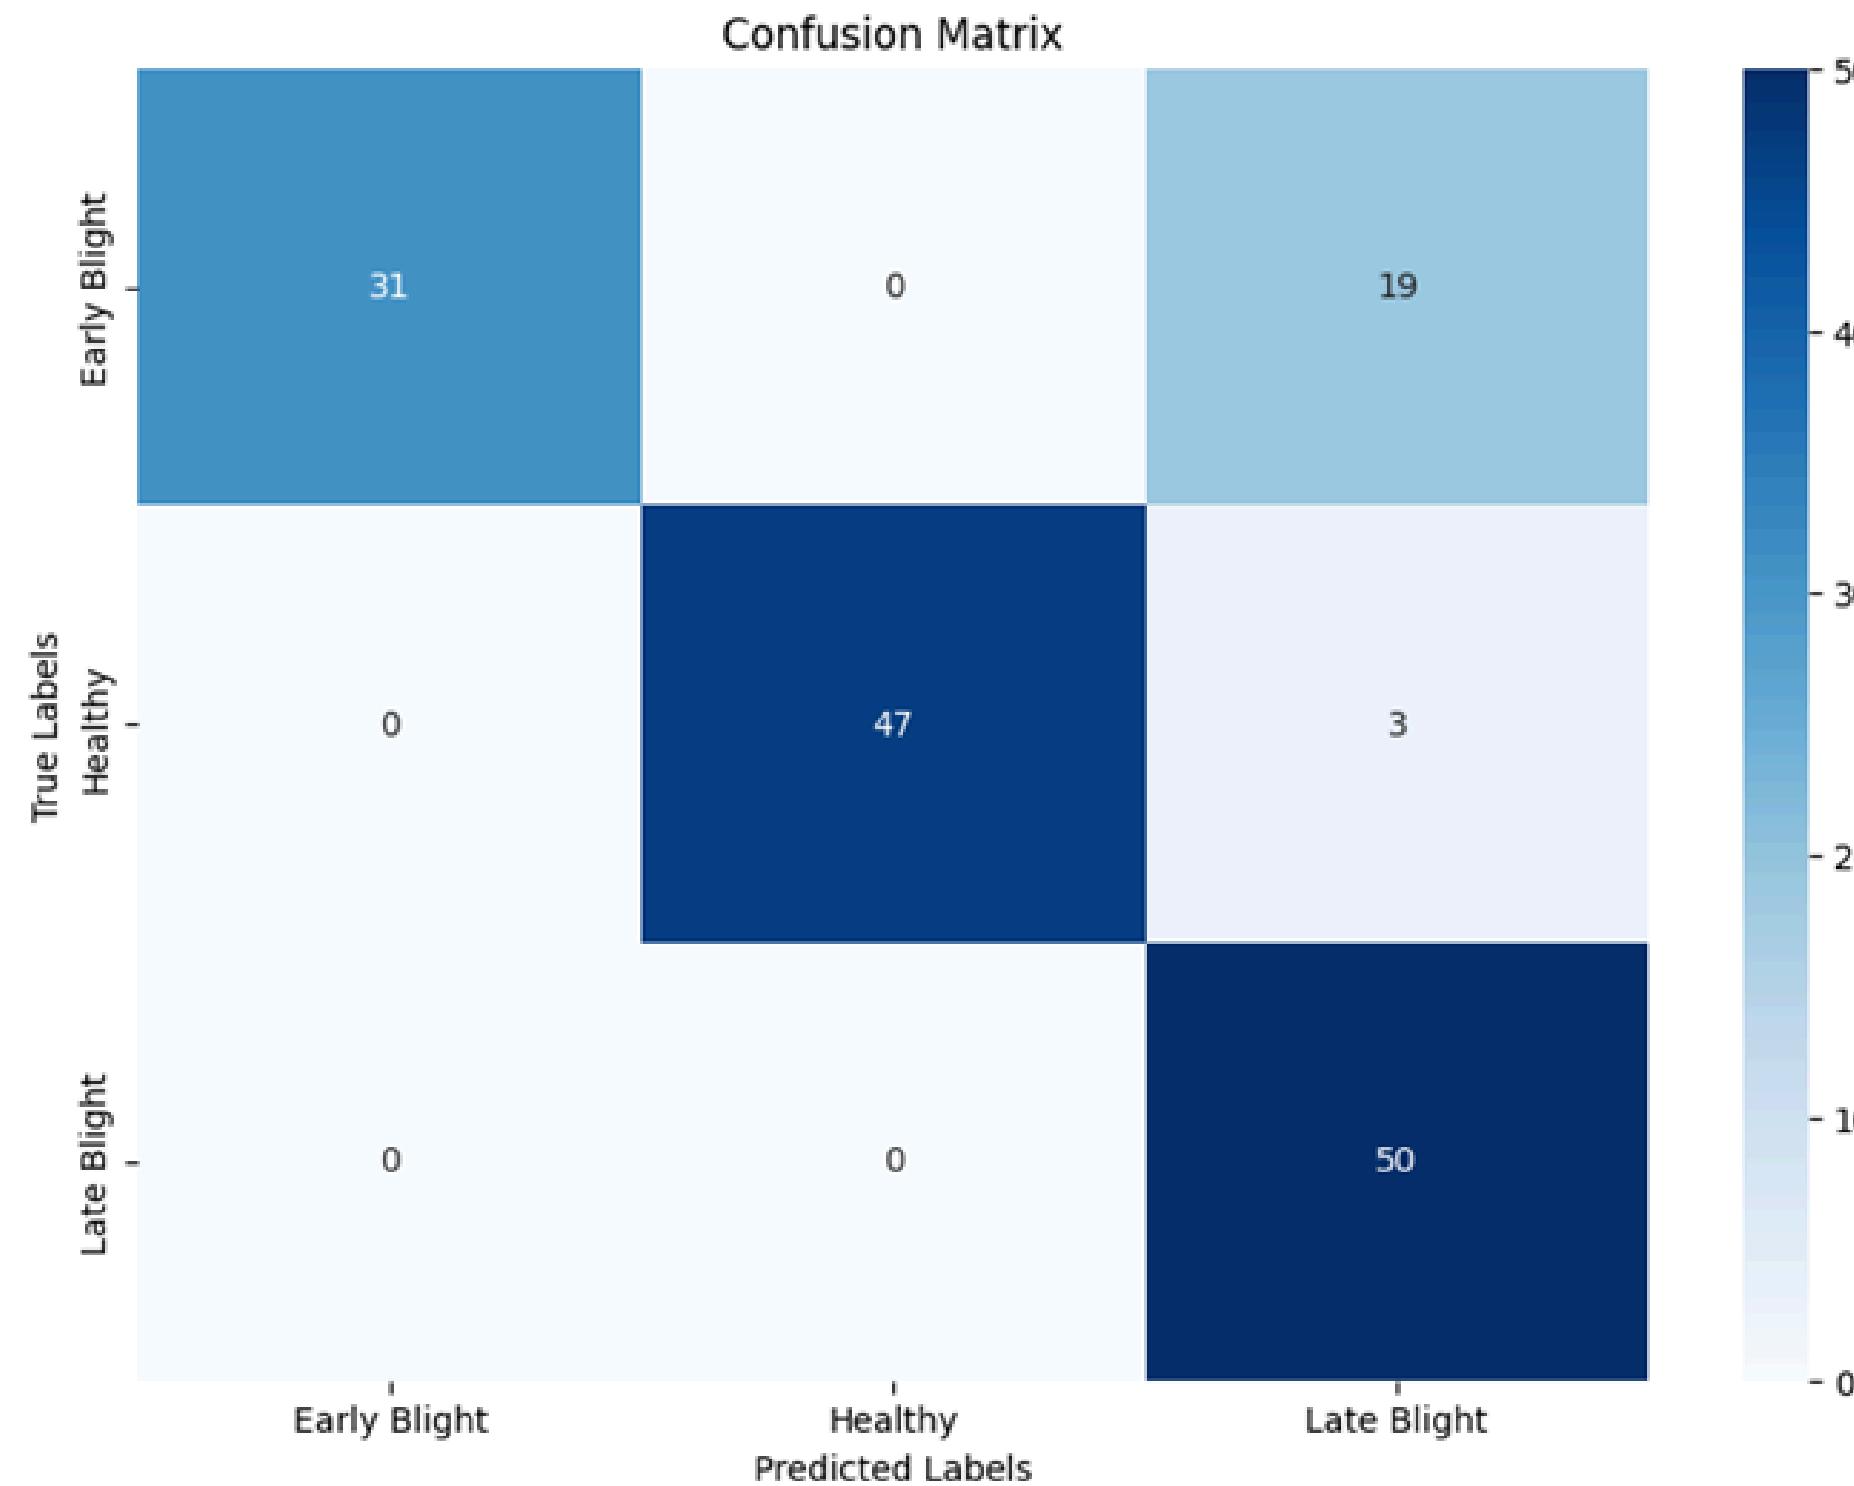
### ***Classification Report***

Class	Precision	Recall	F1-score
Early Blight	1.00	0.98	0.99
Healthy	1.00	0.98	0.99
Late Blight	0.96	1.00	0.98



# EVALUASI AKHIR SISTEM

## Pengujian pada Data SR *Pixel-Dominant*



150 Data Uji Sistem SR *P-Dominant*

**Accuracy: 85.33%**

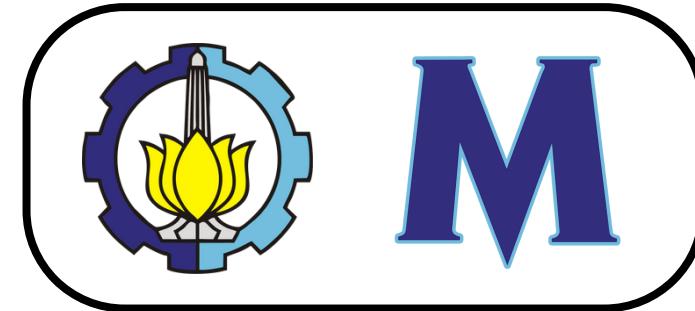
**Loss: 0.43682**

### ***Classification Report***

<i>Class</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
<i>Early Blight</i>	1.00	0.62	0.77
<i>Healthy</i>	1.00	0.94	0.97
<i>Late Blight</i>	0.69	1.00	0.82

# PEMBAHASAN

## Perbandingan Skema Pelatihan ESRGAN



### Skenario *Default*

- Fokus pada persepsi visual → LPIPS rendah (hasil lebih tajam secara visual)
- PSNR dan SSIM sedikit lebih rendah

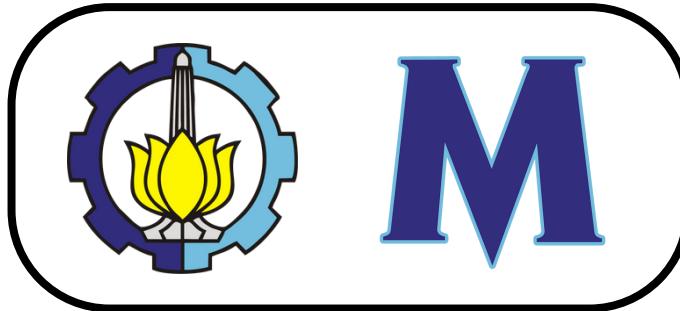
### Skenario *Pixel-Dominant*

- Fokus pada kesamaan piksel → PSNR dan SSIM lebih tinggi
- LPIPS tinggi → citra lebih mulus tapi kehilangan tekstur visual penting

Optimalisasi numerik piksel (PSNR, SSIM) tidak selalu sejalan dengan peningkatan kualitas visual berdasarkan persepsi manusia (LPIPS)

# PEMBAHASAN

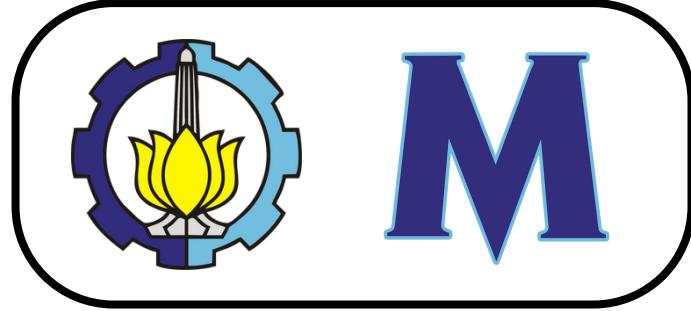
## Pengaruh Kualitas Citra terhadap Performa CNN



- Input SR dari model *default* menghasilkan akurasi klasifikasi 98.67% (Setara HR)
- SR *Pixel-Dominant* hanya 85.33% → fitur semantik hilang
- Input LR hanya 68.00% → resolusi rendah hambat klasifikasi

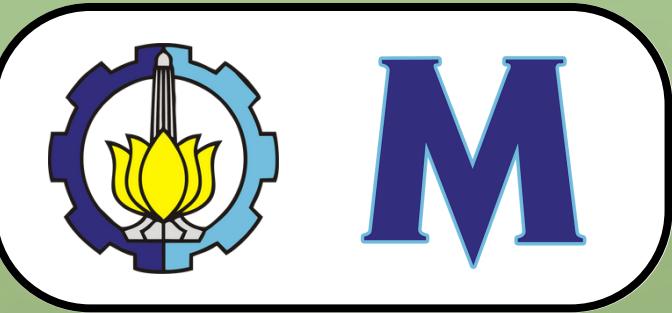
Pendekatan super-resolusi berbasis perceptual tidak hanya menghasilkan gambar yang tampak tajam secara visual, tetapi juga fungsional dalam mendukung kinerja model klasifikasi

# PEMBAHASAN

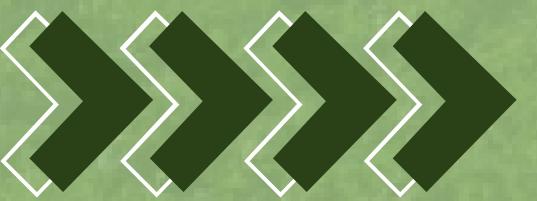


## Hubungan antara Citra dan Performa CNN

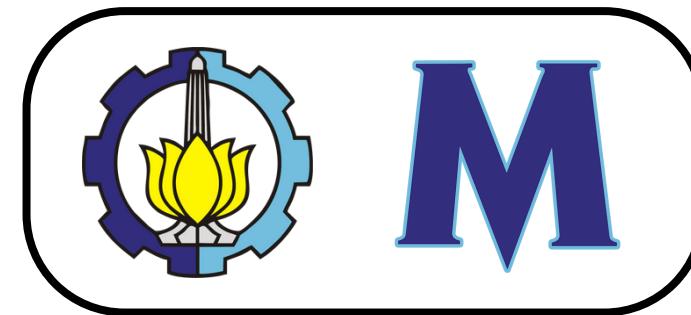
- Kualitas perceptual lebih berpengaruh terhadap CNN daripada kesamaan piksel numerik
- ESRGAN *Default* mampu mengembalikan detail visual penting untuk klasifikasi
- Konsistensi antara persepsi manusia dan performa CNN.



# KESIMPULAN DAN SARAN

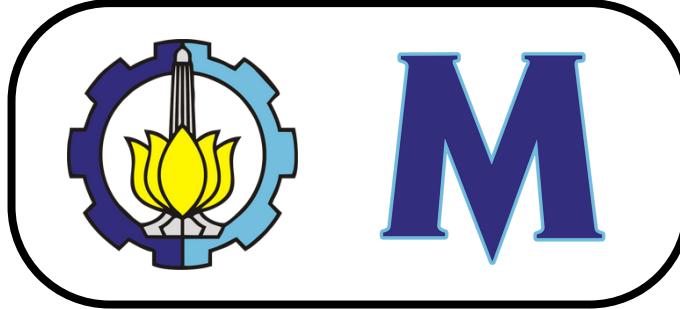


# KESIMPULAN



- Implementasi model ESRGAN telah berhasil dilakukan melalui dua skenario, yaitu default dan pixel-dominant dan telah berhasil diadaptasi dengan baik untuk citra daun kentang berpenyakit.
- Skenario pixel-dominant menghasilkan nilai PSNR dan SSIM masing-masing 22.9620 dan 0.4291 (rekonstruksi struktur piksel yang lebih akurat). Namun model default menghasilkan nilai LPIPS lebih rendah, yaitu 0.1654 yang berarti persepsi visual citra SR lebih mendekati citra asli.
- Kualitas citra hasil ESRGAN berdampak secara signifikan terhadap akurasi klasifikasi penyakit pada daun kentang. ESRGAN berhasil mengembalikan performa klasifikasi mendekati citra HR dengan akurasi mencapai 98.67% dari yang sebelumnya 68.00%

# SARAN



- Penelitian berikutnya menggunakan citra yang lebih bervariasi yang mencakup berbagai kondisi pencahayaan, latar belakang yang tidak seragam, serta berbagai tingkat kerusakan daun sebagaimana yang ditemukan di lapangan.
- Menambahkan lebih banyak kelas penyakit maupun tingkat keparahan penyakit, agar sistem klasifikasi menjadi lebih robust dan aplikatif di dunia nyata.
- Penggunaan data berbasis video beresolusi rendah dari kamera pertanian secara real-time dapat menjadi pendekatan yang lebih praktis untuk pengembangan sistem deteksi penyakit tanaman secara langsung di lapangan.

# THANK YOU